

*Logo ESALQ*

**ESCOLA SUPERIOR DE AGRICULTURA “LUIZ  
DE QUEIROZ”  
UNIVERSIDADE DE SÃO PAULO**

MBA em Data Science e Analytics

**RACISMO ESTRUTURAL NO  
MERCADO DE TRABALHO  
BRASILEIRO: UMA ABORDAGEM  
MULTINÍVEL E DE DECOMPOSIÇÃO  
SALARIAL COM DADOS DA PNAD  
CONTÍNUA (2016–2025)**

**Ricardo Calheiros**

Piracicaba, 2026

## Resumo

Este trabalho investiga o *gap* salarial racial e as barreiras estruturais à progressão de carreira de profissionais negros no Brasil, combinando econometria multinível e métodos de decomposição salarial sobre a série histórica completa da Pesquisa Nacional por Amostra de Domicílios Contínua (PNAD Contínua) de 2016 a 2025 (15,9 milhões de observações brutas). A estratégia empírica articula quatro métodos complementares — modelo linear hierárquico (HLM), decomposição de Oaxaca–Blinder, regressão quantílica com decomposição RIF e modelo logístico multinível (GLMM) —, validados por *machine learning* interpretável (XGBoost + SHAP).

Um modelo linear hierárquico de dois níveis (indivíduos em bairros — UPA —, com efeitos fixos de estado) mostra que 35,3% da variância do log-rendimento está entre bairros e estima que profissionais negros recebem, em média, 10,5% a menos que brancos comparáveis em escolaridade, sexo e idade. Desse diferencial, 39,5% é mediado pelo contexto de moradia (nível 2), reduzindo o *gap* líquido — não explicado por capital humano, bairro nem estado, limite superior da penalidade direta sob seleção em observáveis — a 6,1%.

A decomposição de Oaxaca–Blinder atribui 17,9% do *gap* bruto a retornos diferenciais não explicados por capital humano e contexto; quando a ocupação e a formalidade são tratadas como dotações, essa parcela cai para 15,4% — limite inferior da discriminação salarial *dentro* da ocupação, pois o acesso à ocupação é ele próprio desigual. A decomposição RIF por quantil mostra um padrão de *sticky floor*: esse componente de retorno é maior na base da distribuição (26,5% no q10) e decresce rumo ao topo (8,9% no q90). A desigualdade opera, portanto, também no *acesso* às ocupações — canal que o GLMM mede diretamente.

O GLMM logístico de acesso (intercepto aleatório de UPA) confirma o teto de vidro ocupacional: controlados escolaridade, sexo, idade, estado e contexto do bairro, trabalhadores negros têm *odds* de acesso a cargo qualificado de 0,814 (IC 95% 0,810–0,818) das de brancos do mesmo bairro, que se apertam para 0,761 no topo 10% da renda; o E-value de 1,5 indica robustez a confundidores não observados. O *machine learning* (XGBoost + SHAP) corrobora, sem pressuposto de forma funcional, que a variável racial mantém contribuição negativa direta mesmo após todos os controles e que o contexto territorial figura entre os preditores de maior peso — evidência de que a segregação residencial é um canal relevante da desigualdade, e não mero atributo individual. A penalidade recai de forma agravada sobre a mulher negra, na intersecção de raça e gênero.

**Palavras-chave:** *gap* salarial racial; discriminação estrutural; modelos hierárquicos lineares; decomposição de Oaxaca–Blinder; regressão quantílica; teto de vidro; SHAP values; PNAD Contínua.

## Abstract

This study investigates the racial wage gap and structural barriers to career progression for Black professionals in Brazil, combining multilevel econometrics and wage-decomposition methods on the full historical series of Brazil’s Continuous National Household Sample Survey (PNAD Contínua) from 2016 to 2025 (15.9 million raw observations). The empirical strategy articulates four complementary methods — a hierarchical linear model (HLM), the Oaxaca–Blinder decomposition, quantile regression with RIF decomposition, and a multilevel logistic model (GLMM) —, validated by interpretable machine learning (XGBoost + SHAP).

A two-level hierarchical linear model (individuals nested in neighbourhoods — census tracts —, with state fixed effects) shows that 35.3% of the variance of log earnings lies between neighbourhoods and estimates that Black workers earn 10.5% less than comparable White workers after controlling for education, sex, and age. Of this differential, 39.5% is mediated by residential context (level 2), leaving a *net gap* of 6.1% unexplained by human capital or context — a lower bound on direct labour-market discrimination.

The Oaxaca–Blinder decomposition attributes 17.9% of the raw gap to differential returns unexplained by human capital and context; once occupation and formality are treated as endowments, this share falls to 15.4% — a lower bound on within-occupation wage discrimination, since access to occupations is itself unequal. The quantile RIF decomposition reveals a *sticky floor*: this returns component is largest at the bottom of the distribution (26.5% at q10) and declines toward the top (8.9% at q90). Inequality thus also operates on *access* to occupations — which the GLMM measures directly.

The multilevel logistic model (random intercept by census tract) confirms an occupational glass ceiling: controlling for education, sex, age, state, and neighbourhood context, Black workers face odds of accessing a qualified occupation of 0.814 (95% CI 0.810–0.818) relative to White workers from the same neighbourhood, tightening to 0.761 in the top 10% of income; an E-value of 1.5 indicates robustness to unobserved confounding. Interpretable machine learning (XGBoost + SHAP) corroborates — with no functional-form assumption — that race retains a direct negative contribution after all controls and that territorial context ranks among the strongest predictors, indicating that residential segregation is a relevant channel of inequality rather than a mere individual trait. The penalty falls most heavily on Black women, at the intersection of race and gender.

**Keywords:** racial wage gap; structural discrimination; hierarchical linear models; Oaxaca–Blinder decomposition; quantile regression; glass ceiling; SHAP values; PNAD Contínua.

# Sumário

|                                                                                               |           |
|-----------------------------------------------------------------------------------------------|-----------|
| <b>Em três minutos</b>                                                                        | <b>4</b>  |
| <b>1 Introdução</b>                                                                           | <b>4</b>  |
| 1.1 Hipóteses . . . . .                                                                       | 5         |
| <b>2 Revisão de Literatura</b>                                                                | <b>6</b>  |
| 2.1 Por que haveria discriminação: as duas teorias . . . . .                                  | 6         |
| 2.2 Desigualdade racial no mercado de trabalho brasileiro . . . . .                           | 7         |
| 2.3 Efeitos de vizinhança e segregação residencial . . . . .                                  | 7         |
| 2.4 Modelos lineares hierárquicos para dados aninhados . . . . .                              | 7         |
| 2.5 Decomposições salariais e a distribuição do gap . . . . .                                 | 8         |
| 2.6 Interseccionalidade . . . . .                                                             | 8         |
| 2.7 Interpretabilidade em machine learning: SHAP values . . . . .                             | 8         |
| <b>3 Dados e Metodologia</b>                                                                  | <b>9</b>  |
| 3.1 Base de dados: PNAD Contínua (2016–2025) . . . . .                                        | 9         |
| 3.2 Modelo Linear Hierárquico: indivíduos em bairros (UPA), com efeitos fixos de UF . . . . . | 11        |
| 3.3 Decomposição de Oaxaca–Blinder . . . . .                                                  | 12        |
| 3.4 Regressão quantílica e decomposição RIF . . . . .                                         | 13        |
| 3.5 Modelo logístico multinível de acesso . . . . .                                           | 13        |
| 3.6 Sensibilidade a variáveis omitidas . . . . .                                              | 13        |
| 3.7 Inferência: erros-padrão agrupados, poucos clusters e pesos . . . . .                     | 13        |
| 3.8 Random Forest, XGBoost e SHAP Values . . . . .                                            | 16        |
| <b>4 Resultados</b>                                                                           | <b>16</b> |
| 4.1 Modelos Hierárquicos Lineares — Mediação Contextual do Gap . . . . .                      | 17        |
| 4.2 Modelos de Machine Learning e SHAP Values . . . . .                                       | 24        |
| 4.3 Decomposição do gap por mediação contextual e ocupacional . . . . .                       | 30        |
| 4.4 Decomposição de Oaxaca–Blinder: composição <i>vs.</i> discriminação . . . . .             | 31        |
| 4.5 Regressão Quantílica e RIF-OB: teto de vidro e <i>sticky floor</i> . . . . .              | 33        |
| 4.6 GLMM logístico: o teto de vidro no acesso . . . . .                                       | 35        |
| 4.7 Interseccionalidade: raça e gênero no acesso e no topo . . . . .                          | 38        |
| 4.8 Multicolinearidade do Modelo M4: Análise VIF . . . . .                                    | 40        |
| <b>5 Discussão e Prescrição</b>                                                               | <b>40</b> |
| <b>6 Conclusão</b>                                                                            | <b>44</b> |

## Em três minutos

**O contexto.** Entre 2016 e 2025, um trabalhador negro ganhou em média 10,5% a menos que um branco com a mesma escolaridade, idade e sexo. A explicação usual — “é diferença de qualificação” — já está descontada nesse número.

**O desequilíbrio.** Esse gap não é uma coisa só. Quando se compara apenas pessoas *do mesmo bairro*, ele encolhe: 39,5% do gap transita pela segregação residencial. O que resta — 6,1% — não é explicado por capital humano, bairro ou estado. E, ao olhar quem *entra* nas ocupações qualificadas, a barreira aparece inteira: com o mesmo perfil e o mesmo bairro, a chance de um trabalhador negro ocupar um cargo qualificado é 19% menor; no décimo superior da renda, 24% menor.

**A evidência.** Quatro métodos independentes, sobre a população completa da PNAD Contínua (cerca de 7,7 milhões de observações em 41.459 bairros — o  $N$  exato varia com os filtros de cada método e consta da sua tabela): um modelo hierárquico que separa pessoa e bairro; a decomposição de Oaxaca–Blinder, que separa “ter características diferentes” de “receber preços diferentes”; a regressão quantílica com RIF, que mostra onde na distribuição a penalidade pesa; e um modelo logístico multinível de acesso. Um XGBoost com SHAP confirma, sem impor forma funcional, que a raça mantém contribuição própria. Os erros-padrão são agrupados por bairro, porque a PNAD amostra por conglomerados.

**O que isso muda.** Se o gargalo fosse escolaridade, bastaria ampliar acesso ao ensino. Os resultados dizem outra coisa: parte do gap está em *onde se consegue morar* e a maior parte da barreira está na *porta de entrada* das ocupações — que é onde a Lei 15.142/2025 (cotas em concursos federais, sucessora da Lei 12.990/2014) e a fiscalização da Lei 9.029/1995 atuam. Educação é necessária; sozinha, insuficiente.

*As três seções seguintes detalham, nesta ordem: como o bairro medeia o gap (Barreira I), quanto custa ser negro para quem já está empregado (Barreira II) e o que os números não podem dizer (Limitações).*

## 1 Introdução

Este trabalho mostra que a desigualdade racial no mercado de trabalho brasileiro não se reduz a um desconto salarial isolado — opera como um sistema de barreiras em camadas que começa antes do primeiro salário, na porta de entrada das ocupações qualificadas, e persiste ao longo de toda a trajetória profissional. Políticas baseadas apenas em aumento de escolaridade são, portanto, necessárias, mas estruturalmente insuficientes.

O Brasil é um dos países com maior desigualdade racial de renda no mundo. Segundo a PNAD Contínua, a razão entre o rendimento médio de trabalhadores brancos e negros permanece acima de 1:1,5 ao longo de toda a série histórica disponível, persistindo mesmo quando se controlam escolaridade, experiência e setor de atividade (IBGE, 2023). A desigualdade racial no mercado de trabalho brasileiro é, portanto, não apenas uma herança colonial, mas um fenômeno reproduzido ativamente por mecanismos que a abordagem tradicional de diferenças de capital humano não é capaz de capturar (HASENBALG, 1979).

Esse hiato convive com um quadro macroestrutural recente de **avanço social com desigualdade persistente**. De um lado, a qualidade de vida avançou: entre as edições 2008 e 2018 da Pesquisa de Orçamentos Familiares (POF), o Índice de Perda de Qualidade de Vida recuou cerca de 30% (IBGE, 2019). A melhora, porém, foi proporcional entre os grupos e *não* fechou o hiato racial nem o territorial: famílias chefiadas por pessoas pretas ou pardas mantêm índice de 0,183, contra 0,122 das brancas, e o Nordeste (0,207) e o Norte (0,223) seguem muito acima do Sul (0,114). De outro lado, no rendimento, a desigualdade voltou a crescer: o Gini do rendimento domiciliar *per capita* subiu de 0,487 (2024) para 0,491 (2025), puxado pelo distanciamento do topo — a renda dos 10% mais ricos cresceu 8,7% no ano, contra 3,1% dos 10% mais pobres (IBGE, 2025). É precisamente esse padrão — progresso agregado que não dissolve a barreira racial — que este trabalho dissecou no mercado de trabalho.

A literatura empírica contemporânea identifica três canais principais de reprodução dessa desigualdade: (i) discriminação direta, isto é, diferenças de tratamento em processos de seleção e promoção com características individuais observadas (PAGER, 2007); (ii) segregação residencial e seus efeitos sobre o capital social disponível ao trabalhador — o contexto do bairro define a qualidade das redes de indicação profissional (WILSON, 1987; SAMPSON; RAUDENBUSH; EARLS, 1997); e (iii) subvalorização sistêmica do capital humano negro, pela qual um dado nível de escolaridade gera retornos financeiros menores para trabalhadores negros do que para brancos (HASENBALG, 1979; PAGER, 2007).

Este trabalho avança sobre a literatura nacional ao integrar quatro métodos complementares — modelo linear hierárquico, decomposição de Oaxaca–Blinder, regressão quantílica com decomposição RIF e modelo logístico de acesso —, validados por *machine learning* interpretável, sobre a maior base de dados longitudinal disponível no Brasil para este tema, a PNAD Contínua em sua série completa de 2016 a 2025.

## 1.1 Hipóteses

**H1 Gap racial bruto e líquido:** Profissionais negros apresentam rendimento inferior ao de brancos comparáveis após controlar por escolaridade, experiência potencial e gênero — e esse diferencial persiste após a adição de controles contextuais de nível

de bairro e de estado.

**H2 Mediação pelo networking local:** Uma fração significativa do *gap* racial bruto é explicada pelo contexto socioeconômico do local de moradia (composição racial da UPA, desemprego local, nível educacional médio do entorno) — capturando os efeitos indiretos da segregação residencial sobre a renda.

**H3 Barreira de acesso e teto de vidro:** Trabalhadores negros têm menor chance de acesso a ocupações qualificadas e ao topo da distribuição de renda do que brancos de mesmo perfil, e a penalidade salarial condicional cresce ao longo da distribuição de renda — a discriminação não é um desconto uniforme, mas um teto.

**H4 Importância residual da raça nos modelos preditivos:** Mesmo após controlar por educação, experiência, gênero e contexto de moradia, a variável racial mantém relevância preditiva independente, conforme medida pelos valores SHAP dos modelos de *gradient boosting*.

## 2 Revisão de Literatura

### 2.1 Por que haveria discriminação: as duas teorias

A economia do trabalho oferece duas explicações concorrentes para um diferencial salarial que sobrevive ao controle de produtividade observável, e elas importam porque implicam políticas distintas. Becker (1957) propôs a discriminação *por preferência*: empregadores, colegas ou clientes têm uma desutilidade em transacionar com o grupo minoritário e, por isso, só o contratam a um salário menor. A previsão desse modelo é que a concorrência erode a discriminação — empresas que discriminam pagam mais caro pela mesma produtividade e tendem a ser expulsas do mercado. Arrow (1973) formalizou a alternativa: a discriminação *estatística*, em que o empregador, diante de informação imperfeita sobre a produtividade individual, usa a raça como sinal da média do grupo. Aqui a concorrência não corrige nada; ao contrário, o equilíbrio se autoconfirma, porque o menor retorno esperado desestimula o investimento em qualificação por parte do grupo discriminado.

A distinção tem consequência direta para a leitura dos resultados deste trabalho. O componente de *retornos* da decomposição de Oaxaca–Blinder é compatível com as duas teorias, e os dados observacionais aqui usados não permitem separá-las — uma limitação assumida explicitamente (Seção 6). O que os dados permitem é testar uma implicação comum às duas: se a barreira opera também no *acesso* às ocupações, e não só no preço pago dentro delas, então políticas de qualificação isoladas serão insuficientes sob qualquer das duas hipóteses teóricas.

A tradição brasileira acrescenta uma terceira leitura. Almeida (2019) argumenta que o racismo não é desvio individual nem falha informacional, mas processo estrutural: as instituições reproduzem a desigualdade racial por mecanismos que independem da intenção dos agentes — o que desloca a pergunta de “quem discrimina” para “que arranjos produzem o resultado desigual”. É essa leitura que justifica investigar a segregação residencial e a segregação ocupacional como mecanismos, e não como controles.

## 2.2 Desigualdade racial no mercado de trabalho brasileiro

Hasenbalg (1979) demonstrou pioneiramente que a desigualdade racial no Brasil não decorre apenas de diferenças históricas de acesso à educação, mas de mecanismos ativos de discriminação no mercado de trabalho que convertem desvantagens sociais em desvantagens econômicas de forma cumulativa. Henriques (2001) documentou, para a década de 1990, que a escolaridade média de trabalhadores negros era de cerca de dois anos a menos que a de brancos e que essa diferença explicava apenas parte do diferencial de rendimentos. Soares (2009), cobrindo 1976–2006, estimou por decomposição que em torno de metade do gap racial de rendimentos não era explicada por características observáveis — parcela que sua análise atribui a discriminação salarial e a diferenças de qualidade da educação recebida. Esses são os parâmetros de referência com que os resultados deste trabalho dialogam na Seção 5; a comparação exige cautela, porque a magnitude do componente não explicado depende de quais controles se tratam como dotações (ver Seção 3.3).

## 2.3 Efeitos de vizinhança e segregação residencial

Wilson (1987) propôs a hipótese da *concentrated disadvantage*: a concentração de pobreza em bairros racialmente segregados amplifica desvantagens individuais por meio da redução de redes de contato com o mercado de trabalho formal, degradação de serviços públicos e aumento da violência. Sampson, Raudenbush e Earls (1997) forneceu evidência empírica para essa hipótese em contexto norte-americano, e estudos brasileiros encontraram padrões similares para as regiões metropolitanas (MARQUES, 2010).

A abordagem de *networking* local, operacionalizada neste trabalho pelo segundo nível do modelo hierárquico (UPA), testa se o contexto socioeconômico do bairro exerce efeito independente sobre o rendimento após controlar por características individuais — o chamado *duplo disadvantage* de ser negro e morar em bairros negros.

## 2.4 Modelos lineares hierárquicos para dados aninhados

Raudenbush e Bryk (2002) sistematizaram a fundamentação estatística dos modelos lineares hierárquicos (HLM), tornando-os o padrão metodológico para análise de dados



com estrutura aninhada (indivíduos dentro de bairros dentro de estados). Esses modelos permitem decompor a variância do desfecho em componentes de cada nível e estimar os efeitos contextuais controlando simultaneamente pelos efeitos individuais.

## 2.5 Decomposições salariais e a distribuição do gap

O instrumental que separa “ter características diferentes” de “receber preços diferentes” vem de Oaxaca (1973) e Blinder (1973), que propuseram, de forma independente, decompor a diferença de médias entre dois grupos em uma parcela de *dotações* — atribuível a diferenças nas características observáveis — e outra de *retornos*, atribuível a diferenças nos coeficientes com que essas características são remuneradas. Oaxaca e Ransom (1999) mostraram, porém, que a repartição não é única: ela depende de quais variáveis se admite como dotação. Tratar a ocupação como característica do trabalhador desloca para a parcela explicada toda a desigualdade que opera pela porta de entrada da ocupação — razão pela qual este trabalho reporta as duas especificações lado a lado.

A decomposição de médias, contudo, descreve apenas o trabalhador médio. Koenker e Bassett (1978) introduziram a regressão quantílica, que estima o efeito de um regressor em cada ponto da distribuição condicional e permite verificar se a penalidade racial é uniforme ou se cresce rumo ao topo — a formulação estatística do teto de vidro. Firpo, Fortin e Lemieux (2018) estenderam a decomposição para quantis *incondicionais* por meio de regressões da função de influência recentrada (RIF), respondendo a uma pergunta distinta: de que é feito o gap em um dado ponto da distribuição de renda do país, e não da distribuição condicional a um perfil. As duas leituras são complementares e, como se verá, apontam para padrões aparentemente opostos que descrevem o mesmo fenômeno (Seção 4.5).

## 2.6 Interseccionalidade

Crenshaw (1989) cunhou o conceito de interseccionalidade a partir da constatação de que a experiência de mulheres negras não é descrita pela soma das categorias “mulher” e “negra”: há um efeito próprio da posição na interseção dos eixos, que análises que tratam raça e gênero separadamente não capturam. Empiricamente, isso implica testar se o diferencial do grupo excede a soma dos diferenciais isolados — e, portanto, se políticas desenhadas para um eixo de cada vez deixam de fora justamente quem está na interseção.

## 2.7 Interpretabilidade em machine learning: SHAP values

Lundberg e Lee (2017) propuseram os *SHapley Additive exPlanations* (SHAP), unificando importância de variáveis, efeitos parciais e explicações individuais em uma única estrutura axiomática baseada na teoria dos jogos cooperativos. Para dados socioeconô-

nicos, SHAP permite responder à pergunta: “quanto e em que direção a raça de um indivíduo específico afeta a predição de sua renda?” — uma contribuição metodológica que complementa e enriquece a interpretação dos coeficientes do HLM.

## 3 Dados e Metodologia

### 3.1 Base de dados: PNAD Contínua (2016–2025)

A PNAD Contínua é uma pesquisa amostral de domicílios conduzida trimestralmente pelo IBGE, com cobertura nacional e metodologia de painel rotativo. O microdado contém informações sobre características demográficas, escolaridade, inserção no mercado de trabalho e rendimentos para todos os moradores dos domicílios selecionados. Para este trabalho, foram processados todos os 40 trimestres disponíveis de 2016T1 a 2025T4, totalizando 15.941.675 observações brutas, das quais 7.699.278 possuem renda positiva declarada e completude nas variáveis do modelo. Como cada método exige um conjunto um pouco diferente de variáveis, o  $N$  efetivo varia pouco entre eles: 7.694.080 no HLM, 7.699.273 no GLMM, 7.699.278 na Oaxaca–Blinder e 7.699.273 no aprendizado de máquina (treino e teste somados). Pelo mesmo motivo o número de bairros varia — 41.459 na Oaxaca–Blinder e 41.454 no modelo de acesso —, e o HLM usa 40.728, porque exclui as UPAs com menos de dez observações para estimar a variância entre bairros com estabilidade.

O desfecho de rendimento é o **rendimento mensal efetivo de todos os trabalhos** (VD4020), em logaritmo, convertido para reais constantes do 2º trimestre de 2026 pelo deflator oficial da PNAD Contínua (IBGE), que varia por UF e trimestre; como a deflação não remove choques comuns a cada ano, todos os modelos incluem ainda efeitos fixos de ano. A unidade importa para ler os controles: como o rendimento é mensal e não por hora, a jornada *habitual* (VD4031) entra como controle necessário — sem ela, compara-se o rendimento de quem trabalha meio período com o de quem trabalha jornada integral e atribui-se a diferença à raça.

A escolaridade vem da VD3004 (nível de instrução mais elevado alcançado, harmonizado pelo IBGE) e entra como *dummies cumulativas* de conclusão de ciclo — fundamental completo ou mais, médio completo ou mais, superior completo ou mais e pós-graduação (superior completo cujo curso mais elevado frequentado, V3009A, é especialização, mestrado ou doutorado). Cada coeficiente é, assim, o ganho marginal de completar o ciclo seguinte, e a variável cobre toda a população analisada.

**O que é a UPA e por que este trabalho a chama de bairro.** A Unidade Primária de Amostragem (UPA) *não* é um recorte criado para este trabalho: é a unidade do desenho amostral da própria PNAD Contínua (IBGE, 2023). Em cada estrato, o IBGE sorteia

setores censitários — ou pequenos conjuntos de setores vizinhos, quando um setor tem poucos domicílios — e, dentro de cada um, um grupo de domicílios que é entrevistado em cinco trimestres consecutivos. O código da UPA vem no microdado público (variável UPA), e é isso que permite saber quais entrevistados moram perto uns dos outros. Como o setor censitário reúne algumas centenas de domicílios contíguos, a UPA é a menor unidade territorial que a PNAD identifica e a mais próxima da ideia de vizinhança; por isso, ao longo do texto, ela é chamada de *bairro*. A correspondência é aproximada, e convém dizê-lo: a UPA costuma ser menor que um bairro administrativo de cidade grande e, na zona rural, pode cobrir uma área extensa. Onde a precisão técnica importa — equações do modelo, componentes de variância, erros-padrão agrupados —, o texto usa UPA; no restante, bairro.

A classificação racial segue o critério binário adotado pelos estudos de desigualdade racial no Brasil: *negro* = preto (código 2) + pardo (código 4); *branco* = branco (código 1), ambos da variável V2010 (cor ou raça autodeclarada).

**De que é feita a comparação: balanceamento e suporte comum.** Antes de qualquer controle, convém olhar em que brancos e negros diferem — é o que mostra a Tabela 1. O maior desequilíbrio não está em escolaridade nem em horas: está em *onde se mora*. A composição racial do bairro tem diferença padronizada de  $-1,17$  desvios — uma ordem de grandeza acima de qualquer variável individual —, seguida do desemprego local ( $-0,46$ ) e da educação média do entorno ( $0,42$ ). É esse desequilíbrio que o nível 2 do modelo hierárquico absorve. O suporte comum é amplo: 97,2% das UPAs abrigam trabalhadores dos dois grupos e todas as células UF  $\times$  escolaridade contêm brancos e negros, de modo que a comparação não depende de extrapolação (ANGRIST; PISCHKE, 2009).

**Tabela 1:** Balanceamento entre trabalhadores brancos e negros *antes* de qualquer controle — a tabela que mostra de que é feita a comparação (Angrist & Pischke, cap. 3). Diferença padronizada:  $d = (\bar{x}_b - \bar{x}_n)/\sqrt{(s_b^2 + s_n^2)/2}$ ; valores acima de 0,10 em módulo indicam desequilíbrio relevante. População completa da PEA com renda positiva ( $N = 7.699.278$ ; 3.271.443 brancos e 4.427.835 negros).

| Variável                     | Brancos | Negros | Diferença | $d$   |
|------------------------------|---------|--------|-----------|-------|
| log do rendimento            | 7,872   | 7,447  | 0,425     | 0,49  |
| Idade (centrada)             | -1,637  | -3,120 | 1,483     | 0,11  |
| Sexo feminino                | 0,437   | 0,399  | 0,038     | 0,08  |
| Fundamental completo ou mais | 0,790   | 0,687  | 0,103     | 0,24  |
| Médio completo ou mais       | 0,660   | 0,531  | 0,129     | 0,27  |
| Superior completo ou mais    | 0,276   | 0,142  | 0,134     | 0,34  |
| Pós-graduação                | 0,083   | 0,036  | 0,047     | 0,20  |
| log(horas trabalhadas)       | 3,645   | 3,601  | 0,044     | 0,11  |
| Reside em área urbana        | 0,814   | 0,774  | 0,039     | 0,10  |
| Emprego formal               | 0,494   | 0,441  | 0,053     | 0,11  |
| Conta própria                | 0,276   | 0,281  | -0,005    | -0,01 |
| Trabalho doméstico           | 0,049   | 0,079  | -0,030    | -0,12 |
| CBO: dirigente               | 0,055   | 0,023  | 0,032     | 0,16  |
| CBO: profissional            | 0,151   | 0,079  | 0,072     | 0,23  |
| CBO: técnico                 | 0,090   | 0,067  | 0,023     | 0,09  |
| % negro na UPA ( $z$ )       | -0,705  | 0,329  | -1,034    | -1,17 |
| Desemprego na UPA ( $z$ )    | -0,331  | 0,091  | -0,422    | -0,46 |
| Educ. média na UPA ( $z$ )   | 0,390   | -0,024 | 0,414     | 0,42  |

*Suporte comum:* 97,2% das UPAs têm trabalhadores dos dois grupos, e 100,0% das células UF  $\times$  escolaridade também (100,0% das observações estão em células com os dois grupos) — a comparação não depende de extrapolar para regiões da amostra onde só existe um dos grupos.

### 3.2 Modelo Linear Hierárquico: indivíduos em bairros (UPA), com efeitos fixos de UF

A PNAD Contínua é amostrada por conglomerados: pessoas dentro de unidades primárias de amostragem (UPA, o proxy de bairro), dentro de estados. A hipótese substantiva do trabalho (H1) é que o *bairro* media parte do gap racial; o modelo, portanto, coloca a UPA no nível 2 e trata a UF como conjunto de efeitos fixos — 27 unidades são poucas para um terceiro nível aleatório (ANGRIST; PISCHKE, 2009), e os 26 *dummies* absorvem todo o contexto estadual sem hipóteses distribucionais. O modelo de dois níveis é dado pelas eq. (1) e (2):

**Nível 1 — indivíduo  $i$  na UPA  $j$ , eq. (1):**

$$\ln(W)_{ij} = \beta_{0j} + \beta_1 \text{Negro}_{ij} + \beta_2 \text{Sexo}_{ij} + \beta_3 X_{ij} + \beta_4 X_{ij}^2 + \beta'_E \mathbf{E}_{ij} + \beta'_5 \mathbf{Z}_{ij} + \varepsilon_{ij} \quad (1)$$

em que  $\mathbf{E}$  reúne as variáveis indicadoras cumulativas de escolaridade,  $\mathbf{Z}$  reúne horas, situação urbana e ano (e, no M4, vínculo e grupo CBO), e o termo de erro é  $\varepsilon_{ij} \sim \mathcal{N}(0, \sigma^2)$ .

**Nível 2 — bairro  $j$  (UPA), eq. (2):**

$$\beta_{0j} = \gamma_{00} + \gamma_{01} \overline{\%Negro_j} + \gamma_{02} \overline{\text{Desemprego}_j} + \gamma_{03} \overline{\text{Educ}_j} + \sum_{k=2}^{27} \delta_k \text{UF}_{k(j)} + u_{0j} \quad (2)$$

com  $u_{0j} \sim \mathcal{N}(0, \tau_{\text{UPA}}^2)$ . O coeficiente  $\gamma_{01} < 0$  é a evidência de *duplo disadvantage*: morar em bairros com maior concentração de negros reduz o rendimento *independentemente* da raça individual. A correlação intraclasses, calculada por  $\rho_{\text{UPA}} = \tau_{\text{UPA}}^2 / (\tau_{\text{UPA}}^2 + \sigma^2)$ , mede a fração da variância do log-rendimento que está *entre* bairros; valores acima de 5% justificam o modelo multinível (RAUDENBUSH; BRYK, 2002).

**Estratégia *step-up*.** Seguindo Raudenbush e Bryk (2002), os modelos são estimados em degraus aninhados: M0 (nulo: só o intercepto aleatório, que dá o ICC); M1 (+ capital humano e demografia); M2 (+ contexto do bairro, nível 2); M3 (+ efeitos fixos de UF) — o modelo principal, que produz o **gap líquido**; e M4 (+ vínculo e grupo ocupacional), reportado como *limite inferior* porque ocupação e formalidade são desfechos da própria discriminação (*bad controls*) (ANGRIST; PISCHKE, 2009). Cada degrau é comparado ao anterior por teste de razão de verossimilhança (LR), e a redução de  $\tau_{\text{UPA}}^2$  em relação ao M0 mede a variância entre bairros explicada pelos controles. Testa-se ainda uma *inclinação aleatória* de **negro** por UPA (M3 +  $u_{1j}\text{Negro}_{ij}$ , com covariância não estruturada) — a penalidade racial varia entre bairros? — por LR com dois graus de liberdade. Todos os modelos são estimados por máxima verossimilhança (ML), necessária para comparar efeitos fixos entre degraus; com  $N = 7,7$  milhões, REML e ML produzem os mesmos componentes de variância (no M0,  $\hat{\tau}_{\text{UPA}}^2 = 0,30182$  por ML e 0,30182 por REML; ICC idêntico até a quarta casa).

### 3.3 Decomposição de Oaxaca–Blinder

Estimam-se equações de rendimento separadas para brancos e negros e decompõem-se a diferença de médias na forma *twofold* de Blinder (1973) e Oaxaca (1973), tomando a estrutura de preços dos brancos como referência não discriminatória, conforme a eq. (3):

$$\ln \bar{W}_B - \ln \bar{W}_N = (\bar{X}_B - \bar{X}_N)' \hat{\beta}_B + \bar{X}_N' (\hat{\beta}_B - \hat{\beta}_N) \quad (3)$$

em que o primeiro termo é a parcela de dotações e o segundo, a de retornos. Duas especificações são reportadas: (A) capital humano, jornada, área urbana, contexto de bairro e efeitos fixos de UF — os controles do HLM M3 —, comparável à literatura; e (B) acrescentando formalidade e grupo ocupacional como dotações (os controles do M4). Como adverte Oaxaca e Ransom (1999), a especificação (B) subestima a discriminação total, porque a segregação ocupacional é ela própria seu produto — por isso ela é lida como limite inferior, e não como a estimativa preferida. Os erros-padrão vêm de bootstrap em

blocos de UPA, e não da fórmula analítica, que pressupõe independência entre observações (CAMERON; GELBACH; MILLER, 2008).

### 3.4 Regressão quantílica e decomposição RIF

A regressão quantílica (KOENKER; BASSETT, 1978) estima  $\hat{\beta}(\tau)$  em seis pontos da distribuição condicional ( $\tau \in \{0,10; 0,25; 0,50; 0,75; 0,90; 0,95\}$ ), permitindo testar se a penalidade racial é constante ao longo da distribuição. O teste de igualdade compara  $\tau = 0,90$  e  $\tau = 0,10$  — os mesmos extremos da decomposição RIF —; o  $\tau = 0,95$  é apenas descritivo. Ele usa bootstrap *m-out-of-n* em blocos de UPA, com reescala  $\sqrt{m/G}$  (BICKEL; SAKOV, 2008) — necessária porque reamostrar todas as 41.459 UPAs a cada réplica seria proibitivo com 7,7 milhões de observações. Complementarmente, a decomposição RIF (FIRPO; FORTIN; LEMIEUX, 2018) é aplicada aos quantis incondicionais da distribuição de renda, separando dotações e retornos em cada ponto.

### 3.5 Modelo logístico multinível de acesso

A barreira de entrada é modelada por um GLMM logístico com intercepto aleatório de UPA, estimado por `lme4::glmer` em R, para três desfechos binários: ocupar cargo qualificado (grupos CBO 1–4), estar no quintil superior e estar no decil superior da renda. A estrutura multinível é a mesma do HLM (RAUDENBUSH; BRYK, 2002), agora com função de ligação logit; o ICC do nível de bairro é calculado por  $\tau^2/(\tau^2 + \pi^2/3)$ , a formulação de variância latente apropriada ao modelo logístico. Além da razão de chances, reporta-se o efeito marginal médio em pontos percentuais, porque a razão de chances não é interpretável como diferença de probabilidade.

### 3.6 Sensibilidade a variáveis omitidas

A hipótese de seleção em observáveis não é testável, mas é possível quantificar quanto de confundimento não observado seria necessário para anular os resultados. Reportam-se duas medidas: o *E-value* (VANDERWEELE; DING, 2017), que é a associação mínima — em razão de chances — que um confundidor precisaria ter simultaneamente com a raça e com o desfecho para explicar o efeito observado; e o índice de Frank et al. (2013), que expressa a fração da estimativa que precisaria ser viés para invalidar a inferência.

### 3.7 Inferência: erros-padrão agrupados, poucos clusters e pesos

A PNAD Contínua é uma amostra por conglomerados: pessoas da mesma unidade primária de amostragem (UPA, proxy de bairro) compartilham choques não observados, e os regressores de contexto variam apenas no nível da UPA. Tratar as 7,7 milhões

de observações como independentes subestima os erros-padrão pelo fator de Moulton  $\sqrt{1 + (\bar{n} - 1)\rho}$  (ANGRIST; PISCHKE, 2009). Por isso, todos os modelos de regressão (OLS com efeitos fixos de UF, decomposição de Oaxaca–Blinder, regressão quantílica e logit) reportam erros-padrão *agrupados por UPA* (41.459 clusters) — para a OB e a regressão quantílica, por bootstrap em blocos de UPA. O agrupamento por UF é mais conservador, mas com 27 clusters ( $< 42$ ) a inferência assintótica é pouco confiável (ANGRIST; PISCHKE, 2009); quando reportado, usa a distribuição  $t$  com  $G - 1$  graus de liberdade. No HLM, o intercepto aleatório de UPA modela explicitamente a correlação intra-bairro, de modo que o erro-padrão do modelo já a incorpora (sob a hipótese de efeitos aleatórios); como contraprova, os coeficientes do HLM são comparados aos do OLS com efeitos fixos de UF e erro-padrão agrupado por UPA, que coincidem em sinal, magnitude e significância. No OLS com efeitos fixos de UF (especificação do M3), o erro-padrão de  $\hat{\beta}_{\text{negro}}$  passa de 0,0005 (convencional) para 0,0009 (agrupado por UPA) e 0,0033 (agrupado por UF); para o regressor de contexto  $\overline{\% \text{Negro}}_{\text{UPA}}$ , que varia apenas no nível da UPA, a razão é de  $4,1 \times$  (UPA) e  $20,1 \times$  (UF) — a assinatura do efeito Moulton. Como  $|\hat{\beta}_{\text{negro}}|/\text{SE}$  permanece acima de 19 mesmo no agrupamento mais conservador, nenhuma conclusão sobre o gap racial depende da escolha do erro-padrão; a correção importa para os coeficientes contextuais e para as variáveis de UF.

**Pesos amostrais.** Os modelos são estimados sem o peso amostral da PNAD (V1028), isto é, descrevem a regressão na amostra, não a regressão populacional (ANGRIST; PISCHKE, 2009). Como robustez, o M3 foi reestimado por mínimos quadrados ponderados com V1028 e erro-padrão agrupado por UPA:  $\hat{\beta}_{\text{negro}}$  passa de -0,0630 (MQO equivalente, sem pesos) para -0,0575 (gap de 6,1% para 5,6%), diferença sem relevância econômica; os demais resultados são não ponderados.

**O conjunto das verificações.** A Tabela 2 reúne os diagnósticos aplicados ao longo do trabalho, o resultado de cada um e a providência que ele motivou.

**Tabela 2:** Testes de robustez e diagnóstico. Cada linha traz o que foi verificado, o resultado e a providência tomada. Valores extraídos dos mesmos csv que alimentam as demais tabelas.

| Verificação                                                | Resultado                                                                                                                           | Providência                                                                    |
|------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------|
| Heterocedasticidade (Breusch-Pagan)                        | $R^2$ da regressão auxiliar: 0,066 e 0,067                                                                                          | erro-padrão agrupado por UPA e bootstrap em blocos                             |
| Forma funcional (RE-SET)                                   | ganho de $R^2$ com potências do predito: 0,0020 a 0,0060                                                                            | rejeição sem relevância prática; forma mantida                                 |
| Multicolinearidade (VIF)                                   | VIF de <b>negro</b> = 1,36; nenhum preditor acima de 10                                                                             | sem colinearidade relevante; o coeficiente de interesse não é afetado          |
| Estrutura multinível (teste de razão de verossimilhança)   | ICC da UPA no modelo nulo = 0,353                                                                                                   | nível de bairro justificado (limiar de 5%)                                     |
| Método de estimação (ML vs. REML)                          | $\hat{\tau}^2$ da UPA: 0,30182 (ML) e 0,30182 (REML)                                                                                | coincidem com $N$ de milhões; ML usado para os testes aninhados                |
| Confundidor não observado (Konfound/ITCV)                  | 98,4% das estimativas teriam de ser viés para anular o achado                                                                       | achado robusto a confundimento plausível                                       |
| Confundidor não observado (E-value)                        | E-value entre 1,46 e 2,36                                                                                                           | um confundidor precisaria dessa força com raça e desfecho                      |
| Sobreajuste (treino vs. teste)                             | maior diferença de $R^2$ : 0,0084                                                                                                   | partição 80/20 e validação cruzada $k$ -fold                                   |
| Ganho do ML sobre o linear                                 | $R^2$ de teste: MQO 0,587; RF 0,589; XGBoost 0,644                                                                                  | mesmo treino e teste: o RF empata com o linear (+0,002); o XGBoost ganha 0,058 |
| Peso amostral (V1028) no acesso, no topo e na decomposição | OR do acesso 0,820 $\rightarrow$ 0,808; topo 10% 0,758 $\rightarrow$ 0,777; preço da Oaxaca (A, com peso) 17,9% $\rightarrow$ 15,3% | logit com efeito fixo de estado e erro agrupado por UPA; conclusão inalterada  |
| Validação cruzada ( $k = 5$ )                              | $R^2$ médio entre <i>folds</i> : 0,6435                                                                                             | hiperparâmetros escolhidos em partição de validação e confirmados por CV       |
| Balanceamento e suporte comum                              | maior diferença padronizada entre grupos: 1,17                                                                                      | desequilíbrio concentrado no contexto de bairro, absorvido pelo nível 2        |
| Especificação do nível de estado                           | coeficiente racial com UF aleatória: -0,0629                                                                                        | igual ao da UF como efeito fixo; resultado não depende da escolha              |
| Vazamento das médias de contexto                           | médias do bairro e do estado calculadas sem a própria observação                                                                    | evita que a raça do indivíduo entre no regressor que o descreve                |
| Dependência intragrupo (Moulton)                           | regressores que variam no nível da UPA                                                                                              | erro-padrão agrupado por UPA em todos os modelos                               |

Fonte: Resultados originais da pesquisa.



### 3.8 Random Forest, XGBoost e SHAP Values

Para predição do log-rendimento, foram ajustados dois modelos de ensemble: (i) *Random Forest* (BREIMAN, 2001) com 200 árvores, profundidade máxima 10, ao menos 50 observações por folha e todas as variáveis candidatas em cada divisão (`max_features` padrão do *scikit-learn* para regressão); e (ii) *XGBoost* (CHEN; GUESTRIN, 2016) com 300 iterações, taxa de aprendizado 0,05, profundidade máxima 10 e regularização  $L_1/L_2$ . A profundidade foi escolhida por validação cruzada (Tabela 7), e não por conveniência; os dois modelos usam o mesmo conjunto de *features* e a mesma partição de teste. Sobre o modelo XGBoost, foi aplicado o *TreeExplainer* da biblioteca SHAP (LUNDBERG; LEE, 2017) para calcular os valores de Shapley de cada variável. Os modelos são ajustados e avaliados na população completa; só o cálculo dos valores SHAP usa uma amostra de 50 mil observações sorteadas do conjunto de treino, com semente fixa, porque o custo do *TreeExplainer* cresce com o número de casos explicados.

## 4 Resultados

As evidências deste capítulo estão organizadas em duas camadas de exclusão — duas barreiras que operam em sequência e se reforçam mutuamente. O leitor não encontrará aqui um catálogo de modelos estatísticos: encontrará a trajetória de um trabalhador negro no mercado de trabalho brasileiro, documentada com rigor empírico em cada etapa.

**Tabela 3:** Mapa das duas camadas de exclusão racial — guia de leitura

| Camada                                                  | Pergunta central e evidência                                                                                                                                                                                |
|---------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>BARREIRA I</b><br><b>Acesso e Segregação</b>         | Por que negros raramente chegam às ocupações de prestígio? O GLMM de acesso e o HLM contextual mostram que a exclusão começa antes do salário.                                                              |
| <b>BARREIRA II</b><br><b>Penalidade e Teto de Vidro</b> | Para os que superam a barreira de entrada — qual é o custo de ser negro? Gap líquido de 6,1% (M3) e de 5,6% dentro da mesma ocupação (M4), crescendo nos quantis mais altos ( $Z = -25,87$ , $p < 0,001$ ). |

Cada seção a seguir documenta empiricamente uma dessas camadas. Nenhum método isolado teria identificado o sistema como um todo.

---

### BARREIRA I — ACESSO E SEGREGAÇÃO ESTRUTURAL

*Como a exclusão começa antes do primeiro salário*

---

## 4.1 Modelos Hierárquicos Lineares — Mediação Contextual do Gap

Quanto do gap racial sobrevive à comparação entre dois trabalhadores que moram no mesmo bairro? A pergunta separa duas histórias muito diferentes. Se quase nada sobrevive, o diferencial de renda é sobretudo consequência de onde negros e brancos conseguem morar. Se quase tudo sobrevive, o bairro é cenário, e a diferença se produz pessoa a pessoa, dentro da mesma rua. A Tabela 5 responde em cinco degraus, do modelo nulo (M0) ao modelo com ocupação (M4), todos com intercepto aleatório por UPA e estimados por máxima verossimilhança sobre a população completa: acompanhe a linha **Raça (negro)** da esquerda para a direita e veja o coeficiente aproximar-se de zero à medida que cada degrau acrescenta um bloco de controles.

### Mais de um terço da diferença de renda está entre bairros, não dentro deles.

Antes de qualquer controle, o modelo nulo reparte a variação do log-rendimento em duas parcelas: a que separa um bairro de outro e a que separa dois vizinhos. O ICC da UPA é de 0,353<sup>1</sup> — isto é, **35,3% da variância do log-rendimento está entre bairros**. Em linguagem de leitor: de toda a diferença de renda entre duas pessoas sorteadas ao acaso no país, mais de um terço já está associada a morarem em bairros diferentes, antes de se saber qualquer outra coisa sobre elas. É muito acima do limiar de 5% a partir do qual Raudenbush e Bryk (2002) consideram indispensável tratar a estrutura aninhada, e maior do que a parcela entre estados (cerca de 11%, no modelo alternativo com UF aleatória usado como robustez). Ignorar essa estrutura trataria como independentes pessoas que compartilham o mesmo mercado de trabalho local.

**Comparar vizinhos reduz o gap em cerca de 40%.** Com escolaridade, idade, sexo, horas, situação urbana e ano, mas *sem* nenhum efeito de bairro (OLS com efeitos fixos de UF, Subseção 3.7), trabalhadores negros recebem **10,5% a menos** que brancos comparáveis ( $\hat{\beta} = -0,1104$ ). O M1 acrescenta o intercepto aleatório de UPA — na prática, um nível de renda próprio para cada bairro — e com ele a comparação deixa de ser entre todos os trabalhadores do país e passa a ser entre negros e brancos *do mesmo bairro*: a penalidade cai para **6,5%**<sup>2</sup>. Medida na régua do gap agregado, **39,5% da distância já foi percorrida** — percorrida no sentido de atribuída a um fator observável, e não no sentido de explicada sem discriminação, já que o bairro em que se consegue morar é ele próprio produto de exclusão. Esse é o teste da Hipótese H1, e ele passa: negros e brancos com o mesmo capital humano não moram nos mesmos bairros, e os bairros pagam diferente. Os controles individuais explicam, além disso, 66,5% da variância entre bairros

---

<sup>1</sup> $\hat{\tau}_{\text{UPA}}^2 = 0,3018$  (variância entre bairros) e  $\hat{\sigma}^2 = 0,5524$  (variância entre pessoas do mesmo bairro), com  $\text{ICC} = \hat{\tau}^2 / (\hat{\tau}^2 + \hat{\sigma}^2)$ .

<sup>2</sup> $\hat{\beta}_{\text{negro}}^{M1} = -0,0669$ , IC 95%:  $[-0,0679; -0,0658]$ .

do M0 — parte do que parecia “bairro” é composição de quem mora nele.

Vale guardar a frase: 39,5% do gap racial não separam duas pessoas, separam dois endereços. Resta saber o que, num endereço, produz essa diferença.

**Morar onde moram os negros custa outra vez.** O M2 pergunta o que, num bairro, faz a renda ser mais alta ou mais baixa, e responde com três covariáveis de nível 2 que juntas explicam 55,2% da variância entre bairros que restava no M1<sup>3</sup>. A mais eloquente é a composição racial:  $\hat{\gamma}_{01} = -0,1272$  significa que um desvio-padrão a mais na proporção de moradores negros da UPA reduz o rendimento de *todos* os moradores, negros e brancos, em 0,13 log-pontos — cerca de 2,0 vezes a penalidade que um trabalhador negro carrega individualmente no mesmo modelo. É a evidência mais direta da *dupla desvantagem*: ser negro custa, e morar onde moram os negros custa outra vez, inclusive para quem não é negro. Já o coeficiente individual mal se move (de -0,0669 para -0,0637): acrescentar a composição do bairro quase não altera a penalidade racial média — as duas desvantagens se somam, em vez de uma explicar a outra.

Em uma frase: o bairro cobra duas vezes — da pessoa negra, pela cor; e de todos os que moram ali, pela composição racial do lugar.

**Acrescentar o estado não move a régua.** Com os efeitos fixos de UF, a penalidade é de **6,1%** ( $\hat{\beta}_{\text{negro}}^{M3} = -0,0629$ ). Na régua do gap agregado, 43,0% — praticamente os mesmos 39,5% do M1. O dado relevante aqui é o que *não* aconteceu: depois que a comparação já é entre vizinhos, o contexto do bairro (M2) e a unidade da federação (M3) retiram pouco mais do diferencial. É esse patamar que este trabalho chama de **gap líquido**: o que capital humano, contexto de bairro e estado não explicam — um limite superior da penalidade direta sob seleção em observáveis (o M4 é o inferior), e não uma medida de discriminação.<sup>4</sup>

**Bairro ou estado? A separação em três camadas.** Uma objeção natural: se bairros pobres se concentram em estados pobres, o que este trabalho chama de efeito do bairro pode ser efeito da região. O modelo de dois níveis não separa as duas coisas — ele trata a UF como efeito fixo, e por isso credita ao bairro tudo o que é territorial. Para medir a separação, o modelo nulo foi reestimado com **três** níveis: pessoa dentro de bairro dentro de estado, com intercepto aleatório nos dois.

O resultado divide o território em duas partes desiguais. Dos 35,3% que o modelo de dois níveis atribui ao bairro, **23,4%** permanecem entre bairros do *mesmo* estado e **11,4%** são diferenças entre estados. Depois dos controles individuais e do contexto do

---

<sup>3</sup> $\hat{\tau}^2$  cai de 0,1012 para 0,0454; LR = 29.811, 3 g.l.,  $p < 0,001$ .

<sup>4</sup>IC 95% de  $\hat{\beta}_{\text{negro}}^{M3}$ : [-0,0639; -0,0619]. O ICC cai para 0,076 e os controles acumulados explicam 90,1% da variância entre bairros do M0; a escada completa está nas linhas inferiores da Tabela 5.

bairro, o bairro cai para 7,2% e o estado para 5,6%: a camada do bairro encolhe mais (de 2,1 para 1,3 vez o estado), mas continua sendo a maior.<sup>5</sup>

**Dentro da mesma ocupação o gap encolhe — o que não é o mesmo que explicá-lo.** O M4 acrescenta vínculo e grupo ocupacional, e a penalidade cai para **5,6%** ( $\hat{\beta}_{\text{negro}}^{M4} = -0,0579$ ). A régua vai a **47,6% do gap agregado**. A tentação é ler esse número como a parte do gap que está “explicada”, e é precisamente essa leitura que o desenho do estudo não autoriza: a ocupação não é uma característica que a pessoa traz consigo, é um resultado ao qual ela precisou obter acesso — e o acesso é justamente onde a Subseção 4.6 encontra uma barreira própria, que a decomposição salarial só capta em parte. Controlar por ocupação é, portanto, descontar do gap uma parte do próprio gap. Por isso o M4 é um limite inferior descritivo, e não o número a citar como a penalidade racial brasileira.

**O mesmo controle pode ser legítimo num modelo e viciado noutro.** A regra não é “controlar por tudo” nem “nunca controlar por resultado”: depende do que se está explicando. A jornada trabalhada ilustra bem. No modelo de rendimento ela é *necessária*, porque o desfecho é o rendimento **mensal**: sem ela, comparar-se-ia quem trabalha meio período com quem trabalha jornada integral e a diferença seria creditada à raça. No modelo de acesso o desfecho é *ocupar* o cargo, e a jornada não causa esse acesso — ela é determinada junto com a ocupação, de modo que condicionar nela desconta parte do próprio fenômeno. Por isso a jornada entra no bloco individual do modelo de rendimento e, no de acesso, só no degrau rotulado como limite inferior, ao lado do vínculo.

O critério que organiza os dois modelos é, então, o *estatuto causal* de cada variável em relação ao desfecho daquele modelo, e não a semelhança das listas (Tabela 4):

Dito de outro modo: 5,6% é onde a régua termina, não onde o gap verdadeiro está. O número deste trabalho é o gap líquido de 6,1% do M3; o 5,6% mede o que sobra depois de descontar um canal que é ele próprio discriminatório.

**A penalidade não é a mesma em todo bairro.** Até aqui a penalidade racial foi tratada como um número único. Deixá-la variar de bairro para bairro melhora significativamente o ajuste (LR = 26.267, 2 g.l.,  $p < 0,001$ ), e o desvio-padrão dessa variação é de 0,145 log-pontos<sup>6</sup>. Em bairros a um desvio-padrão de cada lado da média, a penalidade vai de -0,211 a 0,079 log-pontos: há bairros em que o diferencial é mais do que o dobro da média e bairros em que ele se inverte. A discriminação salarial tem geografia — e a covariância entre intercepto e inclinação (-0,0157) indica que a penalidade é maior nos

---

<sup>5</sup>Estimado com `lme4` sobre a mesma população. A especificação do trabalho continua sendo a de dois níveis: 27 estados são poucos para estimar uma variância com precisão, e o efeito fixo absorve o contexto estadual sem hipótese distribucional. O ponto desta checagem é outro: o coeficiente racial não depende dessa escolha — vale -0,0629 com a UF como efeito fixo e -0,0629 com a UF como nível aleatório.


<sup>6</sup> $\hat{\tau}_1^2 = 0,0210$ , componente de variância da inclinação aleatória de **negro** por UPA.

**Tabela 4:** Simetria dos controles entre os dois modelos. Os blocos predeterminados são idênticos; o que difere é o tratamento das variáveis que são elas próprias desfecho do processo estudado.

| Bloco              | Modelo de rendimento (HLM)                                                                       | Modelo de acesso (GLMM)                                               |
|--------------------|--------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------|
| Predeterminados    | sexo, idade, idade <sup>2</sup> , escolaridade (4 degraus cumulativos), área urbana, ano, estado | os mesmos                                                             |
| Contexto do bairro | % negro, desemprego e escolaridade média da UPA                                                  | os mesmos                                                             |
| Jornada            | controle necessário: o desfecho é rendimento mensal                                              | desfecho do processo: entra só no degrau de limite inferior           |
| Vínculo e ocupação | limite inferior (M4)                                                                             | limite inferior (A3); a ocupação não entra, pois é o próprio desfecho |

Fonte: Resultados originais da pesquisa.


bairros de renda-base mais alta. A Figura 1 contrasta os efeitos fixos de estado com os interceptos estimados para os bairros, e a Figura 2 mostra a reta de cada bairro.



**Figura 1:** A variação entre bairros supera a variação entre estados. À esquerda, os efeitos fixos de UF do M3 com IC 95% (referência: primeira UF); à direita, a distribuição dos interceptos aleatórios das UPAs ( $u_{0j}$ , BLUPs do M3).

*Como ler a Figura 1:* cada ponto à esquerda é um estado; a largura do histograma à direita é o quanto a renda-base muda de um bairro para outro, já descontados capital humano, contexto e estado.


*Como ler a Figura 2:* à esquerda, a altura de cada reta é a renda-base do bairro e a inclinação é a penalidade racial dentro dele — retas que descem mais são bairros que penalizam mais. À direita, cada ponto é um bairro, e a reta azul resume a relação: se ela desce, bairros de renda-base maior têm inclinação mais negativa, isto é, penalizam mais.



**Figura 2:** Nos bairros de renda mais alta, a penalidade racial é maior. M3 com intercepto e inclinação de **negro** aleatórios por UPA: à esquerda, a reta ajustada de cada bairro (amostra de 250 UPAs com brancos e negros) e, em azul, a média; à direita, os BLUPs  $u_{0j}$  e  $u_{1j}$  das 40.728 UPAs, com correlação estimada de  $-0,53$ .

**A penalidade ao longo da escada educacional.** O M3 impõe uma única penalidade racial a todos os níveis de escolaridade. Reestimado com o coeficiente de raça livre em cada nível — mesma especificação, mesma população —, ele mostra que a penalidade condicional diminui da base para o topo da escada: 9,6% entre quem está sem fundamental completo e 1,1% entre quem está com pós-graduação. O teste de razão de verossimilhança contra o M3, que impõe uma penalidade única, rejeita a igualdade entre os níveis (LR = 3319, 4 g.l.,  $p < 0,001$ ). Sem controles, o gap mediano é de 14,1% sem fundamental completo e de 26,1% com pós-graduação; a diferença entre o bruto e o condicional, em cada nível, é o que idade, sexo, jornada, bairro e estado explicam ali. A composição também difere: os negros são 67% de quem está sem fundamental completo e 37% de quem está com pós-graduação. Como no restante do trabalho, são diferenças condicionais entre pessoas comparáveis, não o efeito de estudar mais. *Como ler a Figura 3:* cada reta é um nível de escolaridade e vai do trabalhador branco (à esquerda) ao negro (à direita). A altura da reta é o rendimento do nível em relação ao branco sem fundamental completo; a inclinação é a penalidade racial dentro do nível, escrita à direita.

**O gap verdadeiro está entre dois limites, e nenhum confundidor plausível o anula.** O coeficiente racial é uma associação condicional: pela fórmula do viés de variável omitida (ANGRIST; PISCHKE, 2009), o coeficiente “curto” iguala o “longo” mais o efeito do omitido vezes sua relação com a raça. Qualidade da escola, habilidade não observada e redes de contato correlacionam-se negativamente com ser negro e positivamente com a renda: omiti-las *superestima* a penalidade — o que faz do M3 um limite superior para o efeito de tratamento diferencial condicional a essas características. Na direção oposta, os controles que são desfechos (ocupação no M4) *subestimam*. O gap líquido deve ser lido



**Figura 3:** Retorno de cada nível de escolaridade e penalidade racial dentro dele: M3 do núcleo com o coeficiente de raça estimado em cada nível.

entre esses dois limites. Para anular  $\hat{\beta}_{\text{negro}}^{M3}$  seria preciso um viés de 98,4% do coeficiente, pelo Konfound (FRANK et al., 2013), e o E-value do modelo de acesso (Tabela 14) exige um confundidor associado à raça e ao desfecho com razão de risco  $\geq 1,5$  — uma associação modesta, que sozinha não descarta viés.

**Tabela 5:** HLM de dois níveis (indivíduo em UPA) com efeitos fixos de UF — estratégia *step-up*, PNAD Contínua 2016–2025, população completa ( $N = 7.694.080$ ; 40.728 UPAs; 27 UFs). Coeficientes com erro-padrão do modelo entre parênteses (a correlação intra-UPA já está no efeito aleatório). Estimacão por máxima verossimilhança (ML), para os testes LR entre degraus; REML coincide. Com  $N$  desta ordem quase todo coeficiente é significante; a inferência relevante está nos intervalos de confiança, não nos asteriscos (ANGRIST; PISCHKE, 2009, cap. 8).

| Variável                                           | M0              | M1                 | M2                 | M3                 | M4                 |
|----------------------------------------------------|-----------------|--------------------|--------------------|--------------------|--------------------|
| Intercepto                                         | 7,5778 (0,0028) | 4,8436 (0,0039)    | 5,0132 (0,0034)    | 5,2269 (0,0078)    | 5,4140 (0,0074)    |
| <b>Raça (negro)</b>                                | —               | −0,0669 (0,0005)   | −0,0637 (0,0005)   | −0,0629 (0,0005)   | −0,0579 (0,0005)   |
| Sexo feminino                                      | —               | −0,2594 (0,0005)   | −0,2590 (0,0005)   | −0,2592 (0,0005)   | −0,2394 (0,0005)   |
| Idade (centrada)                                   | —               | 0,0079 (<0,0001)   | 0,0078 (<0,0001)   | 0,0078 (<0,0001)   | 0,0088 (<0,0001)   |
| Idade <sup>2</sup>                                 | —               | −0,0004 (<0,0001)  | −0,0004 (<0,0001)  | −0,0004 (<0,0001)  | −0,0004 (<0,0001)  |
| <i>Escolaridade (ref.: fundamental incompleto)</i> |                 |                    |                    |                    |                    |
| Educ.: fundamental completo                        | —               | 0,1884 (0,0007)    | 0,1880 (0,0007)    | 0,1877 (0,0007)    | 0,1464 (0,0007)    |
| Educ.: médio completo                              | —               | 0,1965 (0,0007)    | 0,1956 (0,0007)    | 0,1958 (0,0007)    | 0,1013 (0,0007)    |
| Educ.: superior completo                           | —               | 0,5133 (0,0007)    | 0,5107 (0,0007)    | 0,5112 (0,0007)    | 0,2937 (0,0008)    |
| Educ.: pós-graduação                               | —               | 0,3359 (0,0011)    | 0,3341 (0,0011)    | 0,3350 (0,0011)    | 0,2445 (0,0011)    |
| <i>Inserção</i>                                    |                 |                    |                    |                    |                    |
| log(horas)                                         | —               | 0,6536 (0,0006)    | 0,6539 (0,0006)    | 0,6534 (0,0006)    | 0,5801 (0,0006)    |
| Urbano                                             | —               | 0,3419 (0,0037)    | 0,0927 (0,0032)    | 0,0492 (0,0027)    | 0,0071 (0,0025)    |
| <i>Contexto de bairro — nível 2 (UPA)</i>          |                 |                    |                    |                    |                    |
| % negro na UPA ( $z$ )                             | —               | —                  | −0,1272 (0,0013)   | −0,0528 (0,0018)   | −0,0576 (0,0017)   |
| Desemprego na UPA ( $z$ )                          | —               | —                  | −0,0183 (0,0012)   | −0,0007 (0,0010)   | −0,0051 (0,0010)   |
| Educ. média na UPA ( $z$ )                         | —               | —                  | 0,1577 (0,0014)    | 0,1694 (0,0013)    | 0,1427 (0,0012)    |
| <i>Ocupação e vínculo (M4; bad controls)</i>       |                 |                    |                    |                    |                    |
| Emprego formal                                     | —               | —                  | —                  | —                  | 0,1585 (0,0006)    |
| Conta própria                                      | —               | —                  | —                  | —                  | −0,1658 (0,0006)   |
| Trab. doméstico                                    | —               | —                  | —                  | —                  | −0,1052 (0,0010)   |
| CBO: dirigente                                     | —               | —                  | —                  | —                  | 0,6250 (0,0013)    |
| CBO: profissional                                  | —               | —                  | —                  | —                  | 0,5608 (0,0011)    |
| CBO: técnico                                       | —               | —                  | —                  | —                  | 0,4001 (0,0010)    |
| CBO: administrativo                                | —               | —                  | —                  | —                  | 0,1771 (0,0010)    |
| CBO: serviços                                      | —               | —                  | —                  | —                  | 0,1517 (0,0007)    |
| CBO: agropecuária                                  | —               | —                  | —                  | —                  | 0,0844 (0,0010)    |
| CBO: operário                                      | —               | —                  | —                  | —                  | 0,1839 (0,0008)    |
| CBO: operador                                      | —               | —                  | —                  | —                  | 0,2152 (0,0009)    |
| CBO: FFAA                                          | —               | —                  | —                  | —                  | 0,7871 (0,0023)    |
| IC 95% de $\beta_{\text{negro}}$                   | —               | [−0,0679; −0,0658] | [−0,0647; −0,0627] | [−0,0639; −0,0619] | [−0,0588; −0,0569] |
| Gap (%) = $e^{\beta} - 1$                          | —               | −6,5               | −6,2               | −6,1               | −5,6               |
| Efeitos fixos de UF                                | não             | não                | não                | sim                | sim                |
| <i>Componentes de variância e ajuste</i>           |                 |                    |                    |                    |                    |
| $\hat{\sigma}_{\text{UPA}}^2$ (nível 2)            | 0,3018          | 0,1012             | 0,0454             | 0,0297             | 0,0263             |
| $\hat{\sigma}^2$ (nível 1)                         | 0,5524          | 0,3619             | 0,3619             | 0,3620             | 0,3237             |
| ICC <sub>UPA</sub>                                 | 0,353           | 0,219              | 0,111              | 0,076              | 0,075              |
| $\tau^2$ explicada vs. M0 (%)                      | —               | 66,5               | 85,0               | 90,1               | 91,3               |
| −2 LL (deviance)                                   | 17.439.754      | 14.160.374         | 14.130.562         | 14.115.850         | 13.255.146         |
| AIC                                                | 17.439.760      | 14.160.418         | 14.130.612         | 14.115.952         | 13.255.272         |
| BIC                                                | 17.439.802      | 14.160.722         | 14.130.959         | 14.116.659         | 13.256.145         |
| LR vs. degrau anterior ( $\chi^2$ , g.l.)          | —               | 3.279.380 (19)     | 29.811 (3)         | 14.712 (26)        | 860.704 (12)       |
| $p$ do LR                                          | —               | < 0,001            | < 0,001            | < 0,001            | < 0,001            |

*Inclinação aleatória de negro por UPA ( $M3 + u_{1j}$ ):  $\hat{\tau}_1^2 = 0,0210$  (DP = 0,145 em log-pontos),  $\text{cov}(u_0, u_1) = -0,0157$ ; LR = 26.267 (2 g.l.),  $p < 0,001$ : a penalidade racial varia entre bairros;  $\hat{\beta}_{\text{negro}}$  médio = −0,0659.*



## 4.2 Modelos de Machine Learning e SHAP Values

Todos os modelos até aqui impuseram uma forma à realidade: rendimento linear nos controles, efeitos que se somam, penalidade racial constante. E se a forma estiver errada — se o gap que os coeficientes mostram for, em alguma medida, artefato da equação escolhida? Árvores de decisão respondem a essa objeção porque não pressupõem forma nenhuma: descobrem sozinhas interações e não linearidades e, com os valores SHAP, dizem quanto cada variável pesou em cada previsão. Se a raça aparecer entre os preditores relevantes de um modelo que nunca foi instruído a procurá-la, o achado deixa de depender da especificação. A Tabela 6 traz o desempenho dos modelos sobre o conjunto de teste, separado antes de qualquer ajuste.

**Tabela 6:** Desempenho preditivo — Random Forest, XGBoost e XGBoost sem renda de vizinhança (robustez ao problema do reflexo). *Hold-out* 20% da população ( $N_{\text{teste}} \approx 1,54$  milhão).

| Modelo                     | $R^2$         | MAE           | RMSE          | Gap treino–teste |
|----------------------------|---------------|---------------|---------------|------------------|
| Random Forest              | 0,5891        | 0,4288        | 0,5753        | 0,0003           |
| <b>XGBoost</b>             | <b>0,6444</b> | <b>0,3970</b> | <b>0,5352</b> | <b>0,0084</b>    |
| XGBoost (sem renda da UPA) | 0,6321        | 0,4040        | 0,5443        | 0,0081           |

Como ler a Tabela 6:  $R^2$  mais alto = melhor previsão; o *gap* treino–teste próximo de zero indica ausência de sobreajuste.

O  $R^2$  de teste de 0,64 (XGBoost) é elevado para dados de rendimento individual, onde a variância não observada (setor, cargo, tempo de serviço) responde pela maior parte do resíduo.

**Escolha de hiperparâmetros e validação cruzada.** A profundidade das árvores, a taxa de aprendizado e o número de iterações não foram fixados por conveniência: seis configurações foram comparadas numa partição de validação *dentro* do conjunto de treino — o teste permanece intocado —, e a vencedora foi submetida a validação cruzada *k-fold* ( $k = 5$ ) no treino completo (Tabelas 7 e 8). A configuração escolhida melhora o  $R^2$  em relação à configuração de referência (profundidade 6), com sobreajuste maior, mas ainda desprezível (Tabelas 7 e 8).<sup>7</sup> Com um treino desse tamanho, a variação entre *folds* cai na quarta casa decimal: aqui a validação cruzada serve menos para estimar incerteza e mais para justificar a especificação.

**O erro na unidade original.** Os modelos preveem o *logaritmo* do rendimento; para o leitor, o que importa é o erro em reais. Retransformando com a correção de Duan (1983) (fator de *smearing* = 1,159), o erro mediano de previsão é de **R\$ 664 por mês** (reais

<sup>7</sup>Profundidade 10, com  $R^2 = 0,6435 \pm 0,0006$  entre os *folds*, contra  $0,6294 \pm 0,0006$  da profundidade 6 de referência, sobre 6.159.418 observações de treino.

**Tabela 7:** Escolha de hiperparâmetros do XGBoost na partição de validação (ALENCAR, 2026a; ALENCAR, 2026b; ALENCAR, 2026c; GÉRON, 2021). Seis configurações comparadas *dentro* do treino — o conjunto de teste permanece intocado. População completa: 6.159.418 observações de treino e 1.539.855 de teste; nenhuma amostragem.

| Profundidade | Taxa de aprendizado | Árvores          | $R^2$  | MAE    | Sobreajuste |
|--------------|---------------------|------------------|--------|--------|-------------|
| 10           | 0,05                | 300              | 0,6427 | 0,3977 | 0,0120      |
| 8            | 0,05                | 600              | 0,6395 | 0,3995 | 0,0075      |
| 8            | 0,05                | 300              | 0,6352 | 0,4022 | 0,0046      |
| 6            | 0,10                | 300              | 0,6322 | 0,4041 | 0,0027      |
| 6            | 0,05                | 300 (referência) | 0,6286 | 0,4062 | 0,0019      |
| 4            | 0,05                | 300              | 0,6182 | 0,4128 | 0,0011      |

*Como ler:* “Sobreajuste” é a diferença entre o  $R^2$  de treino e o de validação — valores próximos de zero indicam que o modelo não decorou os dados. A primeira linha é a configuração escolhida.

**Tabela 8:** Validação cruzada  $k$ -fold ( $k = 5$ ) do XGBoost no treino completo, com média e desvio-padrão entre *folds*.

| Configuração                | $R^2$ (média $\pm$ dp) | MAE                 | RMSE                |
|-----------------------------|------------------------|---------------------|---------------------|
| Escolhida (profundidade 10) | 0,6435 $\pm$ 0,0006    | 0,3978 $\pm$ 0,0002 | 0,5360 $\pm$ 0,0002 |
| Referência (profundidade 6) | 0,6294 $\pm$ 0,0006    | 0,4064 $\pm$ 0,0002 | 0,5466 $\pm$ 0,0002 |

*Como ler:* a configuração escolhida ganha 1,4 ponto percentual de  $R^2$  ao custo de um sobreajuste maior, mas ainda pequeno (Tabela 7). No conjunto de teste (intocado durante a escolha),  $R^2 = 0,6444$ .

do 2º trimestre de 2026), ou 35% do rendimento observado — a ordem de grandeza que se deve ter em mente ao ler o  $R^2$ : o modelo acerta a posição relativa das pessoas muito melhor do que o valor exato do salário de cada uma.


**Ampliar a base reduz o risco de sobreajuste, em vez de aumentá-lo.** A objeção usual a modelos flexíveis é que eles decoram os dados em vez de aprender com eles — e quem decorou prevê bem o que já viu e mal o que não viu. Não é o caso aqui, e a razão é o tamanho da base: o  $R^2$  de treino e o de teste praticamente coincidem, com diferença de 0,0084<sup>8</sup>. Três evidências convergem: a diferença entre treino e teste é praticamente nula; o número de observações supera em muitas ordens de grandeza a complexidade dos modelos, todos regularizados; e o  $R^2$  de teste quase não muda ao se passar de uma subamostra para a população inteira. É o contrário da intuição corrente: ampliar a base, de amostral para populacional, reduz o risco de sobreajuste em vez de aumentá-lo.

<sup>8</sup>População completa,  $N = 7.699.273$ , com 80% para treino e 20% para teste; o mesmo *gap* aparece no Random Forest.

**Tabela 9:** Importância SHAP Comparada — Random Forest e XGBoost. Predição de log-rendimento, PNAD 2016–2025 ( $N_{\text{SHAP}} = 50.000$ ). Valores:  $|\text{SHAP}|$  médio.

| Feature                            | $ \text{SHAP} $ RF | Rank RF | $ \text{SHAP} $ XGB | Rank XGB |
|------------------------------------|--------------------|---------|---------------------|----------|
| Renda média UPA (exceto o próprio) | 0,21008            | 2       | 0,18775             | 1        |
| Educ.: superior completo           | 0,24464            | 1       | 0,17823             | 2        |
| Horas trabalhadas                  | 0,19383            | 3       | 0,17220             | 3        |
| Gênero (feminino)                  | 0,11166            | 4       | 0,10557             | 4        |
| Emprego formal (carteira)          | 0,11100            | 5       | 0,10548             | 5        |
| Idade (centrada)                   | 0,05669            | 6       | 0,09059             | 6        |
| Conta própria                      | 0,02228            | 10      | 0,05621             | 7        |
| CBO: Profissionais                 | 0,02371            | 9       | 0,05440             | 8        |
| Educ.: médio completo              | 0,04494            | 7       | 0,04043             | 9        |
| CBO: Técnicos                      | 0,02033            | 11      | 0,03875             | 10       |
| Educ. média Estado                 | 0,00210            | 21      | 0,03339             | 11       |
| CBO: Dirigentes                    | 0,02388            | 8       | 0,03276             | 12       |
| Educ.: fundamental completo        | 0,00738            | 14      | 0,02993             | 13       |
| <b>Raça (negro)</b>                | 0,00222            | 20      | 0,02656             | 14       |
| CBO: Serviços/Vendas               | 0,00197            | 22      | 0,02448             | 15       |
| CBO: Operários                     | 0,00109            | 23      | 0,02231             | 16       |
| CBO: Op. Máquinas                  | 0,00258            | 19      | 0,02144             | 17       |
| Educ. média UPA                    | 0,00033            | 26      | 0,01753             | 18       |
| Educ.: pós-graduação               | 0,01489            | 12      | 0,01690             | 19       |
| Trabalho doméstico                 | 0,00549            | 16      | 0,01658             | 20       |
| <b>Desemprego no Estado</b>        | 0,00038            | 25      | 0,01634             | 21       |
| CBO: Agropecuária                  | 0,00070            | 24      | 0,01471             | 22       |
| <b>% Negro no Estado</b>           | 0,00449            | 17      | 0,01316             | 23       |
| Idade <sup>2</sup> (experiência)   | 0,00657            | 15      | 0,01274             | 24       |
| CBO: Administrativo                | 0,00348            | 18      | 0,01216             | 25       |
| CBO: FFAA/Polícia                  | 0,00803            | 13      | 0,01121             | 26       |
| <b>Desemprego na UPA</b>           | 0,00013            | 28      | 0,00787             | 27       |
| <b>% Negro na UPA</b>              | 0,00023            | 27      | 0,00731             | 28       |

*Como ler a Tabela 9:* variáveis ordenadas pela importância média ( $|\text{SHAP}|$ ); valores maiores = maior peso na previsão da renda.



**Figura 4:** Contexto do bairro, diploma superior e jornada dominam a previsão de renda; a raça aparece na 14ª posição entre 28 preditores (SHAP, XGBoost,  $N_{\text{SHAP}} = 50.000$ ).

Como ler a Figura 4: cada ponto é um trabalhador; quanto mais à direita (ou maior a barra), maior o efeito da variável na renda prevista. A cor indica se o valor da variável é alto ou baixo.

A Tabela 9 mostra o **contexto do bairro** entre os preditores de maior peso do rendimento individual. A variável usada aqui é a renda média da UPA *excluindo o próprio indivíduo* (*leave-one-out*): a média que inclui a própria pessoa é mecanicamente correlacionada com seu rendimento — o problema do reflexo (MANSKI, 1993) — e inflaria artificialmente a importância do território. Mesmo sem essa contaminação, o bairro permanece entre os preditores de primeira ordem, o que é consistente com a hipótese de Wilson (1987); a leitura correta, porém, é de *mediação* territorial — choques comuns ao bairro (mercado de trabalho local, transporte, redes) afetam todos os moradores — e não de efeito causal de um vizinho sobre o outro. Como checagem extrema, o mesmo XGBoost estimado *sem qualquer* renda de vizinhança perde pouco poder preditivo ( $R^2 = 0,632$  contra 0,644 do modelo completo) e, nele, a contribuição média da raça é praticamente a mesma (0,029 contra 0,027 em  $|\text{SHAP}|$ ): o sinal racial não é um artefato da variável de contexto — muda apenas a posição relativa no *ranking*,<sup>9</sup> porque as demais variáveis absorvem parte do que o território explicava.


<sup>9</sup>15ª de 27 variáveis no modelo sem renda de vizinhança, contra 14ª de 28 no modelo completo.

A variável racial ocupa o 14º lugar no ranking de importância mesmo após controlar por todos os demais fatores. A parcela do rendimento predito que o modelo atribui à raça difere em 5,3% entre trabalhadores negros e brancos<sup>10</sup> — o que resta depois de educação, experiência, gênero, contexto de moradia e ocupação. O valor fica a 0,4 ponto percentual do *gap* estimado pelo M4 hierárquico, que usa controles semelhantes (o XGBoost acrescenta a renda média do bairro): um algoritmo que não impõe forma funcional alguma chega perto do modelo linear, sinal de que o achado não depende da especificação de Mincer.

Os dois modelos discordam quanto à raça, e a Tabela 9 mostra a discordância: no Random Forest ela cai para o 20º lugar, com contribuição média próxima de zero, enquanto as demais variáveis têm peso semelhante nos dois. A diferença é de arquitetura, não de dados. Cada árvore da floresta escolhe, em cada nó, a variável de maior ganho entre todas as disponíveis; com a profundidade limitada a dez níveis, uma variável de efeito pequeno perde essa disputa em todos os nós e acaba nunca sendo usada. O *boosting* trabalha em sequência sobre o resíduo: consumidas as variáveis de maior peso nas primeiras iterações, o que sobra passa a ter estrutura racial, e as árvores seguintes chegam a ela. É por isso que a leitura se apoia no XGBoost, que é também o de melhor ajuste — e é uma ilustração do que a literatura de *ensembles* chama de sensibilidade do modelo à forma como o erro é decomposto.

---

<sup>10</sup>Contribuição média da variável racial à previsão, com sinal:  $-0,0241$  log-pontos entre os negros e  $+0,0299$  entre os brancos (XGBoost,  $N_{\text{SHAP}} = 50.000$ ; `shap_negro_por_grupo.csv`). A média de um grupo mede o desvio em relação à previsão média da base, que mistura os dois; o que corresponde ao coeficiente racial das regressões é o contraste entre elas.



**Figura 5:** A mesma variável, sinais opostos: a raça soma à previsão do trabalhador branco e subtrai da do negro. Decomposição SHAP individual (*waterfall*) de dois trabalhadores, cada um no percentil 75 de rendimento do próprio grupo; cada barra é a contribuição de uma variável ao afastamento entre a previsão média da base e a previsão daquele caso, em log-pontos, e as de menor peso estão agrupadas na linha das demais. O painel A é o trabalhador branco, e o B, o negro. Os painéis mostram como o modelo compõe uma previsão: a diferença de rendimento entre os dois é bruta, sem os controles que os modelos aplicam.

Como ler a Figura 5: cada linha é uma variável de **um** trabalhador — não de uma média. A barra mostra quanto aquela variável empurra a previsão para cima ou para baixo, partindo da previsão média da base até a previsão final do caso. Compare a linha *Raça (negro)* nos dois painéis: é a mesma variável, com o sinal trocado — soma no

branco, subtrai no negro. Serve para ver como o modelo compõe uma decisão, não para generalizar: a magnitude média está na Figura 4, sobre os 50 mil casos.

---

## BARREIRA II — PENALIDADE SALARIAL E TETO DE VIDRO

---

*Para quem supera a porta de entrada, qual é o custo de ser negro?*

---

### 4.3 Decomposição do gap por mediação contextual e ocupacional


A Tabela 10 resume o resultado central dos modelos HLM: à medida que se adiciona o bairro (intercepto aleatório e contexto da UPA), o estado e a ocupação, o gap racial encolhe de 10,5% (agregado) para 5,6% (M4); o que resta no M4 é a penalidade que nenhum atributo observável explica.

**Tabela 10:** Decomposição do gap salarial racial por mediação contextual e ocupacional (HLM de dois níveis, indivíduos em UPA, com efeitos fixos de UF; PNAD Contínua 2016–2025, população completa). Cada linha acrescenta um bloco de controles ao anterior; à medida que se adiciona contexto e ocupação, o gap encolhe e a mediação acumulada cresce.

| Modelo (controles acumulados)                         | $\beta_{\text{negro}}$ | Gap (%) | Mediação acum. (%) |
|-------------------------------------------------------|------------------------|---------|--------------------|
| Agregado: individual + UF, sem efeito de bairro (OLS) | −0,1104                | −10,5   | —                  |
| M1: + intercepto aleatório de bairro (UPA)            | −0,0669                | −6,5    | 39,5               |
| M2: + contexto do bairro (UPA)                        | −0,0637                | −6,2    | 42,3               |
| M3: + efeitos fixos de UF (gap líquido)               | −0,0629                | −6,1    | 43,0               |
| M4: + ocupação e formalidade (limite inferior)        | −0,0579                | −5,6    | 47,6               |

*Como ler:* cada linha adiciona algo à anterior.  $\beta_{\text{negro}}$  é a penalidade racial em log-rendimento (mais próximo de zero = menor gap); “Gap (%)” é a penalidade em % de renda; “Mediação acum.” é a fração do gap agregado (primeira linha) já explicada. O salto da primeira para a segunda linha é a mediação pela segregação residencial: comparar negros e brancos *do mesmo bairro* reduz o gap em 39,5%. Do modelo agregado ao M4 o gap cai de 10,5% para 5,6%: 47,6% do gap é mediado por onde a pessoa mora, o estado e a ocupação que acessa — e a penalidade de 5,6% persiste dentro da mesma ocupação (limite inferior, pois a ocupação é ela própria resultado da barreira de acesso). O agregado inclui efeitos fixos de UF e o M1 e o M2 não (o M3 os reintroduz). Reestimado com UF, na mesma base, o M1 dá  $\beta_{\text{negro}} = -0,0645$  e uma mediação pelo bairro de 41,6% (contra 39,5% na tabela): com o estado mantido no modelo, a mediação pelo bairro é ainda maior — a leitura da tabela é conservadora. Sem os efeitos fixos de UF, o gap agregado seria de 20,1% — a diferença entre estados é, ela própria, parte do diferencial.

*Como ler a Figura 6:* cada barra é um modelo da sequência e, de cima para baixo, acrescenta-se um bloco de controles ao anterior. O comprimento da barra é a penalidade racial em log-rendimento e o rótulo dentro dela, a mesma penalidade em % de renda; o traço fino é o intervalo de confiança de 95% com erro-padrão agrupado por UPA. Em azul, o M3 — o gap líquido.



**Figura 6:** Comparar vizinhos reduz o gap em cerca de 40% — e o que sobra não é explicado por escolaridade, idade, sexo, estado nem ocupação. Barras:  $\hat{\beta}_{\text{negro}}$  de cada modelo; traço: IC 95% (estrito pelo  $N$  de milhões); rótulo: gap em % de renda. Em azul, o M3 (gap líquido).

#### 4.4 Decomposição de Oaxaca–Blinder: composição *vs.* discriminação

De que é feito o gap? Duas explicações rivalizam desde Becker (1957), e elas pedem políticas opostas. Ou negros e brancos chegam ao mercado com características diferentes e o mercado paga igual por características iguais — o gap é *composição*, e a política tem de agir antes do mercado, na escola e na formação. Ou chegam com as mesmas características e o mercado paga diferente — o gap é *preço*, e a política tem de agir dentro dele, na contratação e na fiscalização. A distinção é empírica, e a decomposição de Oaxaca–Blinder foi construída para fazê-la.

A decomposição de Oaxaca–Blinder separa o gap bruto de log-rendimento (0,4252 log-pontos, ou 53,0%) em uma parcela explicada por diferenças de dotações e uma parcela não explicada (retornos diferenciais — limite inferior da discriminação). A Tabela 11 apresenta duas especificações, porque ocupação e formalidade são *bad controls* (ANGRIST; PISCHKE, 2009): são elas próprias resultado da discriminação. Em (A), com os controles do HLM M3 (capital humano, jornada, contexto de UPA e estado), 17,9% do gap não é explicado por características observáveis; em (B), tratando também formalidade e grupo CBO como dotações, a parcela não explicada cai para 15,4% — a discriminação salarial *dentro* da ocupação. A diferença entre as duas (2,5 pontos percentuais) é a parcela da discriminação que opera pela *porta de entrada* das ocupações, e não pelo salário — exatamente o que o GLMM de acesso mede adiante. Os erros-padrão vêm de bootstrap em blocos por UPA.

**Pressupostos das regressões por grupo.** As duas regressões auxiliares (brancos e negros) foram submetidas aos testes de Breusch–Pagan e RESET (FÁVERO; BELFIORE, 2024, cap. 12). Há heterocedasticidade — esperada em log-rendimento — mas de mag-




nitude modesta: o  $R^2$  da regressão auxiliar do Breusch–Pagan é 0,067 (brancos) e 0,066 (negros), e é justamente por isso que os erros-padrão são agrupados por UPA e a decomposição usa bootstrap em blocos. O RESET rejeita a forma funcional linear, mas o ganho de  $R^2$  ao acrescentar potências do valor predito é de 0,0020 (brancos) e 0,0060 (negros) — irrelevante para a decomposição. Com  $N$  de milhões, ambos os testes rejeitam qualquer hipótese nula pontual; o que importa é a magnitude, não o  $p$ -valor (ANGRIST; PISCHKE, 2009).

**Tabela 11:** Decomposição de Oaxaca–Blinder (*twofold*, referência: estrutura de preços dos brancos) do gap salarial racial em duas especificações. (A) *Capital humano + contexto*: escolaridade, idade, sexo, jornada, área urbana, contexto de UPA e efeitos fixos de UF — os mesmos controles do HLM M3; a parcela não explicada é comparável à da literatura. (B) *Acesso*: (A) + formalidade e grupo CBO tratados como dotações (os controles do M4) — a parcela não explicada é a discriminação *dentro* da ocupação, um limite inferior, pois a segregação ocupacional é ela própria discriminatória (OAXACA; RANSOM, 1999) (ver o GLMM de acesso, Tabela 14). População completa da PEA com renda positiva ( $N = 7.699.278$ ; 41.459 UPAs). Erros-padrão entre parênteses: bootstrap em blocos por UPA (500 réplicas).

| Componente                               | (A) Sem ocupação |          | (B) Acesso (com ocupação) |          |
|------------------------------------------|------------------|----------|---------------------------|----------|
|                                          | log-pontos (SE)  | % do gap | log-pontos (SE)           | % do gap |
| Gap total (branco – negro)               | 0,4252 (0,0033)  | 100,0    | 0,4252 (0,0032)           | 100,0    |
| Dotações (características observáveis)   | 0,3491 (0,0033)  | 82,1     | 0,3598 (0,0032)           | 84,6     |
| Não explicado (retornos / discriminação) | 0,0761 (0,0012)  | 17,9     | 0,0654 (0,0011)           | 15,4     |

*Como ler:* em cada especificação, Dotações + Não explicado = Gap total. De (A) para (B), parte do “não explicado” migra para “dotações” porque a ocupação passa a ser tratada como característica — é exatamente a parcela da discriminação que opera pela *porta de entrada*, e não pelo salário.



**Figura 7:** Tratar a ocupação como “característica” reduz a discriminação medida de 17,9% para 15,4% do gap. Os 2,5 pontos que somem são a parte que opera na porta de entrada das ocupações — medida diretamente pelo modelo de acesso.

*Como ler a Figura 7:* cada painel é uma cascata lida da esquerda para a direita. A primeira barra é o gap total em log-rendimento; a segunda desconta a parcela atribuída a diferenças de características (dotações); a terceira, em azul, é o que sobra sem explicação. A única diferença entre os painéis é se a ocupação entra ou não como característica.

## 4.5 Regressão Quantílica e RIF-OB: teto de vidro e *sticky floor*

A penalidade racial é a mesma em toda a distribuição de renda? Nada obriga que seja, e as duas possibilidades apontam para lugares diferentes. Se ela crescer rumo ao topo, o problema é um teto de vidro: quanto mais alto se sobe, mais a cor pesa, e o alvo da política são as posições de comando. Se for maior na base, o problema é um piso pegajoso, e concentrar esforços nas elites profissionais erra o alvo por inteiro. Os resultados a seguir mostram que as duas leituras estão corretas — porque respondem a perguntas diferentes, e a subseção termina explicando por que não se contradizem.

A regressão quantílica estima o gap em cada ponto da distribuição de renda; a RIF-OB separa, por quantil, dotação e retorno. A Tabela 12 mostra a penalidade *condicional* crescendo rumo ao topo (teto de vidro entre pessoas de mesmo perfil); a Tabela 13 revela o padrão complementar: o componente de retorno (discriminação proporcional) é maior na base e *decrece* rumo ao topo (*sticky floor*). *Como ler*: na Tabela 13, Dotações + Retornos = 100% do gap RIF — a coluna ao lado do gap observado —, e a coluna Retornos cai de 26,5% (q10) a 8,9% (q90): a parcela não explicada pesa mais na base. Como a RIF usa os controles da Oaxaca–Blinder *sem* ocupação, sua parcela de retornos na mediana (20,6%) se compara aos 17,9% da especificação (A) da Tabela 11, e não aos 15,4% da (B), que trata a ocupação como característica. O q25 pede cautela: ele cai sobre o salário mínimo, onde muitos trabalhadores têm exatamente a mesma renda. Num ponto de massa assim a densidade que a RIF usa não é bem definida e depende da largura de banda do *kernel*; por isso, no q25, o gap que a RIF decompõe fica bem abaixo do observado. As parcelas de dotações e retornos, que são razões, não dependem dessa escolha — a densidade escala as duas pelo mesmo fator —, e o padrão do q10 ao q90 também não.

**Por sexo.** As colunas por sexo da Tabela 12 mostram que o padrão não é o mesmo para todos: entre homens, a penalidade cresce de 3,9% (q10) para 9,0% (q90); entre mulheres, a penalidade é maior nas duas pontas — 4,9% no q10, 4,3% na mediana e 7,3% no q90 —, de modo que ao teto de vidro se soma um piso pegajoso *condicional*.

**Por que os dois padrões não se contradizem.** A regressão quantílica estima quantis *condicionais*:  $\hat{\beta}(\tau)$  compara negros e brancos na mesma posição *dentro* da distribuição de pessoas com o mesmo perfil observável. O crescimento de  $|\hat{\beta}(\tau)|$  ao longo de  $\tau$  significa que a dispersão condicional do rendimento é maior entre brancos — *fanning out* na linguagem de Angrist e Pischke (2009) —, e não que “os negros do topo sofrem mais”: quantis não seguem indivíduos, e a leitura em termos de pessoas exigiria invariância de posto, que não se testa aqui. A RIF-OB, ao contrário, decompõe quantis *incondicionais* da distribuição de renda (FIRPO; FORTIN; LEMIEUX, 2018): responde “de que é feito o gap no q10 da renda do país”. Como a composição observável concentra negros na base, a parcela de retornos é maior ali; e como há mais dispersão condicional no topo, o coeficiente

condicional cresce com  $\tau$ . Os dois resultados são complementares — um é sobre o *preço* pago a características, o outro sobre a *distribuição* de características.

**Tabela 12:** Regressão quantílica: coeficiente  $\hat{\beta}_{\text{negro}}$  por quantil e sexo. Gap (%) =  $(e^{\hat{\beta}} - 1) \times 100$ . M3: controles individuais + contexto UPA + UF efeito fixo. População completa. Entre parênteses (coluna Global): erro-padrão por bootstrap em blocos por UPA. \*\*\* $p < 0,001$  em todos os quantis e grupos.


| Quantil            | Global                     |         | Homens        |         | Mulheres      |         |
|--------------------|----------------------------|---------|---------------|---------|---------------|---------|
|                    | $\hat{\beta}$ (SE)         | Gap (%) | $\hat{\beta}$ | Gap (%) | $\hat{\beta}$ | Gap (%) |
| $\tau = 0,10$      | -0,0437 (0,0014)           | -4,3%   | -0,0402       | -3,9%   | -0,0502       | -4,9%   |
| $\tau = 0,25$      | -0,0435 (0,0009)           | -4,3%   | -0,0424       | -4,2%   | -0,0454       | -4,4%   |
| $\tau = 0,50$      | -0,0504 (0,0008)           | -4,9%   | -0,0537       | -5,2%   | -0,0444       | -4,3%   |
| $\tau = 0,75$      | -0,0670 (0,0010)           | -6,5%   | -0,0723       | -7,0%   | -0,0583       | -5,7%   |
| $\tau = 0,90$      | -0,0875 (0,0014)           | -8,4%   | -0,0940       | -9,0%   | -0,0757       | -7,3%   |
| $\tau = 0,95$      | -0,1035 (0,0020)           | -9,8%   | -0,1092       | -10,3%  | -0,0920       | -8,8%   |
| $\Delta$ (q90–q10) | -0,0439 log-pt*** (0,0017) |         | $Z = -25,87$  |         | $p < 0,001$   |         |

*Teste de heterogeneidade quantílica (Koenker-Bassett style):  $H_0: \hat{\beta}(q)$  constante para todo  $q$ . SE por bootstrap em blocos por UPA, “m de n” ( $B = 200$ ;  $m = 1.243$  das 41.459 UPAs por réplica; SE escalado por  $\sqrt{m/G}$ , Bickel & Sakov, 2008). Sem a escala (conservador):  $Z = -4,48$ ,  $p < 0,001$ .*

**Tabela 13:** Decomposição RIF-OB (FIRPO; FORTIN; LEMIEUX, 2018) do gap salarial racial por quantil incondicional, em formato *two-fold* (referência: estrutura de preços dos brancos). Mesmos controles da decomposição de Oaxaca–Blinder sem ocupação (escolaridade, idade, sexo, jornada, área urbana, ano e contexto do bairro), mais efeitos fixos de UF; a ocupação *não* entra. Dotações: diferença de características observáveis. Retornos: parcela não explicada, que inclui a discriminação e o que não foi observado. Dotações + Retornos = 100% *do gap RIF* — que é o gap decomposto pelo método e difere do gap observado da segunda coluna; as porcentagens são fração daquele, não deste. Padrão *sticky floor*: a parcela de retornos é maior na base e decresce rumo ao topo. PNAD Contínua 2016–2025, população completa. Entre parênteses: erro-padrão por bootstrap em blocos por UPA.

| Quantil | Gap obs. (SE) | Gap RIF | Dotações (%) | Retornos (%) | $N$       |
|---------|---------------|---------|--------------|--------------|-----------|
| q10     | 0,569 (0,005) | 0,536   | 73,5 (0,7)   | 26,5 (0,6)   | 7.699.278 |
| q25     | 0,223 (0,005) | 0,130   | 77,7 (1,0)   | 22,3 (0,6)   | 7.699.278 |
| q50     | 0,375 (0,003) | 0,427   | 79,4 (0,7)   | 20,6 (0,3)   | 7.699.278 |
| q75     | 0,448 (0,004) | 0,462   | 83,1 (1,3)   | 16,9 (0,4)   | 7.699.278 |
| q90     | 0,564 (0,007) | 0,573   | 91,1 (1,6)   | 8,9 (0,5)    | 7.699.278 |

*Como ler a Figura 8:* à esquerda, cada ponto é a penalidade racial estimada num quantil *condicional*  $\tau$  (eixo vertical em log-pontos  $\times 100$ ), e a faixa é o intervalo de 95% por bootstrap em blocos de UPA. À direita, cada barra é um quantil *incondicional* da renda e soma 100%: a parte azul é a parcela não explicada, com o valor escrito dentro.



**Figura 8:** Teto de vidro entre pares, piso pegajoso na renda do país: duas perguntas, dois padrões. À esquerda, a penalidade em quantis *condicionais* cresce rumo ao topo (faixa: IC 95% por bootstrap em blocos de UPA); à direita, a parcela não explicada dos quantis *incondicionais* da renda é maior na base.

## 4.6 GLMM logístico: o teto de vidro no acesso

Até aqui a pergunta foi quanto um trabalhador negro ganha a menos. Ela pressupõe que negros e brancos estejam disputando as mesmas vagas. E se a barreira for anterior ao salário — se ela estiver em *quais* posições cada um consegue alcançar? É a pergunta desta subseção, e ela importa porque muda o alvo da política: se a desigualdade se produz no salário, o remédio é fiscalização de remuneração; se ela se produz no acesso, nenhuma política salarial a alcança. Três desfechos respondem — ocupar cargo qualificado (CBO 1–4), estar no top 20% e no top 10% da renda —, cada um estimado em quatro degraus próprios, rotulados A1 a A4 para não se confundirem com os do HLM — aos quais não correspondem um a um —, com intercepto aleatório de UPA e efeitos fixos de UF; o ajuste e a classificação de cada degrau estão na Tabela 15.<sup>11</sup>

**O acesso também é “bairro”.** A primeira coisa que o modelo mostra é que a lógica territorial do HLM se repete aqui. Entre **9% e 22% da variância latente do acesso está entre bairros**<sup>12</sup> — ou seja, saber apenas em que bairro alguém mora já antecipa boa parte da chance de essa pessoa chegar a um cargo qualificado, antes de se conhecer sua escolaridade. E a fração é maior para o top 10% do que para o cargo qualificado: quanto mais alto o degrau, mais o endereço pesa.

**A porta é mais estreita para negros — e estreita ainda mais no topo.** Comparando pessoas do mesmo bairro, com a mesma escolaridade, sexo, idade e estado, a

<sup>11</sup>`lme4::glmer` com `nAGQ = 0` — os efeitos fixos são estimados junto com os modos condicionais, aproximação mais rápida que a de Laplace e adequada a  $N$  de milhões —, sobre a população completa. Os degraus são: A1 individual; A2 + contexto do bairro; A3 + vínculo (formalidade, setor público, conta própria, doméstico), que é desfecho da própria discriminação e por isso faz do A3 um limite inferior; A4 + interação **negro** × credencial. A Tabela 14 traz *odds ratios*, efeitos marginais, ICC e E-values; a Tabela 15, o ajuste e a classificação.

<sup>12</sup>Correlação intraclassa latente do M1: 0,087 para o cargo qualificado e 0,221 para o top 10%, com  $ICC = \tau^2 / (\tau^2 + \pi^2/3)$ . O teste de razão de verossimilhança contra o logit sem efeito aleatório dá  $LR = 77.940$  para o cargo e  $80.791$  para o top 10% (1 g.l.,  $p < 0,001$ ).

chance de um trabalhador negro ocupar cargo qualificado é  $OR = 0,814^{13}$  da chance de um branco — **chances (*odds*) 19% menores**. Traduzido para probabilidade, que é a medida a reter (ANGRIST; PISCHKE, 2009), são **2,6 pontos percentuais** a menos de chegar lá. E a desvantagem cresce à medida que se sobe na renda: para chegar ao top 10% — que já não é o acesso a uma ocupação, mas a uma faixa de rendimento — o OR cai para 0,761, **chances 24% menores**. Não é o mesmo fenômeno do salário visto de outro ângulo — é uma barreira que age antes, na distribuição das posições, e que nenhuma política de remuneração igual alcançaria.

Em síntese, a desigualdade racial no mercado de trabalho brasileiro não começa só no contracheque: começa também na porta.


**Vínculo e credencial não desfazem a barreira.** Duas explicações alternativas se apresentam naturalmente, e o modelo testa as duas. A primeira é a informalidade: a barreira seria um artefato de negros estarem mais em vínculos precários. Descontar o vínculo (A3) praticamente não move o OR do cargo qualificado (0,791) nem o do top 10% (0,740), de modo que não é isso. A segunda é o diploma: bastaria credenciar-se. A interação **negro**×credencial do A4 é de 1,042 para o superior completo e 0,947 para a pós-graduação — o superior completo atenua levemente a barreira, mas a pós-graduação volta a agravá-la —, e o OR combinado de um trabalhador negro com superior completo ainda é 0,818. A credencial não neutraliza a barreira. A Figura 9 reúne as razões de chance dos três desfechos e dos modelos de cada um.

**Quão forte teria de ser um confundidor omitido.** O modelo separa bem quem acessa de quem não acessa<sup>14</sup>, mas a pergunta que interessa não é essa: é se a desvantagem poderia ser obra de algo que o modelo não viu. O E-value responde quanto um confundidor omitido teria de ser forte para anular o resultado, e aqui ele vale **1,5**: seria preciso uma característica não medida associada tanto a ser negro quanto a ocupar cargo qualificado com razão de risco de pelo menos 1,5 em ambas as pontas (com o desfecho comum, a razão de chances é convertida em razão de risco pela raiz quadrada). É uma associação modesta — a escolaridade, sozinha, tem efeito muito maior sobre o acesso —, e por isso o E-value não basta para descartar viés: o que sustenta o resultado é ele sobreviver ao contexto de bairro e ao teste de Konfound do modelo de renda. Por fim, o logit com efeitos fixos de UF e erro-padrão agrupado por UPA (última coluna da Tabela 14) reproduz os OR a partir do A2 (cargo qualificado: 0,796 contra 0,814); no A1, sem o contexto do bairro, dá 0,728 contra 0,805, porque sem o intercepto de UPA o contexto omitido é absorvido

<sup>13</sup>IC 95% 0,810–0,818. *Odds ratio* abaixo de 1 é desvantagem; acima de 1, vantagem.

<sup>14</sup>AUC de 0,878 com efeitos aleatórios e 0,870 só com efeitos fixos, para o cargo qualificado; no *cutoff* de Youden (0,30), sensibilidade 0,79 e especificidade 0,79. O teste de Hosmer–Lemeshow rejeita a calibração perfeita em todos os degraus — inevitável com *N* de milhões (ANGRIST; PISCHKE, 2009) —, mas a estatística cai 69% no top 20% e 54% no top 10%, embora suba no cargo qualificado ao se acrescentar o vínculo (A3).

pelo coeficiente racial. Com o contexto do bairro no modelo, a conclusão não depende da hipótese de efeitos aleatórios.



**Figura 9:** A porta é mais estreita para trabalhadores negros — e estreita ainda mais no topo da renda. Razão de chances de acesso (negro *vs.* branco do mesmo bairro) com IC 95%, por desfecho e degrau; em azul, o modelo com contexto de bairro (A2).

*Como ler a Figura 9:* cada ponto é uma razão de chances e a linha horizontal, seu intervalo de confiança de 95%; a linha tracejada em 1 marca a paridade, de modo que quanto mais à esquerda, maior a desvantagem. Os blocos são os três desfechos e, dentro de cada um, os modelos; em azul, o A2, que compara pessoas do mesmo bairro.

**Tabela 14:** GLMM logístico (lme4::glmer, intercepto aleatório de UPA e efeitos fixos de UF) — teto de vidro ocupacional e salarial. *Odds ratio* do coeficiente **negro** com IC 95%, efeito marginal médio (AME: diferença média de probabilidade predita, em pontos percentuais), ICC da UPA =  $\tau^2/(\tau^2 + \pi^2/3)$  e E-value (VANDERWEELE; DING, 2017). Coluna final: OR do logit com efeitos fixos de UF e erro-padrão agrupado por UPA (robustez). População completa da PEA com renda positiva ( $N = 7.699.273$ ; 41.454 UPAs). A3 acrescenta o vínculo (formalidade, setor público, conta própria, doméstico), que é desfecho da própria discriminação: limite inferior. Todos os OR com  $p < 0,001$ ; com  $N$  desta ordem, a inferência relevante está nos IC e nos E-values.

| Desfecho                    | Modelo                     | OR (IC 95%)          | AME (p.p.) | ICC <sub>UPA</sub> | E-value | E-value (IC) | OR logit-FE |
|-----------------------------|----------------------------|----------------------|------------|--------------------|---------|--------------|-------------|
| Cargo qualificado (CBO 1-4) | A1 individual + UF         | 0,805 [0,801; 0,809] | −2,75      | 0,087              | 1,47    | 1,47         | 0,728       |
|                             | A2 + contexto do bairro    | 0,814 [0,810; 0,818] | −2,60      | 0,054              | 1,46    | 1,45         | 0,796       |
|                             | A3 + vínculo (limite inf.) | 0,791 [0,787; 0,794] | −2,66      | 0,054              | 1,50    | 1,49         | 0,796       |
|                             | A4 + negro×credencial      | 0,785 [0,781; 0,789] | −2,66      | 0,054              | 1,51    | 1,50         | 0,792       |
| Top 20% de renda            | A1 individual + UF         | 0,759 [0,755; 0,763] | −2,91      | 0,159              | 1,56    | 1,55         | 0,638       |
|                             | A2 + contexto do bairro    | 0,769 [0,765; 0,773] | −2,77      | 0,083              | 1,54    | 1,53         | 0,756       |
|                             | A3 + vínculo (limite inf.) | 0,755 [0,751; 0,759] | −2,80      | 0,084              | 1,57    | 1,56         | 0,756       |
|                             | A4 + negro×credencial      | 0,719 [0,714; 0,723] | −2,79      | 0,084              | 1,64    | 1,63         | 0,713       |
| Top 10% de renda            | A1 individual + UF         | 0,748 [0,743; 0,753] | −1,77      | 0,221              | 2,01    | 1,99         | 0,577       |
|                             | A2 + contexto do bairro    | 0,761 [0,756; 0,766] | −1,66      | 0,116              | 1,96    | 1,94         | 0,739       |
|                             | A3 + vínculo (limite inf.) | 0,740 [0,735; 0,745] | −1,73      | 0,117              | 2,04    | 2,02         | 0,739       |
|                             | A4 + negro×credencial      | 0,668 [0,662; 0,674] | −1,71      | 0,117              | 2,36    | 2,33         | 0,659       |

*Como ler:* OR < 1 = menor chance de acesso para trabalhadores negros do que para brancos de mesmo perfil e do mesmo bairro; quanto mais perto de zero, maior a barreira. O E-value é a força mínima de associação (razão de risco) que um confundidor não observado precisaria ter com a raça e com o desfecho para anular o OR; o E-value (IC) faz o mesmo para o limite do intervalo. A coluna logit-FE mostra que a conclusão não depende da hipótese de efeitos aleatórios.

**Tabela 15:** GLMM logístico — ajuste e desempenho de classificação por degrau. LR vs. pooled: teste de razão de verossimilhança do A2 contra o logit sem efeito aleatório (fronteira,  $p/2$ ); AUC com efeitos aleatórios (ajuste na amostra) e só com efeitos fixos; *cutoff* de Youden (maximiza sensibilidade + especificidade) com as taxas correspondentes; Hosmer–Lemeshow em dez decis. Modelos A1–A4 como na Tabela 14. Com  $N = 7,7$  milhões qualquer desvio de calibração é “significativo” — o  $\chi^2$  deve ser lido como magnitude relativa entre degraus, não como teste (MHE, cap. 8).

| Desfecho                    | Modelo | −2 LL     | AIC       | LR vs. pooled | AUC (RE) | AUC (FE) | Cutoff | Sens./Espec. | HL $\chi^2$ |
|-----------------------------|--------|-----------|-----------|---------------|----------|----------|--------|--------------|-------------|
| Cargo qualificado (CBO 1–4) | A1     | 6.102.483 | 6.102.575 | —             | 0,879    | 0,864    | 0,30   | 0,79/0,79    | 2.760       |
|                             | A2     | 6.088.976 | 6.089.074 | 77.940        | 0,878    | 0,870    | 0,30   | 0,79/0,79    | 2.796       |
|                             | A3     | 5.457.265 | 5.457.373 | —             | 0,906    | 0,900    | 0,31   | 0,83/0,82    | 7.982       |
|                             | A4     | 5.457.207 | 5.457.319 | —             | 0,906    | 0,900    | 0,31   | 0,83/0,82    | 7.881       |
| Top 20% de renda            | A1     | 5.271.208 | 5.271.300 | —             | 0,872    | 0,845    | 0,19   | 0,79/0,79    | 9.078       |
|                             | A2     | 5.251.296 | 5.251.394 | 108.283       | 0,872    | 0,859    | 0,19   | 0,79/0,79    | 9.584       |
|                             | A3     | 4.967.208 | 4.967.316 | —             | 0,886    | 0,875    | 0,19   | 0,81/0,80    | 2.956       |
|                             | A4     | 4.966.299 | 4.966.411 | —             | 0,886    | 0,875    | 0,19   | 0,81/0,80    | 2.630       |
| Top 10% de renda            | A1     | 3.276.689 | 3.276.781 | —             | 0,901    | 0,868    | 0,09   | 0,83/0,81    | 6.085       |
|                             | A2     | 3.258.340 | 3.258.438 | 80.791        | 0,900    | 0,886    | 0,09   | 0,83/0,81    | 6.176       |
|                             | A3     | 3.075.653 | 3.075.761 | —             | 0,913    | 0,900    | 0,10   | 0,83/0,83    | 2.836       |
|                             | A4     | 3.074.632 | 3.074.744 | —             | 0,913    | 0,900    | 0,09   | 0,85/0,82    | 2.472       |

## 4.7 Interseccionalidade: raça e gênero no acesso e no topo

**Tabela 16:** Decomposição interseccional (raça  $\times$  gênero) do gap de rendimento *vs.* o Homem Branco (grupo de referência). Dotações: parcela explicada por características observáveis; Retornos: parcela não explicada (discriminação). Gap (log): a mesma desvantagem em log-pontos, a escala em que os efeitos de raça e de gênero se somam (CRENSHAW, 1989). PNAD Contínua, população completa ( $N$  do grupo de referência — homens brancos — na última linha da nota). Entre parênteses: erro-padrão por bootstrap em blocos por UPA.


| Grupo         | Gap vs HB (%) | Gap (log) | Dotações (%) | Retornos (%) | $N$ do grupo |
|---------------|---------------|-----------|--------------|--------------|--------------|
| Mulher Branca | 19,9 (0,2)    | 0,182     | −97,0 (1,8)  | 197,0 (1,8)  | 1.429.355    |
| Homem Negro   | 56,4 (0,5)    | 0,447     | 77,2 (0,3)   | 22,8 (0,3)   | 2.662.039    |
| Mulher Negra  | 80,7 (0,6)    | 0,592     | 27,4 (0,4)   | 72,6 (0,4)   | 1.765.796    |

*Como ler:* “Gap vs HB” é a desvantagem de renda de cada grupo *vs.* o Homem Branco; Dotações + Retornos = 100% do gap. A Mulher Negra tem o maior gap. Em log-pontos, o gap da Mulher Negra (0,592) fica abaixo da soma dos gaps da Mulher Branca e do Homem Negro (0,629): as desvantagens de raça e de gênero se acumulam sem se multiplicar — a interação é sub-aditiva, como no modelo de acesso. Somar os percentuais daria a impressão contrária, porque a escala percentual é convexa. O sinal negativo das dotações da Mulher Branca indica que suas características observáveis *superam* as do homem branco: todo o gap vem de retornos diferenciais. Grupo de referência: 1.842.088 homens brancos.

Raça e gênero simplesmente se somam? Todos os modelos até aqui responderam que sim, por construção: tratadas como penalidades aditivas, a desvantagem de ser negra e mulher seria a de ser negro mais a de ser mulher. Crenshaw (1989) desconfia dessa aritmética, e a desconfiança é testável — basta trocar os dois indicadores separados por um único fator de quatro grupos e deixar que os dados digam se a soma fecha.<sup>15</sup> A

<sup>15</sup>GLMM de acesso reespecificado com `grupo_rg` (homem branco como referência, mulher branca, homem negro, mulher negra) e a interação `negro×sexo_fem`, em três desfechos: ocupação qualificada (CBO 1–4), renda no top 20% e no top 10%.

Tabela 16 traz a decomposição de Oaxaca–Blinder dos quatro grupos contra o homem branco, e a Figura 10, as razões de chance nos três desfechos.



**Figura 10:** A vantagem aparente da mulher negra no acesso é de composição: razões de chance dos quatro grupos raça×gênero *vs.* homem branco, em três desfechos. Na categoria agregada ela aparece acima da referência, mas por composição: entra pelas ocupações feminizadas e é a mais distante do homem branco entre os dirigentes e no topo da renda.

Como ler a Figura 10: cada série é um grupo raça×gênero e cada ponto, a razão de chances contra o homem branco, cuja referência é a linha tracejada em 1; abaixo dela, o grupo tem menos chance que ele. À esquerda, siga a série azul (mulher negra): ela aparece acima da referência na categoria agregada e termina como o grupo mais distante da referência no topo da renda. À direita, a mesma comparação por grande grupo da CBO mostra de onde vem a aparente vantagem: das ocupações feminizadas, não do comando.

**Na entrada, a vantagem da mulher negra é de ocupações feminizadas.** No acesso à ocupação qualificada (CBO 1–4) a mulher negra tem  $OR = 1,31$ , mais chance do que o homem branco de referência, e o grupo mais penalizado na entrada é o **homem negro** ( $OR = 0,76$ ). O agregado, porém, junta portas muito diferentes, e estimar o mesmo modelo para cada grande grupo da CBO muda o quadro. A aparente vantagem da mulher negra no acesso a cargos CBO 1–4 é composição: vem do apoio administrativo ( $OR 1,96$ ) e das profissões de nível superior, sobretudo ensino e saúde ( $OR 1,36$ ), ocupações feminizadas em que a mulher branca entra ainda mais ( $2,20$  e  $1,42$ ). Entre os dirigentes, onde se exerce comando, a mulher negra tem a menor chance de todos os grupos ( $OR 0,63$ ). Se a análise parasse no agregado, concluiria que a interseccionalidade não se confirma na entrada; separada a ocupação, ela se confirma.

**No topo, a ordem se inverte e ela passa a ser a mais excluída.** No decil superior de renda o quadro vira: a mulher negra tem  $OR = 0,28$ , abaixo da mulher branca ( $0,37$ ) e do homem negro ( $0,73$ ). Em linguagem de leitor: as chances (*odds*) de uma mulher negra chegar aos 10% mais ricos equivalem a 28% das de um homem branco com a mesma escolaridade, idade, jornada, estado e bairro. A vantagem de gênero na entrada, que já



vinha das ocupações feminizadas, desaparece exatamente onde a ascensão se decide, e o que sobra é o acúmulo das duas barreiras, um pouco abaixo da soma.<sup>16</sup>

Em uma frase: a mulher negra entra pelas ocupações feminizadas, mas não chega ao comando nem ao topo.

Esse achado refina a tese central: o teto de vidro não é racial nem sexualmente neutro — recai com força máxima sobre a mulher negra, que pode *entrar* em ocupações qualificadas, mas é sistematicamente barrada de *chegar ao topo* da remuneração.

## 4.8 Multicolinearidade do Modelo M4: Análise VIF

Os controles do M4 estão brigando entre si? A pergunta é legítima: o modelo empilha nove indicadores de grupo ocupacional sobre três de vínculo, e variáveis muito próximas entre si inflam o erro-padrão umas das outras, a ponto de tornar instável justamente o coeficiente que interessa. O *Variance Inflation Factor* mede esse efeito: quanto a variância de cada estimativa cresce em razão das demais. A resposta, aqui, é que há colinearidade — mas não onde ela importaria.<sup>17</sup> Nenhum preditor do M4 tem VIF acima de dez; o maior é o de `ocp_profissional` (2,66). A colinearidade que houver **não** contamina o coeficiente de interesse: o VIF de **negro** é 1,36 e o das variáveis de contexto da UPA fica abaixo de 2,2. Entre as *dummies* de CBO e as variáveis de vínculo — a colinearidade que se temia no M4 — o VIF máximo é 2,66. A especificação do M4 dispensa, portanto, ortogonalização ou eliminação de preditores; o que ela não dispensa é a ressalva de *bad control* (Seção 4.1).

## 5 Discussão e Prescrição

**Nota terminológica.** Três conceitos próximos, mas distintos, percorrem este trabalho e não devem ser confundidos. **Mediação contextual** (HLM) é a fração do gap agregado (condicional a capital humano e estado) que *desaparece* ao se compararem pessoas do mesmo bairro (UPA) — mede o quanto da penalidade racial transita *pelo* território. **Efeito dotação** (Oaxaca–Blinder) é a parcela do gap atribuível a *diferenças nas características observáveis* entre brancos e negros (escolaridade, ocupação, contexto), por oposição ao **efeito retornos** (preços diferenciais pagos às mesmas características). **Gap líquido** é o diferencial que *persiste* após o controle de capital humano e contexto (M3): 6,1%. **Gap residual pós-ocupação** é o que resta ao se controlar também ocupação e formalidade (M4): 5,6% — um limite inferior, pois a ocupação é ela própria resultado

<sup>16</sup>A interação `negro×sexo_fem` é *sub-aditiva* em todos os desfechos (OR = 1,10 no acesso; = 1,04 no top 10%): a penalidade racial é um pouco menor entre mulheres do que entre homens, o que atenua a soma sem desfazê-la.

<sup>17</sup>Calculado sobre a população completa da PEA com renda positiva. Dos 23 preditores analisados, VIF máximo = 2,66 (CBO: Profissionais); 0 variáveis críticas (VIF > 10); 0 variáveis altas (5–10); 6 variáveis moderadas (2–5); 17 variáveis baixas (< 2).

da barreira de acesso. Em suma: a mediação contextual responde “por onde passa o gap”; a decomposição de dotações, “de que ele é feito”; e o gap líquido, “o que sobra sem explicação”.

**Da diagnose às políticas.** O diagnóstico das duas barreiras revela gargalos simultâneos — exclusão de acesso às ocupações qualificadas e penalidade salarial que persiste dentro delas — que aparecem juntas nos mesmos dados. A consequência para o desenho de políticas é direta: nenhuma intervenção unidimensional (só cotas de acesso, só fiscalização salarial, só escolaridade) atinge as duas barreiras ao mesmo tempo; a magnitude relativa de cada uma, estimada aqui, é o insumo para priorizá-las.

**O que este trabalho acrescenta ao debate.** Hasenbalg (1979) identificou a discriminação racial como estrutural, sem poder quantificar mecanismos em escala nacional. Henriques (2001) documentou o gap educacional racial, mas não separou o efeito educacional do de redes e contexto. Soares (2009) estimou, com dados de 2006, que cerca de 50% do gap salarial seria “inexplicado” — interpretado como discriminação direta. Este trabalho, com dados de 2016–2025 e metodologias não disponíveis a Soares, decompõe essa *caixa preta*. Na especificação comparável à dele (capital humano e contexto, sem ocupação), 17,9% do gap bruto são retornos diferenciais — limite superior do tratamento diferencial — e 82,1% são diferenças de dotações; quando a ocupação é tratada como dotação, o não explicado cai para 15,4%, e 84,6% passam a ser dotações — mas essas dotações são, elas mesmas, produto da barreira de acesso às ocupações qualificadas (GLMM), que este trabalho quantifica em conjunto com a penalidade salarial. A contribuição central não é mostrar que o gap existe — isso a literatura já sabia desde Hasenbalg (1979) —, mas mostrar que ele é consistente com um **sistema combinado** em que discriminação de acesso, segregação residencial e penalidade salarial operam em conjunto, tornando insuficientes políticas focadas em um único mecanismo.

**Diálogo com o quadro macro recente do IBGE.** Os resultados convergem com o retrato macroestrutural mais recente. A melhora multidimensional captada pela POF não eliminou o gap racial de qualidade de vida, e a renda voltou a concentrar-se no topo em 2025.<sup>18</sup> As duas medidas não são a mesma coisa, e a diferença importa para não se ler tendência onde há mudança de conceito.<sup>19</sup> No conceito adotado aqui, a desigualdade *interna* é maior entre brancos (= 0,477) do que entre negros (= 0,436) — não por equi-

---

<sup>18</sup>Índice de Perda de Qualidade de Vida (IPQV; quanto maior, pior) de 0,183 para chefes pretos ou pardos, contra 0,122 para brancos; Gini do rendimento domiciliar *per capita* de 0,491 em 2025 (IBGE, 2019; IBGE, 2025).

<sup>19</sup>O Gini estimado neste trabalho refere-se ao rendimento do trabalho entre ocupados (em torno de 0,47), ao passo que o do IBGE é domiciliar *per capita* e de todas as fontes. Os níveis são próximos, mas as medidas podem divergir em tendência: a alta de 2025 é puxada por renda não-trabalho do topo, que não transita pelo rendimento dos ocupados.

dade, mas por confinamento dos negros ao piso da distribuição, o reverso distribucional do teto de vidro.

**Triangulação com o Índice de Progresso Social (IPS).** O IPS municipal (WILM et al., 2026) — que avalia a qualidade de vida dos 5.570 municípios brasileiros a partir de 57 indicadores sociais e ambientais — oferece corroboração externa e multidimensional do eixo territorial desta tese. Uma integração *final* com o nosso proxy de bairro (UPA) é, contudo, inviável: o painel público da PNAD não divulga o município (apenas UF e a situação capital/RM/interior), e o IPS é municipal — portanto mais agregado que a UPA, que é sub-municipal. O IPS, assim, não valida o achado de *bairro*: situa-se acima dele na escala e mede progresso social geral, não desigualdade racial. Fica como agenda: com o município identificado (microdados de acesso restrito), seria possível testar se a penalidade de bairro varia com o progresso social do município.

**O diploma quase iguala o salário, mas não abre a porta.** As duas barreiras respondem de modo diferente à escolaridade. A penalidade salarial é de 9,6% entre quem não tem fundamental completo e cai a 1,1% na pós-graduação (Figura 3); a desvantagem de acesso, não: com superior completo, as chances de um trabalhador negro chegar a um cargo qualificado seguem 18% menores que as de um branco de mesmo perfil e bairro, e com pós-graduação, 23% menores (GLMM, degrau A4, Tabela 14). A escolaridade se associa a quase toda a convergência salarial, mas não à de acesso. Duas cautelas: são diferenças condicionais entre pessoas comparáveis, não o efeito de estudar mais — quem chega à pós-graduação é um grupo selecionado —, e as razões de chances do A4 incluem o vínculo, o que faz delas um limite inferior da desvantagem.

**A segregação residencial como multiplicador da desigualdade.** O achado mais robusto desta análise é que 39,5% do gap salarial racial condicional a capital humano é mediado pelo bairro de moradia — muito além do que modelos cross-sectionais típicos, que ignoram a estrutura aninhada dos dados, seriam capazes de estimar. O coeficiente contextual  $\hat{\gamma}_{01} = -0,1272$  por desvio-padrão da proporção de negros na UPA indica que a penalidade de viver em bairro segregado é da mesma ordem de grandeza da própria penalidade individual de ser negro — e que 35,3% da variância do rendimento está entre bairros, não entre pessoas. Isso sugere que políticas de redistribuição de renda que não enfrentem a segregação residencial terão eficácia limitada sobre o gap racial.

**Subvalorização do capital humano negro.** A decomposição de Oaxaca–Blinder atribui 17,9% do gap a *retornos* diferenciais — as mesmas características de capital humano e contexto rendem menos a trabalhadores negros — e ainda 15,4% quando a própria posição ocupacional é descontada; a decomposição RIF mostra que essa parcela chega

a 27% na base da distribuição. O GLMM acrescenta que a credencial educacional não neutraliza a barreira de acesso (OR combinado de **negro** de 0,818 entre os de superior completo). Juntas, essas evidências indicam um duplo obstáculo ao retorno educacional: além da penalidade direta mensurada pelo HLM, o acesso desigual às ocupações que convertem credenciais em renda. Granovetter (1973) oferece o mecanismo plausível — redes de indicação que não cruzam fronteiras sociais —, hipótese que este trabalho não testa diretamente e que fica como agenda.

**Persistência da discriminação direta.** O gap líquido de 6,1%, estimado após controlar por todos os vetores de transmissão contextual, é o limite superior do intervalo — cujo piso é o M4, com a ocupação — dentro do qual está a penalidade direta não explicada por diferenças observáveis. Os valores SHAP reforçam essa interpretação: a variável racial mantém o 14º lugar na importância preditiva do XGBoost mesmo quando o modelo tem acesso completo às variáveis educacionais, demográficas e contextuais. Essa evidência é consistente com os experimentos de auditoria de Pager (2007), que demonstram experimentalmente a discriminação racial em processos seletivos.

**A convergência veio num degrau, e não num ritmo.** Em dez anos o gap encolheu 14,7%, e a inclinação é estatisticamente distinta de zero<sup>20</sup>. Uma reta, porém, descreve mal a série. No estudo de evento — a penalidade de cada ano contra a de 2019, com efeito fixo de bairro e erro agrupado por UPA, nível que difere do M3 por comparar só vizinhos —, ela oscilou sem tendência de 2016 a 2019 e caiu em 2020, de 7,0% para 5,9% (1,0 log-ponto acima da tendência anterior,  $p = 0,004$ ), sem voltar depois: em 2025 era de 5,2%. A queda não reflete a saída dos negros de menor renda do emprego: a ocupação deles caiu só 0,26 ponto percentual a mais que a dos brancos em 2020, dentro da tendência anterior, e passou a crescer mais que a deles a partir de 2022, quando a penalidade seguia menor. Também não reflete a entrevista por telefone, adotada pelo IBGE em 2020 e 2021: a penalidade menor persistiu depois da volta da coleta presencial. Sem grupo de controle, a série não identifica a causa do degrau; ela mostra que a década não teve um ritmo de convergência a extrapolar, e que os resultados agrupados de 2016–2025 são uma média dos dois patamares. Nada disso trivializa os avanços recentes em políticas de cotas e de acesso ao ensino superior. Diz, sim, que reformas no campo educacional, sem intervenção simultânea nos mecanismos de segregação residencial e de acesso às ocupações, são insuficientes — que é precisamente o que a sequência de modelos deste trabalho mostrou.

---

<sup>20</sup> $\delta = 0,000928$  log-ponto por ano, IC 95% [0,000133; 0,001723],  $p = 0,027$ , por mínimos quadrados ponderados sobre o  $\hat{\beta}_{\text{negro}}$  do M3 estimado ano a ano, 2016–2025.

**Ancoragem em políticas públicas existentes.** As barreiras estimadas não são abstrações: cada uma corresponde a um instrumento jurídico-institucional já existente no Brasil, cuja intensificação ou aperfeiçoamento os resultados sugerem. A **barreira de acesso** (GLMM, OR = 0,814 para CBO 1–4 no modelo com contexto) dialoga diretamente com a Lei 15.142/2025, que substituiu a Lei 12.990/2014 e ampliou a reserva de vagas em concursos públicos federais a pessoas negras, indígenas e quilombolas, e cujo escopo o diagnóstico sugere ampliar para níveis hierárquicos superiores — onde o teto de vidro é mais severo ( $OR(\text{top } 10\%) = 0,761$ ). A **qualificação e o acesso ao ensino superior** correspondem ao *Prouni* e ao *Fies*, bem como ao legado do *PRONATEC*; o achado de que as mesmas credenciais rendem menos a trabalhadores negros (efeito retornos da decomposição de Oaxaca–Blinder) indica que tais programas precisam ser combinados a mecanismos de inserção ocupacional, sob pena de retorno marginal decrescente. O **combate à discriminação direta** encontra base na *Lei 9.029/1995* (que proíbe práticas discriminatórias na relação de trabalho) e no *Estatuto da Igualdade Racial* (*Lei 12.288/2010*), cuja fiscalização o gap líquido de 6,1% — e a penalidade de 5,6% que persiste dentro da mesma ocupação — justifica reforçar.

## 6 Conclusão

Este estudo mostra que a meritocracia baseada em capital humano falha sistematicamente em explicar a trajetória profissional da população negra no Brasil. A exclusão não é um evento isolado na contratação, nem uma consequência automática de menor escolaridade — é uma engrenagem de duas camadas que opera ao longo de toda a trajetória do trabalhador: na porta de entrada das ocupações de prestígio e no salário dentro das mesmas ocupações. Cada uma dessas camadas foi identificada, isolada e medida de forma independente; juntas, elas formam um sistema que nenhuma política unidimensional consegue desmontar.

O achado mais desafiador para o debate de políticas públicas é o da barreira de acesso: com a mesma escolaridade, idade, sexo e contexto de moradia, trabalhadores negros têm chances (*odds*) cerca de 19% menores de ocupar um cargo qualificado e 24% menores de chegar ao décimo superior da renda. Isso significa que aumentar a escolaridade da população negra, sem intervir simultaneamente nos mecanismos de seleção e promoção, produz retorno marginal decrescente: os títulos existem, mas os canais que os convertem em mobilidade profissional permanecem estreitos. Políticas baseadas apenas em educação são, portanto, necessárias, mas estruturalmente insuficientes.

A última década não autoriza esperar: a penalidade caiu sobretudo em 2020, de 7,0% para 5,9%, e não mostrou um ritmo de convergência a extrapolar. Significa, concretamente, que reformas incrementais são insuficientes: é necessário atacar as duas barreiras de forma simultânea e com recursos proporcionais à magnitude do problema.

*Com a mesma escolaridade, idade, sexo e bairro, um trabalhador negro ganha 6,1% a menos e tem chances 19% menores de chegar a um cargo qualificado. O diploma quase iguala o salário, mas não abre a porta.*

Essas conclusões emergem da convergência de quatro métodos e cinco análises de robustez sobre  $N = 7.699.278$  observações da PNAD Contínua 2016–2025. O gap condicional a capital humano, de 10,5% (sem efeito de bairro), decompõe-se em três parcelas: (i) mediação de 39,5% pela segregação residencial — comparando negros e brancos do mesmo bairro ( $\hat{\gamma}_{01} = -0,1272$  por desvio-padrão da composição racial do bairro), chega-se ao **gap líquido de 6,1%** (M3); (ii) mediação ocupacional de 4,5% pelo acesso desigual a grupos CBO de alta remuneração; e (iii) penalidade de 5,6% que persiste *dentro* da mesma ocupação (M4) — limite inferior descritivo, pois a própria ocupação é resultado da barreira de acesso. O GLMM logístico confirma essa barreira:  $OR = 0,814$  para CBO 1–4 no modelo com contexto, com gradiente progressivo  $OR(\text{top } 20\%) = 0,769 \rightarrow OR(\text{top } 10\%) = 0,761$ . A regressão quantílica formaliza o teto de vidro no gap condicional ( $Z = -25,87, p < 0,001$ ), e a decomposição RIF mostra que a parcela de retornos é maior na base da distribuição incondicional.

**Contribuição principal.** Este estudo oferece, ao nosso conhecimento, a primeira análise integrada de modelo hierárquico, decomposição de Oaxaca–Blinder, regressão quantílica com RIF e modelo logístico de acesso — validados por SHAP — sobre a série completa da PNAD Contínua. Mais do que confirmar a existência do gap racial — resultado já documentado desde Hasenbalg (1979) —, este trabalho identifica e quantifica os **mecanismos** que o sustentam em 2016–2025: discriminação de acesso, segregação residencial e penalidade salarial dentro da ocupação, em sistema combinado.

## Limitações e escopo de validade

**Natureza inferencial vs. preditiva dos modelos.** Os resultados devem ser lidos sob dois regimes epistemológicos distintos. Os modelos HLM, a decomposição de Oaxaca–Blinder, a regressão quantílica e o modelo logístico de acesso produzem *estimativas de associação condicional*: medem o diferencial racial que persiste após o controle de covariáveis observáveis, sob o pressuposto de seleção em observáveis. Não constituem, por si sós, prova de causalidade no sentido contrafactual, pois não derivam de desenho experimental ou quase-experimental. Já o XGBoost e os valores SHAP têm finalidade *preditiva e interpretativa*: quantificam a contribuição de cada variável para a *previsão* do rendimento — não o efeito causal de manipulá-la. A convergência entre os dois regimes (a raça mantém importância preditiva não desprezível e coeficiente negativo significativo sob controle exaustivo) é o que confere robustez ao diagnóstico; ainda assim, a linguagem causal foi deliberadamente evitada.

**Condicionar em quem tem renda positiva.** Todos os modelos de rendimento são estimados entre ocupados com renda positiva. Isso é *condicionar no desfecho* (Angrist e Pischke (2009), cap. 3): se a discriminação também reduz a probabilidade de estar ocupado, o gap salarial condicional mistura o efeito sobre o salário com a seleção de quem permanece na amostra. A direção provável do viés é de *subestimação*: se os trabalhadores negros que conseguem se manter ocupados são positivamente selecionados em atributos não observados, o gap entre os observados é menor que o gap potencial na população. O modelo logístico de acesso trata diretamente a outra metade do problema — a probabilidade de chegar à ocupação qualificada —; uma correção de seleção à Heckman, que exigiria uma variável de exclusão crível (algo que afete estar ocupado sem afetar o salário), fica como extensão e não é estimada aqui. A leitura correta é, portanto: o gap líquido aqui reportado é o gap *entre ocupados*, não o gap potencial de toda a população em idade ativa.

**As hipóteses, uma a uma, e o que acontece se falharem.** Seguindo a recomendação de “ser o próprio cético” (Angrist e Pischke (2009), cap. 8):

1. **Seleção em observáveis (CIA).** O gap líquido só é o efeito do tratamento diferencial se, condicional a  $X$ , a raça for “como se” aleatória. Não é: qualidade da escola, habilidade não medida e redes ficam fora. Se esses omitidos correlacionam negativamente com ser negro e positivamente com renda, o coeficiente *superestima* a discriminação — por isso o gap líquido é apresentado como limite superior dessa leitura, e o Konfound/E-value quantificam quanto de confundimento seria preciso.
2. **Bad controls.** Ocupação e formalidade são desfechos da própria discriminação; a jornada, não: com renda mensal, ela é controle necessário e entra nas duas especificações da Oaxaca-Blinder — no modelo de acesso, só no degrau de limite inferior. Com eles (M4, Oaxaca-Blinder de acesso) o resultado é um *limite inferior descritivo*: a parcela que opera pela porta de entrada some da conta. Sem eles (M3, especificação (A) da Oaxaca-Blinder) tem-se o gap total condicional a capital humano e bairro. As duas versões são reportadas lado a lado.
3. **Reflexo (Manski).** Uma média de bairro que inclui o próprio indivíduo é mecanicamente informativa sobre ele — a raça da pessoa entraria no % de negros do seu bairro. Por isso todas as médias de contexto, de UPA e de UF, são calculadas sem a própria observação (*leave-one-out*), e a renda média do bairro, a mais exposta ao problema, fica fora dos modelos estatísticos e só entra como preditor no XGBoost. Isso remove o reflexo mecânico, mas choques comuns ao bairro ainda impedem leitura causal do coeficiente contextual.
4. **Efeitos aleatórios.** O HLM e o GLMM supõem que o efeito de bairro não é

correlacionado com os regressores. Como contraprova, todos os coeficientes foram reestimados com efeitos fixos de UF e erro-padrão agrupado por UPA, com as mesmas conclusões (Subseção 3.7).

5. **Pesos e desenho amostral.** As estimativas são não ponderadas: descrevem a regressão na amostra. A robustez ponderada pelo peso da PNAD muda o gap em cerca de meio ponto percentual.
6. **Correlação intragrupo.** Ignorá-la subestimaria os erros-padrão (Moulton); todos os modelos reportam erro-padrão agrupado por UPA ou o modelam por efeito aleatório, e o agrupamento por UF usa  $t$  com  $G - 1$  graus de liberdade.
7. **Significância com  $N$  grande.** Com 7,7 milhões de observações, quase tudo é “significativo”; a leitura privilegia magnitude, intervalos de confiança e E-values, não asteriscos.

**Desenho transversal e direções futuras.** O caráter transversal do painel público impede a análise de trajetórias individuais; o painel rotativo completo com microdado identificado e a extensão à RAIS permitiriam investigar mobilidade e o teto de vidro em cargos de liderança com identificação de firma. A análise de redes de co-residência, a tipologia por agrupamento e a priorização de políticas por pesquisa operacional, desenvolvidas em versão estendida deste trabalho, ficam como agenda. Também fica como agenda o uso de texto livre: a PNAD divulga ocupação e atividade já codificadas (CBO e CNAE Domiciliar), sem o relato aberto da entrevista, de modo que técnicas de processamento de linguagem natural não têm aqui onde se aplicar. Bases que associam texto a indivíduos — descrições de cargo em registros administrativos, anúncios de vaga e currículos, como nos experimentos de auditoria (PAGER, 2007) — permitiriam medir o conteúdo das funções e a triagem na contratação, que os códigos ocupacionais não captam. A descrição oficial dos códigos não supriria essa lacuna: seria a ocupação de novo, um *bad control* no modelo de rendimento e o próprio desfecho no de acesso. Fica ainda como agenda relacionar a penalidade estimada em cada estado à presença de pretos e pardos nos cargos eletivos, que a Justiça Eleitoral registra por cor ou raça desde 2014: a sub-representação negra no comando político seria a face institucional do teto de vidro aqui medido (ALMEIDA, 2019), mas, com uma observação por estado, a comparação seria apenas ecológica.

**Declaração de uso de inteligência artificial.** Na elaboração deste trabalho foram utilizadas ferramentas de inteligência artificial (Claude Code, da Anthropic) como apoio à implementação e depuração de código (Python e R), à geração de figuras e tabelas e à formatação dos documentos. A concepção da pesquisa, a escolha das metodologias, a interpretação dos resultados e a redação final são de responsabilidade do autor, que revisou, validou e responde por todo o conteúdo.



## Referências

- ALENCAR, V. *Árvores, Redes e Ensembles I*. 2026. Apostila do MBA em Data Science e Analytics. Piracicaba: Escola Superior de Agricultura “Luiz de Queiroz”, Universidade de São Paulo.
- ALENCAR, V. *Árvores, Redes e Ensembles II*. 2026. Apostila do MBA em Data Science e Analytics. Piracicaba: Escola Superior de Agricultura “Luiz de Queiroz”, Universidade de São Paulo.
- ALENCAR, V. *Árvores, Redes e Ensembles III*. 2026. Apostila do MBA em Data Science e Analytics. Piracicaba: Escola Superior de Agricultura “Luiz de Queiroz”, Universidade de São Paulo.
- ALMEIDA, S. L. d. *Racismo Estrutural*. São Paulo: Jandaíra, 2019.
- ANGRIST, J. D.; PISCHKE, J.-S. *Mostly Harmless Econometrics: An Empiricist’s Companion*. Princeton: Princeton University Press, 2009.
- ARROW, K. J. The theory of discrimination. In: ASHENFELTER, O.; REES, A. (Ed.). *Discrimination in Labor Markets*. Princeton, NJ: Princeton University Press, 1973. p. 3–33.
- BECKER, G. S. *The Economics of Discrimination*. Chicago: University of Chicago Press, 1957.
- BICKEL, P. J.; SAKOV, A. On the choice of  $m$  in the  $m$  out of  $n$  bootstrap and confidence bounds for extrema. *Statistica Sinica*, v. 18, n. 3, p. 967–985, 2008.
- BLINDER, A. S. Wage discrimination: Reduced form and structural estimates. *Journal of Human Resources*, v. 8, n. 4, p. 436–455, 1973.
- BREIMAN, L. Random forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001.
- CAMERON, A. C.; GELBACH, J. B.; MILLER, D. L. Bootstrap-based improvements for inference with clustered errors. *The Review of Economics and Statistics*, v. 90, n. 3, p. 414–427, 2008.
- CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. San Francisco: ACM, 2016. p. 785–794.
- CRENSHAW, K. Demarginalizing the intersection of race and sex: A black feminist critique of antidiscrimination doctrine. *University of Chicago Legal Forum*, v. 1989, n. 1, p. 139–167, 1989.
- DUAN, N. Smearing estimate: A nonparametric retransformation method. *Journal of the American Statistical Association*, v. 78, n. 383, p. 605–610, 1983.
- FIRPO, S. P.; FORTIN, N. M.; LEMIEUX, T. Decomposing wage distributions using recentered influence function regressions. *Econometrics*, v. 6, n. 2, p. 28, 2018.

- FRANK, K. A.; MAROULIS, S. J.; DUONG, M. Q.; KELCEY, B. M. What would it take to change an inference? using rubin's causal model to interpret the robustness of causal inferences. *Educational Evaluation and Policy Analysis*, v. 35, n. 4, p. 437–460, 2013.
- FÁVERO, L. P.; BELFIORE, P. *Manual de Análise de Dados: estatística e machine learning com Excel, SPSS, Stata, R e Python*. 2. ed. Rio de Janeiro: GEN LTC, 2024. ISBN 9788595159921.
- GRANOVETTER, M. S. The strength of weak ties. *American Journal of Sociology*, v. 78, n. 6, p. 1360–1380, 1973.
- GÉRON, A. *Mãos à obra: aprendizado de máquina com Scikit-Learn, Keras & TensorFlow: conceitos, ferramentas e técnicas para a construção de sistemas inteligentes*. 2. ed. Rio de Janeiro: Alta Books, 2021. ISBN 9788550815480.
- HASENBALG, C. *Discriminação e Desigualdades Raciais no Brasil*. Rio de Janeiro: Graal, 1979.
- HENRIQUES, R. Desigualdade racial no brasil: Evolução das condições de vida na década de 90. *Texto para Discussão IPEA*, n. 807, 2001.
- IBGE. *Pesquisa de Orçamentos Familiares 2017–2018: análise da qualidade de vida (Índice de Perda de Qualidade de Vida)*. Rio de Janeiro, 2019.
- IBGE. *Pesquisa Nacional por Amostra de Domicílios Contínua: Notas Metodológicas*. Rio de Janeiro, 2023.
- IBGE. *Pesquisa Nacional por Amostra de Domicílios Contínua: Rendimento de Todas as Fontes 2025*. Rio de Janeiro, 2025.
- KOENKER, R.; BASSETT, G. Regression quantiles. *Econometrica*, v. 46, n. 1, p. 33–50, 1978.
- LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, v. 30, 2017.
- MANSKI, C. F. Identification of endogenous social effects: The reflection problem. *Review of Economic Studies*, v. 60, n. 3, p. 531–542, 1993.
- MARQUES, E. Redes sociais, segregação e pobreza em são paulo. *Dados: Revista de Ciências Sociais*, v. 53, n. 1, p. 5–50, 2010.
- OAXACA, R. Male-female wage differentials in urban labor markets. *International Economic Review*, v. 14, n. 3, p. 693–709, 1973.
- OAXACA, R. L.; RANSOM, M. R. Identification in detailed wage decompositions. *Review of Economics and Statistics*, v. 81, n. 1, p. 154–157, 1999.
- PAGER, D. *Marked: Race, Crime, and Finding Work in an Era of Mass Incarceration*. Chicago: University of Chicago Press, 2007.
- RAUDENBUSH, S. W.; BRYK, A. S. *Hierarchical Linear Models: Applications and Data Analysis Methods*. 2. ed. Thousand Oaks, CA: Sage, 2002.

SAMPSON, R. J.; RAUDENBUSH, S. W.; EARLS, F. Neighborhoods and violent crime: A multilevel study of collective efficacy. *Science*, v. 277, p. 918–924, 1997.

SOARES, S. Desigualdade racial de renda no brasil: 1976–2006. *Estudos Econômicos*, v. 39, n. 4, p. 803–825, 2009.

VANDERWEELE, T. J.; DING, P. Sensitivity analysis in observational research: Introducing the e-value. *Annals of Internal Medicine*, v. 167, n. 4, p. 268–274, 2017.

WILM, M. et al. *Índice de Progresso Social Brasil 2026: resumo executivo*. Belém, 2026. Disponível em: <<https://imazon.org.br/relatorios/indice-de-progresso-social-brasil-2026>>.

WILSON, W. J. *The Truly Disadvantaged: The Inner City, the Underclass, and Public Policy*. Chicago: University of Chicago Press, 1987.