

Logo ESALQ

**ESCOLA SUPERIOR DE AGRICULTURA “LUIZ
DE QUEIROZ”
UNIVERSIDADE DE SÃO PAULO**

MBA em Data Science e Analytics

**RACISMO ESTRUTURAL NO
MERCADO DE TRABALHO
BRASILEIRO: UMA ABORDAGEM
MULTINÍVEL E DE DECOMPOSIÇÃO
SALARIAL COM DADOS DA PNAD
CONTÍNUA (2016–2025)**

Ricardo Calheiros

Piracicaba, 2026

Resumo

Este trabalho investiga o *gap* salarial racial e as barreiras estruturais à progressão de carreira de profissionais negros no Brasil, combinando econometria multinível e métodos de decomposição salarial sobre a série histórica completa da Pesquisa Nacional por Amostra de Domicílios Contínua (PNAD Contínua) de 2016 a 2025 (15,9 milhões de observações brutas). A estratégia empírica articula quatro métodos complementares — modelo linear hierárquico (HLM), decomposição de Oaxaca–Blinder, regressão quantílica com decomposição RIF e modelo logístico multinível (GLMM) —, validados por *machine learning* interpretável (XGBoost + SHAP).

Um modelo linear hierárquico de dois níveis (indivíduos em bairros — UPA —, com efeitos fixos de estado) mostra que 36,9% da variância do log-rendimento está entre bairros e estima que profissionais negros recebem, em média, 19,1% a menos que brancos comparáveis em escolaridade, sexo e idade. Desse diferencial, 47,0% é mediado pelo contexto de moradia (nível 2), reduzindo o *gap* líquido — não explicado por capital humano, bairro nem estado, limite inferior da discriminação direta — a 10,2%.

A decomposição de Oaxaca–Blinder atribui 28,4% do *gap* bruto a retornos diferenciais não explicados por capital humano e contexto; quando a ocupação e a formalidade são tratadas como dotações, essa parcela cai para 16,2% — limite inferior da discriminação salarial *dentro* da ocupação, pois o acesso à ocupação é ele próprio desigual. A decomposição RIF por quantil mostra um padrão de *sticky floor*: esse componente de retorno é maior na base da distribuição (35,1% no q10) e decresce rumo ao topo (12,9% no q90). A discriminação opera, portanto, sobretudo no *acesso* às ocupações — canal que o GLMM mede diretamente.

O GLMM logístico de acesso (intercepto aleatório de UPA) confirma o teto de vidro ocupacional: controlados escolaridade, sexo, idade, estado e contexto do bairro, trabalhadores negros têm *odds* de acesso a cargo qualificado de 0,699 (IC 95% 0,696–0,702) das de brancos do mesmo bairro, que se apertam para 0,654 no topo 10% da renda; o E-value de 2,2 indica robustez a confundidores não observados. O *machine learning* (XGBoost + SHAP) corrobora, sem pressuposto de forma funcional, que a variável racial mantém contribuição negativa direta mesmo após todos os controles e que o contexto territorial figura entre os preditores de maior peso — evidência de que a segregação residencial é um canal relevante da desigualdade, e não mero atributo individual. A penalidade recai de forma agravada sobre a mulher negra, na intersecção de raça e gênero.

Palavras-chave: *gap* salarial racial; discriminação estrutural; modelos hierárquicos lineares; decomposição de Oaxaca–Blinder; regressão quantílica; teto de vidro; SHAP values; PNAD Contínua.

Abstract

This study investigates the racial wage gap and structural barriers to career progression for Black professionals in Brazil, combining multilevel econometrics and wage-decomposition methods on the full historical series of Brazil’s Continuous National Household Sample Survey (PNAD Contínua) from 2016 to 2025 (15.9 million raw observations). The empirical strategy articulates four complementary methods — a hierarchical linear model (HLM), the Oaxaca–Blinder decomposition, quantile regression with RIF decomposition, and a multilevel logistic model (GLMM) —, validated by interpretable machine learning (XGBoost + SHAP).

A two-level hierarchical linear model (individuals nested in neighbourhoods — census tracts —, with state fixed effects) shows that 36.9% of the variance of log earnings lies between neighbourhoods and estimates that Black workers earn 19.1% less than comparable White workers after controlling for education, sex, and age. Of this differential, 47.0% is mediated by residential context (level 2), leaving a *net gap* of 10.2% unexplained by human capital or context — a lower bound on direct labour-market discrimination.

The Oaxaca–Blinder decomposition attributes 28.4% of the raw gap to differential returns unexplained by human capital and context; once occupation and formality are treated as endowments, this share falls to 16.2% — a lower bound on within-occupation wage discrimination, since access to occupations is itself unequal. The quantile RIF decomposition reveals a *sticky floor*: this returns component is largest at the bottom of the distribution (35.1% at q10) and declines toward the top (12.9% at q90). Discrimination thus operates mainly on *access* to occupations — which the GLMM measures directly.

The multilevel logistic model (random intercept by census tract) confirms an occupational glass ceiling: controlling for education, sex, age, state, and neighbourhood context, Black workers face odds of accessing a qualified occupation of 0.699 (95% CI 0.696–0.702) relative to White workers from the same neighbourhood, tightening to 0.654 in the top 10% of income; an E-value of 2.2 indicates robustness to unobserved confounding. Interpretable machine learning (XGBoost + SHAP) corroborates — with no functional-form assumption — that race retains a direct negative contribution after all controls and that territorial context ranks among the strongest predictors, indicating that residential segregation is a relevant channel of inequality rather than a mere individual trait. The penalty falls most heavily on Black women, at the intersection of race and gender.

Keywords: racial wage gap; structural discrimination; hierarchical linear models; Oaxaca–Blinder decomposition; quantile regression; glass ceiling; SHAP values; PNAD Contínua.

Sumário

Em três minutos	4
1 Introdução	4
1.1 Hipóteses	5
2 Revisão de Literatura	6
2.1 Por que haveria discriminação: as duas teorias	6
2.2 Desigualdade racial no mercado de trabalho brasileiro	7
2.3 Efeitos de vizinhança e segregação residencial	7
2.4 Modelos lineares hierárquicos para dados aninhados	7
2.5 Decomposições salariais e a distribuição do gap	8
2.6 Interseccionalidade	8
2.7 Interpretabilidade em machine learning: SHAP values	8
3 Dados e Metodologia	9
3.1 Base de dados: PNAD Contínua (2016–2025)	9
3.2 Modelo Linear Hierárquico: indivíduos em bairros (UPA), com efeitos fixos de UF	10
3.3 Decomposição de Oaxaca–Blinder	11
3.4 Regressão quantílica e decomposição RIF	12
3.5 Modelo logístico multinível de acesso	12
3.6 Sensibilidade a variáveis omitidas	12
3.7 Inferência: erros-padrão agrupados, poucos clusters e pesos	12
3.8 Random Forest, XGBoost e SHAP Values	13
4 Resultados	13
4.1 Modelos Hierárquicos Lineares — Mediação Contextual do Gap	14
4.2 Modelos de Machine Learning e SHAP Values	18
4.3 Decomposição do gap por mediação contextual e ocupacional	22
4.4 Decomposição de Oaxaca–Blinder: composição <i>vs.</i> discriminação	24
4.5 Regressão Quantílica e RIF-OB: teto de vidro e <i>sticky floor</i>	25
4.6 GLMM logístico: o teto de vidro no acesso	27
4.7 Interseccionalidade: raça e gênero no acesso e no topo	31
4.8 Multicolinearidade do Modelo M4: Análise VIF	32
5 Discussão e Prescrição	32
6 Conclusão	36

Em três minutos

O contexto. Entre 2016 e 2025, um trabalhador negro ganhou em média 19,1% a menos que um branco com a mesma escolaridade, idade e sexo. A explicação usual — “é diferença de qualificação” — já está descontada nesse número.

O desequilíbrio. Esse gap não é uma coisa só. Quando se compara apenas pessoas *do mesmo bairro*, ele cai quase pela metade: 47,0% do gap transita pela segregação residencial. O que resta — 10,2% — não é explicado por capital humano, bairro ou estado. E, ao olhar quem *entra* nas ocupações qualificadas, a barreira aparece inteira: com o mesmo perfil e o mesmo bairro, a chance de um trabalhador negro ocupar um cargo qualificado é 30% menor; no décimo superior da renda, 35% menor.

A evidência. Quatro métodos independentes, sobre a população completa da PNAD Contínua (cerca de 7,7 milhões de observações em 40.969 bairros — o N exato varia com os filtros de cada método e consta da sua tabela): um modelo hierárquico que separa pessoa e bairro; a decomposição de Oaxaca–Blinder, que separa “ter características diferentes” de “receber preços diferentes”; a regressão quantílica com RIF, que mostra onde na distribuição a penalidade pesa; e um modelo logístico multinível de acesso. Um XGBoost com SHAP confirma, sem impor forma funcional, que a raça mantém contribuição própria. Os erros-padrão são agrupados por bairro, porque a PNAD amostra por conglomerados.

O que isso muda. Se o gargalo fosse escolaridade, bastaria ampliar acesso ao ensino. Os resultados dizem outra coisa: parte do gap está em *onde se consegue morar* e a maior parte da barreira está na *porta de entrada* das ocupações — que é onde a Lei 12.990/2014 e a fiscalização da Lei 9.029/1995 atuam. Educação é necessária; sozinha, insuficiente.

As três seções seguintes detalham, nesta ordem: como o bairro medeia o gap (Barreira I), quanto custa ser negro para quem já está empregado (Barreira II) e o que os números não podem dizer (Limitações).

1 Introdução

Este trabalho mostra que a desigualdade racial no mercado de trabalho brasileiro não se reduz a um desconto salarial isolado — opera como um sistema de barreiras em camadas que começa antes do primeiro salário, na porta de entrada das ocupações qualificadas, e persiste ao longo de toda a trajetória profissional. Políticas baseadas apenas em aumento de escolaridade são, portanto, necessárias, mas estruturalmente insuficientes.

O Brasil é um dos países com maior desigualdade racial de renda no mundo. Segundo a PNAD Contínua, a razão entre o rendimento médio de trabalhadores brancos e negros permanece acima de 1:1,5 ao longo de toda a série histórica disponível, persistindo mesmo quando se controlam escolaridade, experiência e setor de atividade (IBGE, 2023). A desigualdade racial no mercado de trabalho brasileiro é, portanto, não apenas uma herança colonial, mas um fenômeno reproduzido ativamente por mecanismos que a abordagem tradicional de diferenças de capital humano não é capaz de capturar (HASENBALG, 1979).

Esse hiato convive com um quadro macroestrutural recente de **avanço social com desigualdade persistente**. De um lado, a qualidade de vida avançou: entre as edições 2008 e 2018 da Pesquisa de Orçamentos Familiares (POF), o Índice de Perda de Qualidade de Vida recuou cerca de 30% (IBGE, 2019). A melhora, porém, foi proporcional entre os grupos e *não* fechou o hiato racial nem o territorial: famílias chefiadas por pessoas pretas ou pardas mantêm índice de 0,183, contra 0,122 das brancas, e o Nordeste (0,207) e o Norte (0,223) seguem muito acima do Sul (0,114). De outro lado, no rendimento, a desigualdade voltou a crescer: o Gini do rendimento domiciliar *per capita* subiu de 0,487 (2024) para 0,491 (2025), puxado pelo distanciamento do topo — a renda dos 10% mais ricos cresceu 8,7% no ano, contra 3,1% dos 10% mais pobres (IBGE, 2025). É precisamente esse padrão — progresso agregado que não dissolve a barreira racial — que este trabalho dissecou no mercado de trabalho.

A literatura empírica contemporânea identifica três canais principais de reprodução dessa desigualdade: (i) discriminação direta, isto é, diferenças de tratamento em processos de seleção e promoção com características individuais observadas (PAGER, 2007); (ii) segregação residencial e seus efeitos sobre o capital social disponível ao trabalhador — o contexto do bairro define a qualidade das redes de indicação profissional (WILSON, 1987; SAMPSON; RAUDENBUSH; EARLS, 1997); e (iii) subvalorização sistêmica do capital humano negro, pela qual um dado nível de escolaridade gera retornos financeiros menores para trabalhadores negros do que para brancos (HASENBALG, 1979; PAGER, 2007).

Este trabalho avança sobre a literatura nacional ao integrar quatro métodos complementares — modelo linear hierárquico, decomposição de Oaxaca–Blinder, regressão quantílica com decomposição RIF e modelo logístico de acesso —, validados por *machine learning* interpretável, sobre a maior base de dados longitudinal disponível no Brasil para este tema, a PNAD Contínua em sua série completa de 2016 a 2025.

1.1 Hipóteses

H1 Gap racial bruto e líquido: Profissionais negros apresentam rendimento inferior ao de brancos comparáveis após controlar por escolaridade, experiência potencial e gênero — e esse diferencial persiste após a adição de controles contextuais de nível

de bairro e de estado.

H2 Mediação pelo networking local: Uma fração significativa do *gap* racial bruto é explicada pelo contexto socioeconômico do local de moradia (composição racial da UPA, desemprego local, nível educacional médio do entorno) — capturando os efeitos indiretos da segregação residencial sobre a renda.

H3 Barreira de acesso e teto de vidro: Trabalhadores negros têm menor chance de acesso a ocupações qualificadas e ao topo da distribuição de renda do que brancos de mesmo perfil, e a penalidade salarial condicional cresce ao longo da distribuição de renda — a discriminação não é um desconto uniforme, mas um teto.

H4 Importância residual da raça nos modelos preditivos: Mesmo após controlar por educação, experiência, gênero e contexto de moradia, a variável racial mantém relevância preditiva independente, conforme medida pelos valores SHAP dos modelos de *gradient boosting*.

2 Revisão de Literatura

2.1 Por que haveria discriminação: as duas teorias

A economia do trabalho oferece duas explicações concorrentes para um diferencial salarial que sobrevive ao controle de produtividade observável, e elas importam porque implicam políticas distintas. Becker (1957) propôs a discriminação *por preferência*: empregadores, colegas ou clientes têm uma desutilidade em transacionar com o grupo minoritário e, por isso, só o contratam a um salário menor. A previsão desse modelo é que a concorrência erode a discriminação — empresas que discriminam pagam mais caro pela mesma produtividade e tendem a ser expulsas do mercado. Arrow (1973) formalizou a alternativa: a discriminação *estatística*, em que o empregador, diante de informação imperfeita sobre a produtividade individual, usa a raça como sinal da média do grupo. Aqui a concorrência não corrige nada; ao contrário, o equilíbrio se autoconfirma, porque o menor retorno esperado desestimula o investimento em qualificação por parte do grupo discriminado.

A distinção tem consequência direta para a leitura dos resultados deste trabalho. O componente de *retornos* da decomposição de Oaxaca–Blinder é compatível com as duas teorias, e os dados observacionais aqui usados não permitem separá-las — uma limitação assumida explicitamente (Seção 6). O que os dados permitem é testar uma implicação comum às duas: se a barreira opera sobretudo no *acesso* às ocupações, e não apenas no preço pago dentro delas, então políticas de qualificação isoladas serão insuficientes sob qualquer das duas hipóteses teóricas.

A tradição brasileira acrescenta uma terceira leitura. Almeida (2019) argumenta que o racismo não é desvio individual nem falha informacional, mas processo estrutural: as instituições reproduzem a desigualdade racial por mecanismos que independem da intenção dos agentes — o que desloca a pergunta de “quem discrimina” para “que arranjos produzem o resultado desigual”. É essa leitura que justifica investigar a segregação residencial e a segregação ocupacional como mecanismos, e não como controles.

2.2 Desigualdade racial no mercado de trabalho brasileiro

Hasenbalg (1979) demonstrou pioneiramente que a desigualdade racial no Brasil não decorre apenas de diferenças históricas de acesso à educação, mas de mecanismos ativos de discriminação no mercado de trabalho que convertem desvantagens sociais em desvantagens econômicas de forma cumulativa. Henriques (2001) documentou, para a década de 1990, que a escolaridade média de trabalhadores negros era de cerca de dois anos a menos que a de brancos e que essa diferença explicava apenas parte do diferencial de rendimentos. Soares (2009), cobrindo 1976–2006, estimou por decomposição que em torno de metade do gap racial de rendimentos não era explicada por características observáveis — parcela que sua análise atribui a discriminação salarial e a diferenças de qualidade da educação recebida. Esses são os parâmetros de referência com que os resultados deste trabalho dialogam na Seção 5; a comparação exige cautela, porque a magnitude do componente não explicado depende de quais controles se tratam como dotações (ver Seção 3.3).

2.3 Efeitos de vizinhança e segregação residencial

Wilson (1987) propôs a hipótese da *concentrated disadvantage*: a concentração de pobreza em bairros racialmente segregados amplifica desvantagens individuais por meio da redução de redes de contato com o mercado de trabalho formal, degradação de serviços públicos e aumento da violência. Sampson, Raudenbush e Earls (1997) forneceu evidência empírica para essa hipótese em contexto norte-americano, e estudos brasileiros encontraram padrões similares para as regiões metropolitanas (MARQUES, 2010).

A abordagem de *networking* local, operacionalizada neste trabalho pelo segundo nível do modelo hierárquico (UPA), testa se o contexto socioeconômico do bairro exerce efeito independente sobre o rendimento após controlar por características individuais — o chamado *duplo disadvantage* de ser negro e morar em bairros negros.

2.4 Modelos lineares hierárquicos para dados aninhados

Raudenbush e Bryk (2002) sistematizaram a fundamentação estatística dos modelos lineares hierárquicos (HLM), tornando-os o padrão metodológico para análise de dados

com estrutura aninhada (indivíduos dentro de bairros dentro de estados). Esses modelos permitem decompor a variância do desfecho em componentes de cada nível e estimar os efeitos contextuais controlando simultaneamente pelos efeitos individuais.

2.5 Decomposições salariais e a distribuição do gap

O instrumental que separa “ter características diferentes” de “receber preços diferentes” vem de Oaxaca (1973) e Blinder (1973), que propuseram, de forma independente, decompor a diferença de médias entre dois grupos em uma parcela de *dotações* — atribuível a diferenças nas características observáveis — e outra de *retornos*, atribuível a diferenças nos coeficientes com que essas características são remuneradas. Oaxaca e Ransom (1999) mostraram, porém, que a repartição não é única: ela depende de quais variáveis se admite como dotação. Tratar a ocupação como característica do trabalhador desloca para a parcela explicada toda a desigualdade que opera pela porta de entrada da ocupação — razão pela qual este trabalho reporta as duas especificações lado a lado.

A decomposição de médias, contudo, descreve apenas o trabalhador médio. Koenker e Bassett (1978) introduziram a regressão quantílica, que estima o efeito de um regressor em cada ponto da distribuição condicional e permite verificar se a penalidade racial é uniforme ou se cresce rumo ao topo — a formulação estatística do teto de vidro. Firpo, Fortin e Lemieux (2018) estenderam a decomposição para quantis *incondicionais* por meio de regressões da função de influência recentrada (RIF), respondendo a uma pergunta distinta: de que é feito o gap em um dado ponto da distribuição de renda do país, e não da distribuição condicional a um perfil. As duas leituras são complementares e, como se verá, apontam para padrões aparentemente opostos que descrevem o mesmo fenômeno (Seção 4.5).

2.6 Interseccionalidade

Crenshaw (1989) cunhou o conceito de interseccionalidade a partir da constatação de que a experiência de mulheres negras não é descrita pela soma das categorias “mulher” e “negra”: há um efeito próprio da posição na interseção dos eixos, que análises que tratam raça e gênero separadamente não capturam. Empiricamente, isso implica testar se o diferencial do grupo excede a soma dos diferenciais isolados — e, portanto, se políticas desenhadas para um eixo de cada vez deixam de fora justamente quem está na interseção.

2.7 Interpretabilidade em machine learning: SHAP values

Lundberg e Lee (2017) propuseram os *SHapley Additive exPlanations* (SHAP), unificando importância de variáveis, efeitos parciais e explicações individuais em uma única estrutura axiomática baseada na teoria dos jogos cooperativos. Para dados socioeconô-

nicos, SHAP permite responder à pergunta: “quanto e em que direção a raça de um indivíduo específico afeta a predição de sua renda?” — uma contribuição metodológica que complementa e enriquece a interpretação dos coeficientes do HLM.

3 Dados e Metodologia

3.1 Base de dados: PNAD Contínua (2016–2025)

A PNAD Contínua é uma pesquisa amostral de domicílios conduzida trimestralmente pelo IBGE, com cobertura nacional e metodologia de painel rotativo. O microdado contém informações sobre características demográficas, escolaridade, inserção no mercado de trabalho e rendimentos para todos os moradores dos domicílios selecionados. Para este trabalho, foram processados todos os 40 trimestres disponíveis de 2016T1 a 2025T4, totalizando 15.941.675 observações brutas, das quais 7.694.198 possuem renda positiva declarada e completude nas variáveis do modelo.

A classificação racial segue o critério binário adotado pelos estudos de desigualdade racial no Brasil: *negro* = preto (código 2) + pardo (código 4); *branco* = branco (código 1), ambos da variável V2010 (cor ou raça autodeclarada).

De que é feita a comparação: balanceamento e suporte comum. Antes de qualquer controle, convém olhar em que brancos e negros diferem — é o que mostra a Tabela 1. O maior desequilíbrio não está em escolaridade nem em horas: está em *onde se mora*. A composição racial do bairro tem diferença padronizada de $-1,18$ desvios — uma ordem de grandeza acima de qualquer variável individual —, seguida do desemprego local ($-0,46$) e da educação média do entorno ($-0,30$). É esse desequilíbrio que o nível 2 do modelo hierárquico absorve. As *dummies* de escolaridade, por sua vez, são condicionais ao registro da variável, cuja cobertura difere entre os grupos (73,7% contra 65,3% de não registro); por isso o indicador `educ_missing` entra em todos os modelos e os retornos educacionais são lidos com a cautela registrada nas limitações. O suporte comum é amplo: 97,3% das UPAs abrigam trabalhadores dos dois grupos e todas as células UF $\times$ escolaridade contêm brancos e negros, de modo que a comparação não depende de extrapolação (ANGRIST; PISCHKE, 2009).

Tabela 1: Balanceamento entre trabalhadores brancos e negros *antes* de qualquer controle — a tabela que mostra de que é feita a comparação (Angrist & Pischke, cap. 3). Diferença padronizada: $d = (\bar{x}_b - \bar{x}_n)/\sqrt{(s_b^2 + s_n^2)/2}$; valores acima de 0,10 em módulo indicam desequilíbrio relevante. População completa da PEA com renda positiva ($N = 7.694.198$; 3.259.516 brancos e 4.434.682 negros).

Variável	Brancos	Negros	Diferença	d
log do rendimento	7,577	7,151	0,425	0,47
Idade (centrada)	-1,638	-3,110	1,472	0,11
Sexo feminino	0,437	0,399	0,038	0,08
Fundamental completo	0,003	0,009	-0,006	-0,07
Médio completo	0,046	0,041	0,006	0,03
Superior completo	0,198	0,278	-0,080	-0,19
Pós-graduação	0,006	0,009	-0,004	-0,04
Escolaridade não registrada	0,737	0,653	0,084	0,18
log(horas trabalhadas)	3,644	3,598	0,045	0,11
Reside em área urbana	0,813	0,773	0,039	0,10
Emprego formal	0,493	0,439	0,054	0,11
Conta própria	0,277	0,282	-0,006	-0,01
Trabalho doméstico	0,049	0,079	-0,030	-0,12
CBO: dirigente	0,055	0,023	0,032	0,16
CBO: profissional	0,149	0,079	0,071	0,22
CBO: técnico	0,090	0,066	0,023	0,09
% negro na UPA (z)	-0,705	0,335	-1,040	-1,18
Desemprego na UPA (z)	-0,327	0,093	-0,420	-0,46
Educ. média na UPA (z)	-0,133	0,165	-0,298	-0,30

Suporte comum: 97,3% das UPAs têm trabalhadores dos dois grupos, e 100,0% das células UF $\times$ escolaridade também (100,0% das observações estão em células com os dois grupos) — a comparação não depende de extrapolar para regiões da amostra onde só existe um dos grupos.

3.2 Modelo Linear Hierárquico: indivíduos em bairros (UPA), com efeitos fixos de UF

A PNAD Contínua é amostrada por conglomerados: pessoas dentro de unidades primárias de amostragem (UPA, o proxy de bairro), dentro de estados. A hipótese substantiva do trabalho (H2) é que o *bairro* media parte do gap racial; o modelo, portanto, coloca a UPA no nível 2 e trata a UF como conjunto de efeitos fixos — 27 unidades são poucas para um terceiro nível aleatório (ANGRIST; PISCHKE, 2009), e os 26 *dummies* absorvem todo o contexto estadual sem hipóteses distribucionais. O modelo de dois níveis é:

Nível 1 — indivíduo i na UPA j :

$$\ln(W)_{ij} = \beta_{0j} + \beta_1 \text{Negro}_{ij} + \beta_2 \text{Sexo}_{ij} + \beta_3 X_{ij} + \beta_4 X_{ij}^2 + \sum_e \beta_e \text{Educ}_{e,ij} + \beta'_5 \mathbf{Z}_{ij} + \varepsilon_{ij}, \quad \varepsilon_{ij} \sim \mathcal{N}(0, \sigma^2) \quad (1)$$

em que $\mathbf{Z}$ reúne horas, situação urbana e ano (e, no M4, vínculo e grupo CBO).

Nível 2 — bairro j (UPA):

$$\beta_{0j} = \gamma_{00} + \gamma_{01} \overline{\%Negro_j} + \gamma_{02} \overline{Desemprego_j} + \gamma_{03} \overline{Educ_j} + \sum_{k=2}^{27} \delta_k \overline{UF_{k(j)}} + u_{0j}, \quad u_{0j} \sim \mathcal{N}(0, \tau_{UPA}^2) \quad (2)$$

O coeficiente $\gamma_{01} < 0$ é a evidência de *duplo disadvantage*: morar em bairros com maior concentração de negros reduz o rendimento *independentemente* da raça individual. A correlação intraclasse

$$\rho_{UPA} = \frac{\tau_{UPA}^2}{\tau_{UPA}^2 + \sigma^2} \quad (3)$$

mede a fração da variância do log-rendimento que está *entre* bairros; valores acima de 5% justificam o modelo multinível (RAUDENBUSH; BRYK, 2002).

Estratégia *step-up*. Seguindo Raudenbush e Bryk (2002), os modelos são estimados em degraus aninhados: M0 (nulo: só o intercepto aleatório, que dá o ICC); M1 (+ capital humano e demografia); M2 (+ contexto do bairro, nível 2); M3 (+ efeitos fixos de UF) — o modelo principal, que produz o **gap líquido**; e M4 (+ vínculo e grupo ocupacional), reportado como *limite inferior* porque ocupação e formalidade são desfechos da própria discriminação (*bad controls*, Angrist e Pischke (2009)). Cada degrau é comparado ao anterior por teste de razão de verossimilhança (LR), e a redução de τ_{UPA}^2 em relação ao M0 mede a variância entre bairros explicada pelos controles. Testa-se ainda uma *inclinação aleatória* de **negro** por UPA (M3 + $u_{1j} \text{Negro}_{ij}$, com covariância não estruturada) — a penalidade racial varia entre bairros? — por LR com dois graus de liberdade. Todos os modelos são estimados por máxima verossimilhança (ML), necessária para comparar efeitos fixos entre degraus; com $N = 7,7$ milhões, REML e ML produzem os mesmos componentes de variância (no M0, $\hat{\tau}_{UPA}^2 = 0,33698$ por ML e 0,33699 por REML; ICC idêntico até a quarta casa). A

3.3 Decomposição de Oaxaca–Blinder

Estimam-se equações de rendimento separadas para brancos e negros e decompõe-se a diferença de médias na forma *twofold* (OAXACA, 1973; BLINDER, 1973), tomando a estrutura de preços dos brancos como referência não discriminatória: $\ln \bar{W}_B - \ln \bar{W}_N = (\bar{X}_B - \bar{X}_N)' \hat{\beta}_B + \bar{X}_N' (\hat{\beta}_B - \hat{\beta}_N)$, em que o primeiro termo é a parcela de dotações e o segundo, a de retornos. Duas especificações são reportadas: (A) apenas capital humano e contexto de bairro, comparável à literatura; e (B) acrescentando horas, formalidade e grupo ocupacional como dotações. Como adverte Oaxaca e Ransom (1999), a especificação (B) subestima a discriminação total, porque a segregação ocupacional é ela própria seu produto — por isso ela é lida como limite inferior, e não como a estimativa preferida. Os erros-padrão vêm de bootstrap em blocos de UPA, e não da fórmula analítica, que

pressupõe independência entre observações (CAMERON; GELBACH; MILLER, 2008).

3.4 Regressão quantílica e decomposição RIF

A regressão quantílica (KOENKER; BASSETT, 1978) estima $\hat{\beta}(\tau)$ em cinco pontos da distribuição condicional ($\tau \in \{0,10; 0,25; 0,50; 0,75; 0,90\}$), permitindo testar se a penalidade racial é constante ao longo da distribuição. O teste de igualdade entre os quantis extremos usa bootstrap *m-out-of-n* em blocos de UPA, com reescala $\sqrt{m/G}$ (BICKEL; SAKOV, 2008) — necessária porque reamostrar todas as 40.969 UPAs a cada réplica seria proibitivo com 7,7 milhões de observações. Complementarmente, a decomposição RIF (FIRPO; FORTIN; LEMIEUX, 2018) é aplicada aos quantis incondicionais da distribuição de renda, separando dotações e retornos em cada ponto.

3.5 Modelo logístico multinível de acesso

A barreira de entrada é modelada por um GLMM logístico com intercepto aleatório de UPA, estimado por `lme4::glmer` em R, para três desfechos binários: ocupar cargo qualificado (grupos CBO 1–4), estar no quintil superior e estar no decil superior da renda. A estrutura multinível é a mesma do HLM (RAUDENBUSH; BRYK, 2002), agora com função de ligação logit; o ICC do nível de bairro é calculado por $\tau^2/(\tau^2 + \pi^2/3)$, a formulação de variância latente apropriada ao modelo logístico. Além da razão de chances, reporta-se o efeito marginal médio em pontos percentuais, porque a razão de chances não é interpretável como diferença de probabilidade.

3.6 Sensibilidade a variáveis omitidas

A hipótese de seleção em observáveis não é testável, mas é possível quantificar quanto de confundimento não observado seria necessário para anular os resultados. Reportam-se duas medidas: o *E-value* (VANDERWEELE; DING, 2017), que é a associação mínima — em razão de chances — que um confundidor precisaria ter simultaneamente com a raça e com o desfecho para explicar o efeito observado; e o índice de Frank et al. (2013), que expressa a fração da estimativa que precisaria ser viés para invalidar a inferência.

3.7 Inferência: erros-padrão agrupados, poucos clusters e pesos

A PNAD Contínua é uma amostra por conglomerados: pessoas da mesma unidade primária de amostragem (UPA, proxy de bairro) compartilham choques não observados, e os regressores de contexto variam apenas no nível da UPA. Tratar as 7,7 milhões de observações como independentes subestima os erros-padrão pelo fator de Moulton $\sqrt{1 + (\bar{n} - 1)\rho}$ (ANGRIST; PISCHKE, 2009). Por isso, todos os modelos de regressão

(OLS com efeitos fixos de UF, decomposição de Oaxaca–Blinder, regressão quantílica e logit) reportam erros-padrão *agrupados por UPA* (41.517 clusters) — para a OB e a regressão quantílica, por bootstrap em blocos de UPA. O agrupamento por UF é mais conservador, mas com 27 clusters (< 42) a inferência assintótica é pouco confiável (ANGRIST; PISCHKE, 2009); quando reportado, usa a distribuição t com $G - 1$ graus de liberdade. No HLM, o intercepto aleatório de UPA modela explicitamente a correlação intra-bairro, de modo que o erro-padrão do modelo já a incorpora (sob a hipótese de efeitos aleatórios); como contraprova, os coeficientes do HLM são comparados aos do OLS com efeitos fixos de UF e erro-padrão agrupado por UPA, que coincidem em sinal, magnitude e significância. No OLS com efeitos fixos de UF (especificação do M3), o erro-padrão de $\hat{\beta}_{\text{negro}}$ passa de 0,0006 (convencional) para 0,0011 (agrupado por UPA) e 0,0035 (agrupado por UF); para o regressor de contexto $\overline{\% \text{Negro}}_{\text{UPA}}$, que varia apenas no nível da UPA, a razão é de $7,3\times$ (UPA) e $51,9\times$ (UF) — a assinatura do efeito Moulton. Como $|\hat{\beta}_{\text{negro}}|/\text{SE}$ permanece acima de 29 mesmo no agrupamento mais conservador, nenhuma conclusão sobre o gap racial depende da escolha do erro-padrão; a correção importa para os coeficientes contextuais e para as variáveis de UF.

Pesos amostrais. Os modelos são estimados sem o peso amostral da PNAD (V1028), isto é, descrevem a regressão na amostra, não a regressão populacional (ANGRIST; PISCHKE, 2009). Como robustez, o M3 foi reestimado por mínimos quadrados ponderados com V1028 e erro-padrão agrupado por UPA: $\hat{\beta}_{\text{negro}}$ passa de -0,1009 para -0,0967 (gap de 9,6% para 9,2%), diferença sem relevância econômica; os demais resultados são não ponderados.

3.8 Random Forest, XGBoost e SHAP Values

Para predição do log-rendimento, foram ajustados dois modelos de ensemble: (i) *Random Forest* (BREIMAN, 2001) com 200 árvores e profundidade máxima 10; e (ii) *XGBoost* (CHEN; GUESTRIN, 2016) com 300 iterações, taxa de aprendizado 0,05, profundidade máxima 10 e regularização L_1/L_2 . A profundidade foi escolhida por validação cruzada (Tabela 5), e não por conveniência; os dois modelos usam o mesmo conjunto de *features* e a mesma partição de teste. Sobre o modelo XGBoost, foi aplicado o *TreeExplainer* da biblioteca SHAP (LUNDBERG; LEE, 2017) sobre um subsample de 50.000 observações para calcular os valores de Shapley de cada feature.

4 Resultados

As evidências deste capítulo estão organizadas em duas camadas de exclusão — duas barreiras que operam em sequência e se reforçam mutuamente. O leitor não encon-

trará aqui um catálogo de modelos estatísticos: encontrará a trajetória de um trabalhador negro no mercado de trabalho brasileiro, documentada com rigor empírico em cada etapa.

Tabela 2: Mapa das duas camadas de exclusão racial — guia de leitura

Camada	Pergunta central e evidência
BARREIRA I Acesso e Segregação	Por que negros raramente chegam às ocupações de prestígio? O GLMM de acesso e o HLM contextual mostram que a exclusão começa antes do salário.
BARREIRA II Penalidade e Teto de Vidro	Para os que superam a barreira de entrada — qual é o custo de ser negro? Gap líquido de 10,2% (M3) e de 7,0% dentro da mesma ocupação (M4), crescendo nos quantis mais altos ($Z = -16,95$, $p < 0,001$).

Cada seção a seguir documenta empiricamente uma dessas camadas. Nenhum método isolado teria identificado o sistema como um todo.

BARREIRA I — ACESSO E SEGREGAÇÃO ESTRUTURAL

Como a exclusão começa antes do primeiro salário

4.1 Modelos Hierárquicos Lineares — Mediação Contextual do Gap

Esta seção documenta como o território amplifica o gap racial: o bairro de moradia não é apenas contexto — é parte do mecanismo de exclusão.

A Tabela 3 apresenta os cinco degraus da estratégia *step-up*, do modelo nulo (M0) ao modelo com ocupação (M4), todos com intercepto aleatório por UPA e estimados por máxima verossimilhança sobre a população completa. *Como ler:* acompanhe a linha **Raça (negro)** da esquerda para a direita — cada coluna acrescenta um bloco de controles e o coeficiente se aproxima de zero; as linhas de baixo dizem quanto da variância entre bairros cada bloco explica e se o degrau melhora o ajuste (LR).

Quanto da renda é “bairro”: o modelo nulo. O M0 estima $\hat{\tau}_{UPA}^2 = 0,3370$ e $\hat{\sigma}^2 = 0,5759$, ou seja, $ICC_{UPA} = 0,369$: **36,9% da variância do log-rendimento está entre bairros**, muito acima do limiar de 5% de Raudenbush e Bryk (2002) e da parcela entre estados (cerca de 10%, no modelo alternativo com UF aleatória usado como robustez). A estrutura aninhada não é um detalhe técnico: ignorá-la trataria como independentes pessoas que compartilham o mesmo mercado de trabalho local.

Gap agregado vs. gap dentro do bairro (M1). Com escolaridade, idade, sexo, horas, situação urbana e ano, mas *sem* nenhum efeito de bairro (OLS com efeitos fixos de UF, Subseção 3.7), trabalhadores negros recebem 19,1% a menos que brancos comparáveis ($\hat{\beta} = -0,2123$). O M1 acrescenta o intercepto aleatório de UPA e passa a comparar negros e brancos *do mesmo bairro*: $\hat{\beta}_{\text{negro}}^{M1} = -0,1124$ (IC 95%: $[-0,1135; -0,1113]$), ou **10,6% a menos**. A diferença entre os dois — **47,0% do gap agregado** — é a parcela do gap racial que transita pela segregação residencial: negros e brancos com o mesmo capital humano não moram nos mesmos bairros, e os bairros pagam diferente. Esse é o teste da Hipótese H2. Os controles individuais explicam, além disso, 55,2% da variância entre bairros do M0: parte do que parecia “bairro” é composição de quem mora nele.

O que faz de um bairro um bairro (M2). As três covariáveis de nível 2 explicam 40,1% da variância entre bairros que restava no M1 ($\hat{\tau}^2$ de 0,1509 para 0,0903; LR = 19.536, 3 g.l., $p < 0,001$). O coeficiente de composição racial, $\hat{\gamma}_{01} = -0,2189$ (SE 0,0017), indica que um desvio-padrão a mais na proporção de negros da UPA reduz o log-rendimento de *todos* os moradores em 0,22 pontos — da mesma ordem da penalidade individual — a evidência mais direta do *duplo disadvantage*. O coeficiente individual mal se move ($\hat{\beta}_{\text{negro}}^{M2} = -0,1076$): dentro do bairro, a penalidade racial não depende de quem são os vizinhos; o bairro opera pela *porta de entrada* (onde se consegue morar), não pelo salário de quem já está lá.

Gap líquido (M3). Com os efeitos fixos de UF, $\hat{\beta}_{\text{negro}}^{M3} = -0,1077$ (IC 95%: $[-0,1087; -0,1066]$): o **gap líquido de 10,2%** é o diferencial que capital humano, contexto de bairro e estado não explicam — limite inferior da discriminação direta sob seleção em observáveis. O ICC cai para 0,144 e os controles explicam 78,9% da variância entre bairros do M0.

Dentro da mesma ocupação (M4). Acrescentar vínculo e grupo CBO leva a $\hat{\beta}_{\text{negro}}^{M4} = -0,0724$ (7,0%). A queda adicional — 16,6% do gap agregado — não é “explicação”, é *canal*: a ocupação é ela própria resultado da barreira de acesso (Seção 4.6), por isso o M4 é um limite inferior descritivo.

A penalidade varia entre bairros. A inclinação aleatória de **negro** por UPA é significativa (LR = 38.657, 2 g.l., $p < 0,001$): $\hat{\tau}_1^2 = 0,0293$, desvio-padrão de 0,171 log-pontos. Em bairros a um desvio-padrão da média a penalidade vai de $-0,280$ a $0,063$ log-pontos — a discriminação salarial tem geografia, e a covariância intercepto-inclinação de $-0,0245$ indica que a penalidade é maior nos bairros de renda-base mais alta.

Como ler a Figura 1: cada ponto à esquerda é um estado; a largura do histograma à direita é o quanto a renda-base muda de um bairro para outro, já descontados capital




Figura 1: A variação entre bairros supera a variação entre estados. À esquerda, os efeitos fixos de UF do M3 com IC 95% (referência: primeira UF); à direita, a distribuição dos interceptos aleatórios das UPAs (u_{0j} , BLUPs do M3).

humano, contexto e estado.

Viés de variável omitida e sensibilidade. O coeficiente racial é uma associação condicional: pela fórmula do viés de variável omitida (ANGRIST; PISCHKE, 2009), o coeficiente “curto” iguala o “longo” mais o efeito do omitido vezes sua relação com a raça. Qualidade da escola, habilidade não observada e redes de contato correlacionam-se negativamente com ser negro e positivamente com a renda: omiti-las *superestima* a penalidade — o que faz do M3 um limite superior para o efeito de tratamento diferencial condicional a essas características. Na direção oposta, os controles que são desfechos (ocupação no M4) *subestimam*. O gap líquido deve ser lido entre esses dois limites. Para anular $\hat{\beta}_{\text{negro}}^{M3}$ seria preciso um viés de 99,0% do coeficiente (Konfound, Frank et al. (2013)), e o E-value do modelo de acesso (Tabela 11) exige um confundidor associado à raça e ao desfecho com razão de risco $\geq 2,2$ — mais forte que qualquer covariável observada.

Tabela 3: HLM de dois níveis (indivíduo em UPA) com efeitos fixos de UF — estratégia *step-up*, PNAD Contínua 2016–2025, população completa ($N = 7.689.426$; 40.295 UPAs; 27 UFs). Coeficientes com erro-padrão do modelo entre parênteses (a correlação intra-UPA já está no efeito aleatório). Estimação por máxima verossimilhança (ML), para os testes LR entre degraus; REML coincide. Todos os coeficientes com $|t| > 10$; a inferência relevante está nos intervalos de confiança, não nos asteriscos (MHE, cap. 8).

Variável	M0	M1	M2	M3	M4
Intercepto	7,3022 (0,0029)	4,2579 (0,0051)	4,2885 (0,0046)	4,5538 (0,0116)	4,7525 (0,0093)
Raça (negro)	—	−0,1124 (0,0006)	−0,1076 (0,0006)	−0,1077 (0,0006)	−0,0724 (0,0005)
Sexo feminino	—	−0,1944 (0,0005)	−0,1945 (0,0005)	−0,1945 (0,0005)	−0,2190 (0,0005)
Idade (centrada)	—	0,0087 (2,1e-05)	0,0087 (2,1e-05)	0,0087 (2,1e-05)	0,0092 (1,9e-05)
Idade ²	—	−0,0005 (1,2e-06)	−0,0005 (1,2e-06)	−0,0005 (1,2e-06)	−0,0004 (1,1e-06)
<i>Escolaridade (ref.: fundamental incompleto)</i>					
Educ.: fundamental completo	—	−0,2007 (0,0038)	−0,2002 (0,0038)	−0,1986 (0,0038)	−0,1821 (0,0034)
Educ.: médio completo	—	−0,0537 (0,0027)	−0,0545 (0,0027)	−0,0547 (0,0027)	−0,0438 (0,0024)
Educ.: superior completo	—	0,0521 (0,0025)	0,0521 (0,0025)	0,0523 (0,0025)	0,0537 (0,0023)
Educ.: pós-graduação	—	−0,0034 (0,0036)	−0,0033 (0,0036)	−0,0030 (0,0036)	−0,0043 (0,0033)
Educ.: não registrada	—	0,4228 (0,0025)	0,4233 (0,0025)	0,4237 (0,0025)	0,2194 (0,0023)
<i>Inserção</i>					
log(horas)	—	0,6823 (0,0006)	0,6818 (0,0006)	0,6815 (0,0006)	0,5979 (0,0006)
Urbano	—	0,4348 (0,0045)	0,3771 (0,0036)	0,3347 (0,0033)	0,2026 (0,0026)
<i>Contexto de bairro — nível 2 (UPA)</i>					
% negro na UPA (z)	—	—	−0,2189 (0,0017)	−0,2508 (0,0025)	−0,1812 (0,0020)
Desemprego na UPA (z)	—	—	−0,0542 (0,0016)	−0,0338 (0,0015)	−0,0275 (0,0012)
Educ. média na UPA (z)	—	—	0,0055 (0,0013)	−0,0052 (0,0012)	0,0054 (0,0010)
<i>Ocupação e vínculo (M4; bad controls)</i>					
Emprego formal	—	—	—	—	0,1776 (0,0006)
Conta própria	—	—	—	—	−0,1725 (0,0007)
Trab. doméstico	—	—	—	—	−0,1272 (0,0010)
CBO: dirigente	—	—	—	—	0,7777 (0,0013)
CBO: profissional	—	—	—	—	0,8720 (0,0010)
CBO: técnico	—	—	—	—	0,5009 (0,0010)
CBO: administrativo	—	—	—	—	0,2639 (0,0010)
CBO: serviços	—	—	—	—	0,1832 (0,0008)
CBO: agropecuária	—	—	—	—	0,0892 (0,0011)
CBO: operário	—	—	—	—	0,1976 (0,0009)
CBO: operador	—	—	—	—	0,2294 (0,0010)
CBO: FFAA	—	—	—	—	0,9199 (0,0024)
IC 95% de β_{negro}	—	[−0,1135; −0,1113]	[−0,1087; −0,1065]	[−0,1087; −0,1066]	[−0,0734; −0,0714]
Gap (%) = $e^{\beta} - 1$	—	−10,6	−10,2	−10,2	−7,0
Efeitos fixos de UF	não	não	não	sim	sim
<i>Componentes de variância e ajuste</i>					
$\hat{\tau}_{\text{UPA}}^2$ (nível 2)	0,3370	0,1509	0,0903	0,0712	0,0430
$\hat{\sigma}^2$ (nível 1)	0,5759	0,4244	0,4244	0,4244	0,3440
ICC _{UPA}	0,369	0,262	0,175	0,144	0,111
τ^2 explicada vs. M0 (%)	—	55,2	73,2	78,9	87,2
−2LL (deviance)	17.751.140	15.384.825	15.365.289	15.356.451	13.729.450
AIC	17.751.146	15.384.871	15.365.341	15.356.555	13.729.578
BIC	17.751.187	15.385.190	15.365.702	15.357.275	13.730.465
LR vs. degrau anterior (χ^2 , g.l.)	—	2.366.315 (20)	19.536 (3)	8.838 (26)	1.627.001 (12)
p do LR	—	< 0,001	< 0,001	< 0,001	< 0,001

Inclinação aleatória de negro por UPA ($M3 + u_{1j}$): $\hat{\tau}_1^2 = 0,0293$ (DP = 0,171 em log-pontos), cov(u_0, u_1) = −0,0245; LR = 38.657 (2 g.l.), $p < 0,001$: a penalidade racial varia entre bairros; $\hat{\beta}_{\text{negro}}$ médio = −0,1085.

4.2 Modelos de Machine Learning e SHAP Values

A Tabela 4 apresenta o desempenho preditivo dos dois modelos sobre o conjunto de teste (*hold-out* 20%).

Tabela 4: Desempenho preditivo — Random Forest, XGBoost e XGBoost sem renda de vizinhança (robustez ao problema do reflexo). *Hold-out* 20% da população ($N_{\text{teste}} \approx 1,54$ milhão).

Modelo	R^2	MAE	RMSE	Gap treino–teste
Random Forest	0,5689	0,4557	0,6070	0,0015
XGBoost	0,6280	0,4218	0,5639	0,0090
XGBoost (sem renda da UPA)	0,5983	0,4402	0,5860	0,0092

Como ler a Tabela 4: R^2 mais alto = melhor previsão; o *gap* treino–teste próximo de zero indica ausência de sobreajuste.

O R^2 de teste de 0,62 (XGBoost) é elevado para dados de rendimento individual, onde a variância não observada (setor, cargo, tempo de serviço) responde pela maior parte do resíduo.

Escolha de hiperparâmetros e validação cruzada. A profundidade das árvores, a taxa de aprendizado e o número de iterações não foram fixados por conveniência: seis configurações foram comparadas numa partição de validação *dentro* do conjunto de treino — o teste permanece intocado —, e a vencedora foi submetida a validação cruzada *k-fold* ($k = 5$) no treino completo (Tabela 5). A configuração escolhida (profundidade 10) alcança $R^2 = 0,6281 \pm 0,0007$ entre os *folds*, contra $0,6143 \pm 0,0007$ da profundidade 6 usada na versão anterior deste trabalho, sem aumentar o sobreajuste. O desvio-padrão entre *folds* na quarta casa decimal mostra que, com 6.155.355 observações de treino, o desempenho não depende de qual parte dos dados é usada para validar — a validação cruzada aqui serve menos para estimar incerteza e mais para justificar a especificação.

O erro na unidade original. Os modelos preveem o *logaritmo* do rendimento; para o leitor, o que importa é o erro em reais. Retransformando com a correção de Duan (1983) (fator de *smearing* = 1,178), o erro mediano de previsão é de **R\$ 538 por mês**, ou 37% do rendimento observado — a ordem de grandeza que se deve ter em mente ao ler o R^2 : o modelo acerta a posição relativa das pessoas muito melhor do que o valor exato do salário de cada uma.

Ausência de sobreajuste (população completa). Estimado sobre a população ($N = 7.694.198$; treino 80%/teste 20%), o método não-paramétrico não apresenta *overfitting*: o R^2 de treino e de teste praticamente coincidem (*gap* = 0,0090 para o XGBoost e para o Random Forest). Três evidências convergem: o *gap* treino–teste ≈ 0 ; a razão $N \gg$ comple-

Tabela 5: Escolha de hiperparâmetros e validação cruzada do XGBoost (Alencar, 2024; Géron, 2021). Painel A: seis configurações comparadas numa partição de validação *dentro* do treino — o conjunto de teste permanece intocado. Painel B: validação cruzada k -fold ($k = 5$) no treino completo, com média e desvio-padrão entre *folds*. População completa: 6.155.355 observações de treino e 1.538.839 de teste; nenhuma amostragem.

A. Busca na partição de validação					
Profundidade	Taxa de aprendizado	Árvores	R^2	MAE	Sobreajuste
10	0,05	300	0,6279	0,4213	0,0112
8	0,05	600	0,6252	0,4229	0,0067
8	0,05	300	0,6207	0,4257	0,0040
6	0,10	300	0,6179	0,4275	0,0022
6	0,05	300 (atual)	0,6140	0,4300	0,0013
4	0,05	300	0,6030	0,4370	0,0006

B. Validação cruzada no treino (5 folds)			
Configuração	R^2 (média $\pm$ dp)	MAE	RMSE
Escolhida (profundidade 10)	$0,6281 \pm 0,0007$	$0,4213 \pm 0,0002$	$0,5628 \pm 0,0003$
Anterior (profundidade 6)	$0,6143 \pm 0,0007$	$0,4300 \pm 0,0001$	$0,5732 \pm 0,0002$


Como ler: “Sobreajuste” é a diferença entre o R^2 de treino e o de validação — valores próximos de zero indicam que o modelo não decorou os dados. A configuração escolhida melhora o R^2 em 1,4 ponto percentual sem aumentar o sobreajuste, e a variação entre *folds* é da ordem de 0,0007 — com 6,2 milhões de observações de treino, o desempenho praticamente não depende de qual pedaço dos dados é usado para validar. No conjunto de teste (intocado durante a escolha), $R^2 = 0,6280$. Na unidade original, o erro mediano de previsão é de R\$ 538 por mês (37% do rendimento observado), com correção de Duan para a retransformação do logaritmo.

xidade (modelos regularizados sobre 7,7 milhões de observações); e a estabilidade do R^2 de teste entre a subamostra de 20% e a população (praticamente idêntico, $\approx 0,62$). Em suma, *ampliar* a base, de amostral para populacional, *reduz* — não aumenta — o risco de sobreajuste.

Tabela 6: Importância SHAP Comparada — Random Forest e XGBoost. Predição de log-rendimento, PNAD 2016–2025 ($N_{\text{SHAP}} = 50.000$). Valores: $|\text{SHAP}|$ médio. Destaque em negrito: variáveis raciais/contextuais.

Feature	$ \text{SHAP} $ RF	Rank RF	$ \text{SHAP} $ XGB	Rank XGB
Renda média UPA (exceto o próprio)	0,32538	1	0,25705	1
Horas trabalhadas	0,16918	2	0,16727	2
CBO: Profissionais	0,11711	4	0,12157	3
Emprego formal (carteira)	0,14821	3	0,11753	4
Gênero (feminino)	0,09288	5	0,09908	5
Idade (centralizada)	0,06494	6	0,09663	6
Educ.: não registrada	0,03203	9	0,07138	7
Conta própria	0,02089	10	0,06304	8
CBO: Técnicos	0,03709	8	0,04778	9
CBO: Dirigentes	0,04052	7	0,04102	10
Raça (negro)	0,00006	24	0,03140	11
CBO: Serviços/Vendas	0,00052	20	0,03046	12
Desemprego na UPA	0,00073	17	0,02735	13
% Negro no Estado	0,00075	16	0,02493	14
CBO: Operários	0,00072	18	0,02415	15
CBO: Op. Máquinas	0,00005	25	0,02239	16
CBO: Administrativo	0,00234	14	0,01974	17
Trabalho doméstico	0,00651	12	0,01873	18
Desemprego no Estado	0,00036	21	0,01746	19
CBO: Agropecuária	0,00133	15	0,01583	20
Idade ² (experiência)	0,00641	13	0,01534	21
% Negro na UPA	0,00010	22	0,01320	22
CBO: FFAA/Polícia	0,01110	11	0,01311	23
Educ. média UPA	0,00009	23	0,01157	24
Educ. média Estado	0,00067	19	0,00908	25
Educ.: superior completo	0,00001	26	0,00517	26
Educ.: médio completo	0,00001	26	0,00475	27
Educ.: fundamental completo	0,00000	28	0,00104	28
Educ.: pós-graduação	0,00000	28	0,00011	29

Como ler a Tabela 6: variáveis ordenadas pela importância média ($|\text{SHAP}|$); valores maiores = maior peso na previsão da renda.



(a) Beeswarm: distribuição de SHAP por feature (XGBoost).

Figura 2: Contexto do bairro e jornada dominam a previsão de renda; a raça aparece na 11ª posição entre 29 preditores (SHAP, XGBoost, $N_{\text{SHAP}} = 50.000$).

Como ler a Figura 2: cada ponto é um trabalhador; quanto mais à direita (ou maior a barra), maior o efeito da variável na renda prevista. A cor indica se o valor da variável é alto ou baixo.

A Tabela 6 mostra o **contexto do bairro** entre os preditores de maior peso do rendimento individual. A variável usada aqui é a renda média da UPA *excluindo o próprio indivíduo* (*leave-one-out*): a média que inclui a própria pessoa é mecanicamente correlacionada com seu rendimento — o problema do reflexo (MANSKI, 1993) — e inflaria artificialmente a importância do território. Mesmo sem essa contaminação, o bairro permanece entre os preditores de primeira ordem, o que é consistente com a hipótese de Wilson (1987); a leitura correta, porém, é de *mediação* territorial — choques comuns ao bairro (mercado de trabalho local, transporte, redes) afetam todos os moradores — e não de efeito causal de um vizinho sobre o outro. Como checagem extrema, o mesmo XGBoost estimado *sem qualquer* renda de vizinhança perde pouco poder preditivo ($R^2 = 0,598$ contra 0,628 do modelo completo) e, nele, a contribuição média da raça é praticamente a mesma (0,031 contra 0,031 em $|\text{SHAP}|$): o sinal racial não é um artefato da variável de contexto — muda apenas a posição relativa no *ranking* (17ª de 28, contra 11ª de 29), porque as demais variáveis absorvem parte do que o território explicava.

A variável racial ocupa o 11º lugar no ranking de importância mesmo após controlar por todos os demais fatores, com SHAP médio de $-0,0469$ para trabalhadores negros — equivalente a uma penalidade de 4,6% sobre o rendimento predito que não pode ser atribuída a diferenças em educação, experiência, gênero ou contexto de moradia.




Figura 3: Como a previsão de um caso é construída: decomposição SHAP individual (*waterfall*) de um trabalhador negro de baixa renda. Valores em log-pontos; a contribuição da variável racial aparece isolada das demais.

Como ler a Figura 3: cada linha é uma variável de **um** trabalhador — não de uma média. A barra mostra quanto aquela variável empurra a previsão para cima ou para baixo, partindo da previsão média da base até a previsão final do caso. Serve para ver como o modelo compõe uma decisão, não para generalizar.

BARREIRA II — PENALIDADE SALARIAL E TETO DE VIDRO

Para quem supera a porta de entrada, qual é o custo de ser negro?

4.3 Decomposição do gap por mediação contextual e ocupacional

A Tabela 7 resume o resultado central dos modelos HLM: à medida que se adiciona o bairro (intercepto aleatório e contexto da UPA), o estado e a ocupação, o gap racial encolhe de 19,1% (agregado) para 7,0% (M4). *Como ler:* acompanhe a coluna β_{negro} aproximando-se de zero linha a linha — a fração do gap já explicada aparece em “Mediação acum.”; o que resta no M4 é a penalidade que nenhum atributo observável explica.

Como ler a Figura 4: cada barra é um modelo da sequência e, de cima para baixo, acrescenta-se um bloco de controles ao anterior. O comprimento da barra é a penalidade racial em log-rendimento e o rótulo dentro dela, a mesma penalidade em % de renda; o

Tabela 7: Decomposição do gap salarial racial por mediação contextual e ocupacional (HLM de dois níveis, indivíduos em UPA, com efeitos fixos de UF; PNAD Contínua 2016–2025, população completa). Cada linha acrescenta um bloco de controles ao anterior; à medida que se adiciona contexto e ocupação, o gap encolhe e a mediação acumulada cresce.

Modelo (controles acumulados)	β_{negro}	Gap (%)	Mediação acum. (%)
Agregado: individual + UF, sem efeito de bairro (OLS)	−0,2123	−19,1	—
M1: + intercepto aleatório de bairro (UPA)	−0,1124	−10,6	47,0
M2: + contexto do bairro (UPA)	−0,1076	−10,2	49,3
M3: + efeitos fixos de UF (gap líquido)	−0,1077	−10,2	49,3
M4: + ocupação e formalidade (limite inferior)	−0,0724	−7,0	65,9

Como ler: cada linha adiciona algo à anterior. β_{negro} é a penalidade racial em log-rendimento (mais próximo de zero = menor gap); “Gap (%)” é a penalidade em % de renda; “Mediação acum.” é a fração do gap agregado (primeira linha) já explicada. O salto da primeira para a segunda linha é a mediação pela segregação residencial: comparar negros e brancos *do mesmo bairro* reduz o gap quase à metade. Do modelo agregado ao M4 o gap cai de 19,1% para 7,0%: 65,9% do gap é mediado por onde a pessoa mora, o estado e a ocupação que acessa — e a penalidade de 7,0% persiste dentro da mesma ocupação (limite inferior, pois a ocupação é ela própria resultado da barreira de acesso).

traço fino é o intervalo de confiança de 95% com erro-padrão agrupado por UPA. Em azul, o M3 — o gap líquido.

Metade do gap racial desaparece ao comparar pessoas do mesmo bairro
...mas o que sobra não é explicado por escolaridade, idade, sexo, estado nem ocupação.




Figura 4: Metade do gap racial desaparece ao comparar pessoas do mesmo bairro — e o que sobra não é explicado por escolaridade, idade, sexo, estado nem ocupação. Barras: $\hat{\beta}_{\text{negro}}$ de cada modelo; traço: IC 95% (estreito pelo N de milhões); rótulo: gap em % de renda. Em azul, o M3 (gap líquido).

4.4 Decomposição de Oaxaca–Blinder: composição *vs.* discriminação

A decomposição de Oaxaca–Blinder separa o gap bruto de log-rendimento (0,4255 log-pontos, ou 53,0%) em uma parcela explicada por diferenças de dotações e uma parcela não explicada (retornos diferenciais — limite inferior da discriminação). A Tabela 8 apresenta duas especificações, porque ocupação e formalidade são *bad controls* (Angrist & Pischke, 2009): são elas próprias resultado da discriminação. Em (A), com os controles do HLM M3 (capital humano e contexto de UPA), 28,4% do gap não é explicado por características observáveis; em (B), tratando também horas, formalidade e grupo CBO como dotações, a parcela não explicada cai para 16,2% — a discriminação salarial *dentro* da ocupação. A diferença entre as duas (12,2 pontos percentuais) é a parcela da discriminação que opera pela *porta de entrada* das ocupações, e não pelo salário — exatamente o que o GLMM de acesso mede adiante. *Como ler:* em cada coluna, Dotações + Não explicado = 100%; os erros-padrão vêm de bootstrap em blocos por UPA.

Pressupostos das regressões por grupo. As duas regressões auxiliares (brancos e negros) foram submetidas aos testes de Breusch–Pagan e RESET (Fávoro & Belfiore, cap. 12). Há heterocedasticidade — esperada em log-rendimento — mas de magnitude modesta: o R^2 da regressão auxiliar do Breusch–Pagan é 0,061 (brancos) e 0,065 (negros), e é justamente por isso que os erros-padrão são agrupados por UPA e a decomposição usa bootstrap em blocos. O RESET rejeita a forma funcional linear, mas o ganho de R^2 ao acrescentar potências do valor predito é de 0,0009 (brancos) e 0,0038 (negros) — irrelevante para a decomposição. Com N de milhões, ambos os testes rejeitam qualquer

hipótese nula pontual; o que importa é a magnitude, não o p -valor (ANGRIST; PISCHKE, 2009).

Tabela 8: Decomposição de Oaxaca–Blinder (*twofold*, referência: estrutura de preços dos brancos) do gap salarial racial em duas especificações. (A) *Capital humano + contexto*: escolaridade, idade, sexo e contexto de UPA — os mesmos controles do HLM M3; a parcela não explicada é comparável à da literatura. (B) *Acesso*: (A) + horas, formalidade e grupo CBO tratados como dotações — a parcela não explicada é a discriminação *dentro* da ocupação, um limite inferior, pois a segregação ocupacional é ela própria discriminatória (Oaxaca & Ransom, 1999; ver o GLMM de acesso, Tabela 11). População completa da PEA com renda positiva ($N = 7.694.198$; 40.969 UPAs). Erros-padrão entre parênteses: bootstrap em blocos por UPA (500 réplicas).

Componente	(A) Sem ocupação		(B) Acesso (com ocupação)	
	log-pontos (SE)	% do gap	log-pontos (SE)	% do gap
Gap total (branco – negro)	0,4255 (0,0034)	100,0	0,4255 (0,0034)	100,0
Dotações (características observáveis)	0,3046 (0,0038)	71,6	0,3566 (0,0036)	83,8
Não explicado (retornos / discriminação)	0,1209 (0,0018)	28,4	0,0689 (0,0013)	16,2

Como ler: em cada especificação, Dotações + Não explicado = Gap total. De (A) para (B), parte do “não explicado” migra para “dotações” porque a ocupação passa a ser tratada como característica — é exatamente a parcela da discriminação que opera pela *porta de entrada*, e não pelo salário.

Tratar a ocupação como “característica” derruba a discriminação medida pela metade

A parcela que some é justamente a que opera na porta de entrada das ocupações.




Figura 5: Tratar a ocupação como “característica” derruba pela metade a discriminação medida: de 28,4% para 16,2% do gap. A parcela que some é a que opera na porta de entrada das ocupações — medida adiante pelo modelo de acesso.

Como ler a Figura 5: cada painel é uma cascata lida da esquerda para a direita. A primeira barra é o gap total em log-rendimento; a segunda desconta a parcela atribuída a diferenças de características (dotações); a terceira, em azul, é o que sobra sem explicação. A única diferença entre os painéis é se a ocupação entra ou não como característica.

4.5 Regressão Quantílica e RIF-OB: teto de vidro e *sticky floor*

A regressão quantílica estima o gap em cada ponto da distribuição de renda; a RIF-OB separa, por quantil, dotação e retorno. A Tabela 9 mostra o gap crescendo ao longo da distribuição (teto de vidro no gap bruto); a Tabela 10 revela o padrão complementar:

o componente de retorno (discriminação proporcional) é maior na base e *decrece* rumo ao topo (*sticky floor*). *Como ler*: na Tabela 10, Dotações + Retornos = 100% em cada quantil; siga a coluna Retornos caindo de 35,1% (q10) a 12,9% (q90) — a discriminação de preço pesa mais na base.

Por que os dois padrões não se contradizem. A regressão quantílica estima quantis *condicionais*: $\hat{\beta}(\tau)$ compara negros e brancos na mesma posição *dentro* da distribuição de pessoas com o mesmo perfil observável. O crescimento de $|\hat{\beta}(\tau)|$ ao longo de τ significa que a dispersão condicional do rendimento é maior entre brancos — *fanning out* na linguagem de Angrist e Pischke (2009) —, e não que “os negros do topo sofrem mais”: quantis não seguem indivíduos, e a leitura em termos de pessoas exigiria invariância de posto, que não se testa aqui. A RIF-OB, ao contrário, decompõe quantis *incondicionais* da distribuição de renda (FIRPO; FORTIN; LEMIEUX, 2018): responde “de que é feito o gap no q10 da renda do país”. Como a composição observável concentra negros na base, a parcela de retornos é maior ali; e como há mais dispersão condicional no topo, o coeficiente condicional cresce com τ . Os dois resultados são complementares — um é sobre o *preço* pago a características, o outro sobre a *distribuição* de características.

Tabela 9: Regressão quantílica: coeficiente $\hat{\beta}_{\text{negro}}$ por quantil e sexo. Gap (%) = $(e^{\hat{\beta}} - 1) \times 100$. M3: controles individuais + contexto UPA + UF efeito fixo. População completa. Entre parênteses (coluna Global): erro-padrão por bootstrap em blocos por UPA. *** $p < 0,001$ em todos os quantis e grupos.

Quantil	Global		Homens		Mulheres	
	$\hat{\beta}$ (SE)	Gap (%)	$\hat{\beta}$	Gap (%)	$\hat{\beta}$	Gap (%)
$\tau = 0.10$	−0.0832 (0.0019)	−8.0%	−0.0608	−5.9%	−0.1160	−11.0%
$\tau = 0.25$	−0.0734 (0.0013)	−7.1%	−0.0605	−5.9%	−0.0915	−8.7%
$\tau = 0.50$	−0.0813 (0.0012)	−7.8%	−0.0739	−7.1%	−0.0899	−8.6%
$\tau = 0.75$	−0.1039 (0.0013)	−9.9%	−0.1012	−9.6%	−0.1049	−10.0%
$\tau = 0.90$	−0.1235 (0.0019)	−11.6%	−0.1244	−11.7%	−0.1155	−10.9%
$\tau = 0.95$	−0.1317 (0.0024)	−12.3%	−0.1327	−12.4%	−0.1244	−11.7%
Δ (q90−q10)	−4.03pp *** (0.0024)		$Z = -16.95$		$p = 1.84e - 64$	

Teste de heterogeneidade quantílica (Koenker-Bassett style): H_0 : $\hat{\beta}(q)$ constante para todo q . SE por bootstrap em blocos por UPA, “ m de n ” ($B = 200$; $m = 1.229$ das 40.969 UPAs por réplica; SE escalado por $\sqrt{m/G}$, Bickel & Sakov, 2008). Sem a escala (conservador): $Z = -2.94$, $p = 3.3e - 03$.

Como ler a Figura 6: à esquerda, cada ponto é a penalidade racial estimada num quantil *condicional* τ (eixo vertical em log-pontos $\times 100$), e a faixa é o intervalo de 95% por bootstrap em blocos de UPA. À direita, cada barra é um quantil *incondicional* da renda e soma 100%: a parte azul é a parcela não explicada, com o valor escrito dentro.

Tabela 10: Decomposição RIF-OB (Firpo, Fortin & Lemieux, 2018) do gap salarial racial por quantil incondicional, em formato *two-fold* (referência: estrutura de preços dos brancos). Dotações: diferença de características observáveis (capital humano, ocupação, contexto). Retornos: parcela não explicada (componente discriminatório). Dotações + Retornos = 100% do gap em cada quantil. Padrão *sticky floor*: o componente de retornos (discriminação de mercado) é maior na base e decresce rumo ao topo. PNAD Contínua 2016–2025, população completa. Entre parênteses: erro-padrão por bootstrap em blocos por UPA.

Quantil	Gap obs. (SE)	Dotações (%)	Retornos (%)	<i>N</i>
q10	0,559 (0,007)	64,9 (0,8)	35,1 (0,7)	7.694.198
q25	0,310 (0,009)	68,8 (0,9)	31,2 (0,6)	7.694.198
q50	0,378 (0,008)	72,7 (0,9)	27,3 (0,4)	7.694.198
q75	0,470 (0,010)	75,5 (1,1)	24,5 (0,4)	7.694.198
q90	0,483 (0,011)	87,1 (1,9)	12,9 (0,9)	7.694.198

Teto de vidro e piso pegajoso são a mesma coisa vista de dois ângulos

À esquerda, quantis condicionais (dispersão maior no topo); à direita, quantis incondicionais da renda do país.




Figura 6: Teto de vidro e piso pegajoso são o mesmo fenômeno visto de dois ângulos. À esquerda, a penalidade em quantis *condicionais* cresce rumo ao topo (faixa: IC 95% por bootstrap em blocos de UPA); à direita, a parcela não explicada dos quantis *incondicionais* da renda é maior na base.

4.6 GLMM logístico: o teto de vidro no acesso

O modelo logístico multinível (`lme4::glmer`, intercepto aleatório de UPA e efeitos fixos de UF, estimado por Laplace na população completa) modela a probabilidade de três desfechos — cargo qualificado (CBO 1–4), renda no top 20% e no top 10% — em quatro degraus paralelos aos do HLM: M1 individual, M2 + contexto do bairro, M3 + vínculo (formalidade, setor público, conta própria, doméstico — *bad controls*, logo limite inferior) e M4 + interação **negro**×credencial. A Tabela 11 traz *odds ratios*, efeitos marginais, ICC e E-values; a Tabela 12, o ajuste e o desempenho de classificação.

O acesso também é “bairro”. No M1, a correlação intraclassa latente é de 0,198 para o cargo qualificado e 0,350 para o top 10%: entre 20% e 35% da variância latente do acesso está entre bairros. O teste de razão de verossimilhança do M2 contra o logit sem efeito aleatório (LR = 411.007 para o cargo; 337.418 para o top 10%, 1 g.l., $p < 0,001$)

mostra que o efeito aleatório de UPA é indispensável — o logit *pooled* trataria como independentes pessoas do mesmo mercado local.

A porta é mais estreita para negros — e mais ainda no topo. No M2, controlados escolaridade, sexo, idade, horas, estado e contexto do bairro, a chance de um trabalhador negro ocupar cargo qualificado é $OR = 0,699$ (IC 95% 0,696–0,702) da de um branco do mesmo bairro — **30% menos chance**, ou 5,5 pontos percentuais de probabilidade. No top 20% da renda o OR é 0,688 e no top 10%, 0,654 (35% menos chance): o teto se aperta à medida que se sobe. *Como ler:* $OR < 1$ é desvantagem; o AME traduz o OR em probabilidade e é a medida a reter (MHE, cap. 3).

Vínculo e credencial não desfazem a barreira. Descontar o vínculo empregatício (M3) muda pouco o OR do cargo qualificado (0,691) e do top 10% (0,656): a barreira não é um artefato da informalidade. No M4, a interação com a credencial é $OR = 1,069$ para o superior completo e 1,060 para a pós-graduação: o diploma atenua a penalidade sem eliminá-la, e o OR combinado do negro com superior completo é 0,735 — a credencial não neutraliza a barreira de acesso.

Ajuste e classificação. O M2 discrimina bem os desfechos: AUC de 0,831 (com efeitos aleatórios) e 0,790 (só efeitos fixos) para o cargo qualificado; no *cutoff* de Youden (0,30) a sensibilidade é 0,82 e a especificidade 0,68. O teste de Hosmer–Lemeshow rejeita a calibração perfeita em todos os degraus — inevitável com $N = 7,7$ milhões (MHE, cap. 8) —, mas a estatística cai a cerca de metade quando se acrescenta o vínculo (M3), sinal de calibração melhor; entre M1 e M2 ela praticamente não muda. O logit com efeitos fixos de UF e erro-padrão agrupado por UPA (última coluna da Tabela 11) reproduz os OR do GLMM: a conclusão não depende da hipótese de efeitos aleatórios. *Como ler a Figura 7:* cada ponto é uma razão de chances e a linha horizontal, seu intervalo de confiança de 95%; a linha tracejada em 1 marca a paridade, de modo que quanto mais à esquerda, maior a desvantagem. Os blocos são os três desfechos e, dentro de cada um, os modelos; em azul, o M2, que compara pessoas do mesmo bairro.

A porta é mais estreita para negros — e estreita ainda mais no topo da renda
GLMM com intercepto aleatório de UPA; em azul, o modelo com contexto de bairro (M2).




Figura 7: A porta é mais estreita para trabalhadores negros — e estreita ainda mais no topo da renda. Razão de chances de acesso (negro *vs.* branco do mesmo bairro) com IC 95%, por desfecho e degrau; em azul, o modelo com contexto de bairro (M2).

Tabela 11: GLMM logístico (lme4::glmer, intercepto aleatório de UPA e efeitos fixos de UF) — teto de vidro ocupacional e salarial. *Odds ratio* do coeficiente **negro** com IC 95%, efeito marginal médio (AME: diferença média de probabilidade predita, em pontos percentuais), ICC da UPA = $\tau^2/(\tau^2 + \pi^2/3)$ e E-value (VanderWeele & Ding, 2017). Coluna final: OR do logit com efeitos fixos de UF e erro-padrão agrupado por UPA (robustez). População completa da PEA com renda positiva ($N = 7.694.198$; 40.969 UPAs). M3 acrescenta o vínculo (formalidade, setor público, conta própria, doméstico), que é desfecho da própria discriminação: limite inferior. Todos os OR com $p < 0,001$; com N desta ordem, a inferência relevante está nos IC e nos E-values.

Desfecho	Modelo	OR (IC 95%)	AME (p.p.)	ICC _{UPA}	E-value	E-value (IC)	OR logit-FE
Cargo qualificado (CBO 1-4)	M1 individual + UF	0,691 [0,688; 0,694]	-5,68	0,198	2,25	2,24	0,555
	M2 + contexto do bairro	0,699 [0,696; 0,702]	-5,49	0,159	2,21	2,20	0,705
	M3 + vínculo (limite inf.)	0,691 [0,688; 0,694]	-4,79	0,162	2,25	2,24	0,705
	M4 + negro×credencial	0,688 [0,684; 0,691]	-4,79	0,162	2,27	2,25	0,699
Top 20% de renda	M1 individual + UF	0,680 [0,677; 0,683]	-4,89	0,281	2,30	2,29	0,540
	M2 + contexto do bairro	0,688 [0,685; 0,691]	-4,74	0,219	2,27	2,25	0,691
	M3 + vínculo (limite inf.)	0,690 [0,687; 0,693]	-4,43	0,227	2,26	2,24	0,691
	M4 + negro×credencial	0,689 [0,685; 0,692]	-4,43	0,227	2,26	2,25	0,694
Top 10% de renda	M1 individual + UF	0,643 [0,639; 0,647]	-3,10	0,350	2,49	2,46	0,457
	M2 + contexto do bairro	0,654 [0,650; 0,659]	-2,97	0,262	2,43	2,41	0,656
	M3 + vínculo (limite inf.)	0,656 [0,651; 0,660]	-2,80	0,265	2,42	2,40	0,656
	M4 + negro×credencial	0,661 [0,657; 0,666]	-2,80	0,265	2,39	2,37	0,664

Como ler: OR < 1 = menor chance de acesso para trabalhadores negros do que para brancos de mesmo perfil e do mesmo bairro; quanto mais perto de zero, maior a barreira. O E-value é a força mínima de associação (razão de risco) que um confundidor não observado precisaria ter com a raça e com o desfecho para anular o OR; o E-value (IC) faz o mesmo para o limite do intervalo. A coluna logit-FE mostra que a conclusão não depende da hipótese de efeitos aleatórios.

Tabela 12: GLMM logístico — ajuste e desempenho de classificação por degrau. LR vs. pooled: teste de razão de verossimilhança do M2 contra o logit sem efeito aleatório (fronteira, $p/2$); AUC com efeitos aleatórios (ajuste na amostra) e só com efeitos fixos; *cutoff* de Youden (maximiza sensibilidade + especificidade) com as taxas correspondentes; Hosmer–Lemeshow em 10 decis. Com $N = 7,7$ milhões qualquer desvio de calibração é “significativo” — o χ^2 deve ser lido como magnitude relativa entre degraus, não como teste (MHE, cap. 8).

Desfecho	Modelo	−2LL	AIC	LR vs. pooled	AUC (RE)	AUC (FE)	Cutoff	Sens./Espec.	HL χ^2
Cargo qualificado (CBO 1–4)	M1 individual + UF	7.068.424	7.068.498	—	0,831	0,766	0,30	0,82/0,68	8.378
	M2 + contexto do bairro	7.059.978	7.060.058	411.007	0,831	0,790	0,30	0,82/0,68	8.576
	M3 + vínculo (limite inf.)	6.089.887	6.089.975	—	0,882	0,856	0,31	0,83/0,77	5.269
	M4 + negro×credencial	6.089.819	6.089.911	—	0,882	0,856	0,31	0,83/0,77	5.178
Top 20% de renda	M1 individual + UF	6.104.884	6.104.958	—	0,844	0,770	0,22	0,78/0,74	4.038
	M2 + contexto do bairro	6.094.129	6.094.209	469.691	0,844	0,798	0,22	0,78/0,74	4.070
	M3 + vínculo (limite inf.)	5.779.565	5.779.653	—	0,862	0,821	0,22	0,79/0,76	1.584
	M4 + negro×credencial	5.779.560	5.779.652	—	0,862	0,821	0,23	0,78/0,77	1.597
Top 10% de renda	M1 individual + UF	3.713.826	3.713.900	—	0,878	0,788	0,10	0,82/0,77	4.049
	M2 + contexto do bairro	3.702.360	3.702.440	337.418	0,878	0,830	0,10	0,82/0,77	3.949
	M3 + vínculo (limite inf.)	3.502.169	3.502.257	—	0,893	0,852	0,11	0,82/0,80	1.934
	M4 + negro×credencial	3.502.075	3.502.167	—	0,893	0,852	0,11	0,82/0,80	1.869

4.7 Interseccionalidade: raça e gênero no acesso e no topo

Tabela 13: Decomposição interseccional (raça $\times$ gênero) do gap de rendimento *vs.* o Homem Branco (grupo de referência). Dotações: parcela explicada por características observáveis; Retornos: parcela não explicada (discriminação). Penalidade extra: o quanto o gap da Mulher Negra excede a soma das penalidades de raça e de gênero isoladas (efeito interseccional puro, Crenshaw, 1989). PNAD Contínua, população completa (N do grupo de referência — homens brancos — na última linha da nota). Entre parênteses: erro-padrão por bootstrap em blocos por UPA.

Grupo	Gap vs HB (%)	Dotações (%)	Retornos (%)	Penal. extra (p.p.)	N do grupo
Mulher Branca	19,7 (0,2)	-51,9 (1,0)	151,9 (1,0)	—	1.423.994
Homem Negro	56,3 (0,6)	73,9 (0,4)	26,1 (0,4)	—	2.664.739
Mulher Negra	80,6 (0,6)	35,3 (0,4)	64,7 (0,4)	4,6	1.769.943

Como ler: “Gap vs HB” é a desvantagem de renda de cada grupo *vs.* o Homem Branco; Dotações + Retornos = 100% do gap. A Mulher Negra tem o maior gap e ainda uma penalidade *extra* que não se reduz à soma de “ser negro” e “ser mulher” — a marca da interseccionalidade. O sinal negativo das dotações da Mulher Branca indica que suas características observáveis *superam* as do homem branco: todo o gap vem de retornos diferenciais. Grupo de referência: 1.835.522 homens brancos.

Os modelos anteriores tratam raça e gênero de forma aditiva. Uma leitura *interseccional* pergunta se a desvantagem de ser negra *e* mulher é a soma das partes. Reespecificamos o GLMM de acesso com um fator de quatro grupos (`grupo_rg`: homem branco [referência], mulher branca, homem negro, mulher negra) e a interação `negro $\times$ sexo_fem`, em três desfechos: acesso a ocupação qualificada (CBO 1–4), renda no top 20% e no top 10%. A Tabela 13 traz a decomposição de Oaxaca–Blinder dos quatro grupos contra o homem branco, e a Figura 8, as razões de chance nos três desfechos.

Como ler a Figura 8: cada barra é um grupo raça $\times$ gênero; a altura é o gap *vs.* o homem branco — a mulher negra acumula as duas penalidades.

O resultado revela uma **inversão** (Figura 8). No **acesso à categoria** qualificada, a mulher negra tem OR = 1,33 — *acima* do homem branco —, porque o efeito de gênero é positivo nesse desfecho (profissões credenciadas feminizadas, em CBO 1–4); o grupo mais penalizado é o **homem negro** (OR = 0,65). No **topo da renda**, porém, o quadro *inverte*: a mulher negra passa a ser a **mais excluída** de todos — OR = 0,34 no decil superior, abaixo da mulher branca (= 0,49) e do homem negro (= 0,65). A interação `negro $\times$ sexo_fem` é *sub-aditiva* em todos os desfechos (OR = 1,14 no acesso; = 1,07 no top 10%): a penalidade racial é ligeiramente menor entre mulheres, mas isso não impede que a mulher negra acumule a barreira racial *e* o teto de vidro de gênero exatamente onde mais importa para a ascensão — o topo da distribuição.

Esse achado refina a tese central: o teto de vidro não é racial nem sexualmente neutro — recai com força máxima sobre a mulher negra, que pode *entrar* em ocupações qualificadas, mas é sistematicamente barrada de *chegar ao topo* da remuneração.




Figura 8: A mulher negra entra na categoria, mas não chega ao topo: razões de chance dos quatro grupos raça×gênero *vs.* homem branco, em três desfechos. A mulher negra é *alçada* no acesso à categoria, mas torna-se a *mais excluída* no topo da renda.

4.8 Multicolinearidade do Modelo M4: Análise VIF

Para verificar se a inclusão simultânea dos 9 dummies CBO e das variáveis de vínculo empregatício (`emprego_formal`, `conta_propria`, `trab_domestico`) introduz colinearidade problemática no Modelo M4, calculou-se o *Variance Inflation Factor* (VIF) sobre subsample de 200.000 observações da PEA com renda positiva. Dos 24 preditores analisados, VIF máximo = 22,25 (Educ.: não registrada); 2 variável crítica (VIF > 10); 1 variável alta (5–10); 1 variável moderada (2–5); 20 variáveis baixas (< 2). Os dois VIF acima de 10 são `educ_missing` (22,25) e `educ_superior_completo` (19,45) — colinearidade *por construção* dentro do bloco educacional, já que o indicador de escolaridade não registrada é quase o complemento das *dummies* de conclusão (Fávero & Belfiore, cap. 12). Ela infla o erro-padrão dos retornos educacionais, que por isso são lidos com cautela, mas **não** contamina o coeficiente de interesse: o VIF de `negro` é 1,37 e o das variáveis de contexto da UPA fica abaixo de 1,8. Entre os *dummies* de CBO e as variáveis de vínculo — a colinearidade que se temia no M4 — o VIF máximo é 2,09. A especificação do M4 dispensa, portanto, ortogonalização ou eliminação de preditores; o que ela não dispensa é a ressalva de *bad control* (Seção 4.1).

5 Discussão e Prescrição

Nota terminológica. Três conceitos próximos, mas distintos, percorrem este trabalho e não devem ser confundidos. **Mediação contextual** (HLM) é a fração do gap bruto

que *desaparece* ao se controlar o local de moradia (UPA/UF) — mede o quanto da penalidade racial transita *pelo* território. **Efeito dotação** (Oaxaca–Blinder) é a parcela do gap atribuível a *diferenças nas características observáveis* entre brancos e negros (escolaridade, ocupação, contexto), por oposição ao **efeito retornos** (preços diferenciais pagos às mesmas características). **Gap líquido** é o diferencial que *persiste* após o controle de capital humano e contexto (M3): 10,2%. **Gap residual pós-ocupação** é o que resta ao se controlar também ocupação e formalidade (M4): 7,0% — um limite inferior, pois a ocupação é ela própria resultado da barreira de acesso. Em suma: a mediação contextual responde “por onde passa o gap”; a decomposição de dotações, “de que ele é feito”; e o gap líquido, “o que sobra sem explicação”.

Da diagnose às políticas. O diagnóstico das duas barreiras revela gargalos simultâneos — exclusão de acesso às ocupações qualificadas e penalidade salarial que persiste dentro delas — que se reforçam mutuamente. A consequência para o desenho de políticas é direta: nenhuma intervenção unidimensional (só cotas de acesso, só fiscalização salarial, só escolaridade) atinge as duas barreiras ao mesmo tempo; a magnitude relativa de cada uma, estimada aqui, é o insumo para priorizá-las.

O que este trabalho acrescenta ao debate. Hasenbalg (1979) identificou a discriminação racial como estrutural, sem poder quantificar mecanismos em escala nacional. Henriques (2001) documentou o gap educacional racial, mas não separou o efeito educacional do de redes e contexto. Soares (2009) estimou, com dados de 2006, que cerca de 50% do gap salarial seria “inexplicado” — interpretado como discriminação direta. Este trabalho, com dados de 2016–2025 e metodologias não disponíveis a Soares, decompõe essa *caixa preta*. Na especificação comparável à dele (capital humano e contexto, sem ocupação), 28,4% do gap bruto são retornos diferenciais — limite inferior da discriminação direta — e 71,6% são diferenças de dotações; quando a ocupação é tratada como dotação, o não explicado cai para 16,2%, e 83,8% passam a ser dotações — mas essas dotações são, elas mesmas, produto da barreira de acesso às ocupações qualificadas (GLMM), que este trabalho quantifica em conjunto com a penalidade salarial. A contribuição central não é mostrar que o gap existe — isso a literatura já sabia desde Hasenbalg (1979) —, mas demonstrar que ele é sustentado por um **sistema combinado** em que discriminação de acesso, segregação residencial e penalidade salarial se reforçam mutuamente, tornando insuficientes políticas focadas em um único mecanismo.

Diálogo com o quadro macro recente do IBGE. Os resultados convergem com o retrato macroestrutural mais recente. A melhora multidimensional captada pela POF não eliminou o gap racial de qualidade de vida (0,183 para chefes pretos/pardos *vs.* 0,122 para brancos), e a renda voltou a concentrar-se no topo em 2025 (Gini do rendimento domiciliar

per capita de 0,491) (IBGE, 2019; IBGE, 2025). Cabe uma ressalva metodológica: o Gini estimado neste trabalho refere-se ao **rendimento do trabalho entre ocupados** (em torno de 0,48), conceito distinto do Gini domiciliar *per capita* de todas as fontes do IBGE — níveis próximos, mas medidas diferentes que podem divergir em tendência, pois a alta de 2025 é puxada por renda *não*-trabalho do topo, que não transita pelo rendimento dos ocupados. Nesse mesmo conceito, a desigualdade *interna* é maior entre brancos ($= 0,485$) do que entre negros ($= 0,449$) — não por equidade, mas por confinamento dos negros ao piso da distribuição, o reverso distribucional do teto de vidro. O contraste territorial reforça a tese: o Distrito Federal, de maior renda *per capita* do país, é também a UF de *maior* penalidade racial salarial em nossos modelos regionais — riqueza média elevada e desigualdade racial aguda coexistem no mesmo território.

Triangulação com o Índice de Progresso Social (IPS). O IPS municipal (Imazon e parceiros, 2026) — que avalia a qualidade de vida dos 5.570 municípios brasileiros a partir de 57 indicadores sociais e ambientais — oferece corroboração externa e multidimensional do eixo territorial desta tese. Uma integração *final* com o nosso proxy de bairro (UPA) é, contudo, inviável: o painel público da PNAD não divulga o município (apenas UF e a situação capital/RM/interior), e o IPS é municipal — portanto mais agregado que a UPA, que é sub-municipal. O IPS, assim, não valida o achado de *bairro* (situa-se acima dele na escala), mas ecoa o gradiente macro: as regiões de menor progresso social (Norte e Nordeste) coincidem com as de maior penalidade racial em nossos modelos. Empregamo-lo, portanto, como evidência *convergente* do caráter territorial da desigualdade — não como fonte de dados integrada, e ressaltando que o IPS mede progresso social geral, não desigualdade racial.

A segregação residencial como multiplicador da desigualdade. O achado mais robusto desta análise é que 47,0% do gap salarial racial condicional a capital humano é mediado pelo bairro de moradia — muito além do que modelos cross-sectionais típicos, que ignoram a estrutura aninhada dos dados, seriam capazes de estimar. O coeficiente contextual $\hat{\gamma}_{01} = -0,2189$ por desvio-padrão da proporção de negros na UPA indica que a penalidade de viver em bairro segregado é da mesma ordem de grandeza da própria penalidade individual de ser negro — e que 36,9% da variância do rendimento está entre bairros, não entre pessoas. Isso sugere que políticas de redistribuição de renda que não enfrentem a segregação residencial terão eficácia limitada sobre o gap racial.

Subvalorização do capital humano negro. A decomposição de Oaxaca–Blinder atribui 28,4% do gap a *retornos* diferenciais — as mesmas características de capital humano e contexto rendem menos a trabalhadores negros — e ainda 16,2% quando a própria posição ocupacional é descontada; a decomposição RIF mostra que essa parcela chega

a 35% na base da distribuição. O GLMM acrescenta que a credencial educacional não neutraliza a barreira de acesso (OR de **negro** próximo de 0,7 mesmo entre os mais escolarizados). Juntas, essas evidências indicam um duplo obstáculo ao retorno educacional: além da penalidade direta mensurada pelo HLM, o acesso desigual às ocupações que convertem credenciais em renda. Granovetter (1973) oferece o mecanismo plausível — redes de indicação que não cruzam fronteiras sociais —, hipótese que este trabalho não testa diretamente e que fica como agenda.

Persistência da discriminação direta. O gap líquido de 10,2%, estimado após controlar por todos os vetores de transmissão contextual, representa um piso para a discriminação direta não explicada por diferenças observáveis. Os valores SHAP reforçam essa interpretação: a variável racial mantém o 11º lugar na importância preditiva do XGBoost mesmo quando o modelo tem acesso completo às variáveis educacionais, demográficas e contextuais. Essa evidência é consistente com os experimentos de auditoria de Pager (2007), que demonstram experimentalmente a discriminação racial em processos seletivos.

Lenta convergência racial. A redução de apenas 2,4% do gap em dez anos — equivalente a 0,001 ponto de log-rendimento por ano ($\delta = 0,000847$, $p = 0,077$, WLS 2016–2025) — sugere que, ao ritmo atual, a convergência racial levaria mais de um século para eliminar o diferencial observado em 2016. Essa constatação não trivializa avanços recentes em políticas de cotas e acesso ao ensino superior, mas evidencia que reformas no campo da educação, sem intervenção simultânea nos mecanismos de segregação residencial e de acesso às redes profissionais, são insuficientes.

Ancoragem em políticas públicas existentes. As barreiras estimadas não são abstrações: cada uma corresponde a um instrumento jurídico-institucional já existente no Brasil, cuja intensificação ou aperfeiçoamento os resultados sugerem. A **barreira de acesso** (GLMM, OR = 0,699 para CBO 1–4 no modelo com contexto) dialoga diretamente com a *Lei 12.990/2014*, que reserva 20% das vagas em concursos públicos federais a candidatos negros, e cujo escopo o diagnóstico sugere ampliar para níveis hierárquicos superiores — onde o teto de vidro é mais severo (OR(top 10%) = 0,654). A **qualificação e o acesso ao ensino superior** correspondem ao *Prouni* e ao *Fies*, bem como ao legado do *PRONATEC*; o achado de que as mesmas credenciais rendem menos a trabalhadores negros (efeito retornos da decomposição de Oaxaca–Blinder) indica que tais programas precisam ser combinados a mecanismos de inserção ocupacional, sob pena de retorno marginal decrescente. O **combate à discriminação direta** encontra base na *Lei 9.029/1995* (que proíbe práticas discriminatórias na relação de trabalho) e no *Estatuto da Igualdade Racial* (*Lei 12.288/2010*), cuja fiscalização o gap líquido de 10,2% — e a penalidade de 7,0% que persiste dentro da mesma ocupação — justifica reforçar.

6 Conclusão

Este estudo mostra que a meritocracia baseada em capital humano falha sistematicamente em explicar a trajetória profissional da população negra no Brasil. A exclusão não é um evento isolado na contratação, nem uma consequência automática de menor escolaridade — é uma engrenagem de duas camadas que opera ao longo de toda a trajetória do trabalhador: na porta de entrada das ocupações de prestígio e no salário dentro das mesmas ocupações. Cada uma dessas camadas foi identificada, isolada e medida de forma independente; juntas, elas formam um sistema que nenhuma política unidimensional consegue desmontar.

O achado mais desafiador para o debate de políticas públicas é o da barreira de acesso: com a mesma escolaridade, idade, sexo e contexto de moradia, trabalhadores negros têm cerca de 30% menos chance de ocupar um cargo qualificado e 35% menos chance de chegar ao décimo superior da renda. Isso significa que aumentar a escolaridade da população negra, sem intervir simultaneamente nos mecanismos de seleção e promoção, produz retorno marginal decrescente: os títulos existem, mas os canais que os convertem em mobilidade profissional permanecem estreitos. Políticas baseadas apenas em educação são, portanto, necessárias, mas estruturalmente insuficientes.

O ritmo de convergência observado na última década reforça a urgência. Ao passo atual, a eliminação do diferencial racial levaria mais de um século. Não é uma previsão, e sim uma extrapolação aritmética da combinação entre a magnitude do gap e a velocidade atual de redução — velocidade que, aliás, não se distingue de zero aos níveis convencionais ($p = 0,077$): a leitura conservadora é que a década não produziu convergência mensurável. Significa, concretamente, que reformas incrementais são insuficientes: é necessário atacar as duas barreiras de forma simultânea e com recursos proporcionais à magnitude do problema.

Com a mesma escolaridade, idade, sexo e bairro, um trabalhador negro ganha 10,2% a menos que um branco — e a barreira mais dura não é o salário, é a porta: 30% menos chance de chegar a um cargo qualificado. O mercado de trabalho brasileiro não é racialmente neutro, e educação sozinha não corrige isso.

Essas conclusões emergem da convergência de quatro métodos e cinco análises de robustez sobre $N = 7.694.198$ observações da PNAD Contínua 2016–2025. O gap condicional a capital humano, de 19,1% (sem efeito de bairro), decompõe-se em três parcelas: (i) mediação de 47,0% pela segregação residencial — comparando negros e brancos do mesmo bairro ($\hat{\gamma}_{01} = -0,2189$ por desvio-padrão da composição racial do bairro), chega-se ao **gap líquido de 10,2%** (M3); (ii) mediação ocupacional de 16,6% pelo acesso desigual a grupos CBO de alta remuneração; e (iii) penalidade de 7,0% que persiste *dentro*

da mesma ocupação (M4) — limite inferior descritivo, pois a própria ocupação é resultado da barreira de acesso. O GLMM logístico confirma essa barreira: $OR = 0,699$ para CBO 1–4 no modelo com contexto, com gradiente progressivo $OR(\text{top } 20\%) = 0,688 \rightarrow OR(\text{top } 10\%) = 0,654$. A regressão quantílica formaliza o teto de vidro no gap condicional ($Z = -16,95, p < 0,001$), e a decomposição RIF mostra que a parcela de retornos é maior na base da distribuição incondicional.

Contribuição principal. Este estudo oferece, ao nosso conhecimento, a primeira análise integrada de modelo hierárquico, decomposição de Oaxaca–Blinder, regressão quantílica com RIF e modelo logístico de acesso — validados por SHAP — sobre a série completa da PNAD Contínua. Mais do que confirmar a existência do gap racial — resultado já documentado desde Hasenbalg (1979) —, este trabalho identifica e quantifica os **mecanismos** que o sustentam em 2016–2025: discriminação de acesso, segregação residencial e penalidade salarial dentro da ocupação, em sistema combinado.

Limitações e escopo de validade

Natureza inferencial *vs.* preditiva dos modelos. Os resultados devem ser lidos sob dois regimes epistemológicos distintos. Os modelos HLM, a decomposição de Oaxaca–Blinder, a regressão quantílica e o modelo logístico de acesso produzem *estimativas de associação condicional*: medem o diferencial racial que persiste após o controle de covariáveis observáveis, sob o pressuposto de seleção em observáveis. Não constituem, por si sós, prova de causalidade no sentido contrafactual, pois não derivam de desenho experimental ou quase-experimental. Já o XGBoost e os valores SHAP têm finalidade *preditiva e interpretativa*: quantificam a contribuição de cada variável para a *previsão* do rendimento — não o efeito causal de manipulá-la. A convergência entre os dois regimes (a raça permanece preditora de primeira ordem e mantém coeficiente negativo significativo sob controle exaustivo) é o que confere robustez ao diagnóstico; ainda assim, a linguagem causal foi deliberadamente evitada.

Cobertura da variável de escolaridade. A escolaridade detalhada (`educ_cat`) está registrada para cerca de 31% da PEA no painel público utilizado. Para preservar o N completo, os níveis de instrução entram como *dummies* de conclusão acompanhadas de um indicador explícito de não-registro (`educ_missing`), de modo que a categoria de referência não confunda “baixa escolaridade” com “dato ausente”. Testes de sensibilidade mostram que o coeficiente racial é estável a essa especificação (variação inferior a 1%); ainda assim, os retornos educacionais devem ser interpretados com a cautela própria de uma variável parcialmente observada.

Condicionar em quem tem renda positiva. Todos os modelos de rendimento são estimados entre ocupados com renda positiva. Isso é *condicionar no desfecho* (Angrist e Pischke (2009), cap. 3): se a discriminação também reduz a probabilidade de estar ocupado, o gap salarial condicional mistura o efeito sobre o salário com a seleção de quem permanece na amostra. A direção provável do viés é de *subestimação*: se os trabalhadores negros que conseguem se manter ocupados são positivamente selecionados em atributos não observados, o gap entre os observados é menor que o gap potencial na população. O modelo logístico de acesso trata diretamente a outra metade do problema — a probabilidade de chegar à ocupação qualificada — e a correção de Heckman, estimada na versão estendida deste trabalho, indicou seleção não nula ($\hat{\lambda}$ significativo), com o coeficiente racial estável em sinal e ordem de grandeza. A leitura correta é, portanto: o gap líquido aqui reportado é o gap *entre ocupados*, não o gap potencial de toda a população em idade ativa.

As hipóteses, uma a uma, e o que acontece se falharem. Seguindo a recomendação de “ser o próprio cético” (Angrist e Pischke (2009), cap. 8):

1. **Seleção em observáveis (CIA).** O gap líquido só é o efeito do tratamento diferencial se, condicional a X , a raça for “como se” aleatória. Não é: qualidade da escola, habilidade não medida e redes ficam fora. Se esses omitidos correlacionam negativamente com ser negro e positivamente com renda, o coeficiente *superestima* a discriminação — por isso o gap líquido é apresentado como limite superior dessa leitura, e o Konfound/E-value quantificam quanto de confundimento seria preciso.
2. **Bad controls.** Ocupação, formalidade e horas são desfechos da própria discriminação. Com eles (M4, Oaxaca-Blinder de acesso) o resultado é um *limite inferior descritivo*: a parcela que opera pela porta de entrada some da conta. Sem eles (M3, especificação (A) da Oaxaca-Blinder) tem-se o gap total condicional a capital humano e bairro. As duas versões são reportadas lado a lado.
3. **Reflexo (Manski).** A renda média do bairro inclui o próprio indivíduo; usada como preditor, é mecanicamente informativa. Nos modelos de acesso ela foi removida e, no XGBoost, substituída pela média *leave-one-out*; ainda assim, choques comuns ao bairro impedem leitura causal do coeficiente contextual.
4. **Efeitos aleatórios.** O HLM e o GLMM supõem que o efeito de bairro não é correlacionado com os regressores. Como contraprova, todos os coeficientes foram reestimados com efeitos fixos de UF e erro-padrão agrupado por UPA, com as mesmas conclusões (Subseção 3.7).
5. **Pesos e desenho amostral.** As estimativas são não ponderadas: descrevem a regressão na amostra. A robustez ponderada pelo peso da PNAD muda o gap em

menos de meio ponto percentual.

6. **Correlação intragrupo.** Ignorá-la subestimaria os erros-padrão (Moulton); todos os modelos reportam erro-padrão agrupado por UPA ou o modelam por efeito aleatório, e o agrupamento por UF usa t com $G - 1$ graus de liberdade.
7. **Significância com N grande.** Com 7,7 milhões de observações, quase tudo é “significativo”; a leitura privilegia magnitude, intervalos de confiança e E-values, não asteriscos.

Desenho transversal e direções futuras. O caráter transversal do painel público impede a análise de trajetórias individuais; o painel rotativo completo com microdado identificado e a extensão à RAIS permitiriam investigar mobilidade e o teto de vidro em cargos de liderança com identificação de firma. A análise de redes de co-residência, a tipologia por agrupamento e a priorização de políticas por pesquisa operacional, desenvolvidas em versão estendida deste trabalho, ficam como agenda.

Declaração de uso de inteligência artificial. Na elaboração deste trabalho foram utilizadas ferramentas de inteligência artificial (Claude Code, da Anthropic) como apoio à implementação e depuração de código (Python e R), à geração de figuras e tabelas e à formatação dos documentos. A concepção da pesquisa, a escolha das metodologias, a interpretação dos resultados e a redação final são de responsabilidade do autor, que revisou, validou e responde por todo o conteúdo.

Referências

- ALMEIDA, S. L. d. *Racismo Estrutural*. São Paulo: Jandaíra, 2019.
- ANGRIST, J. D.; PISCHKE, J.-S. *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton: Princeton University Press, 2009.
- ARROW, K. J. The theory of discrimination. In: ASHENFELTER, O.; REES, A. (Ed.). *Discrimination in Labor Markets*. Princeton, NJ: Princeton University Press, 1973. p. 3–33.
- BECKER, G. S. *The Economics of Discrimination*. Chicago: University of Chicago Press, 1957.
- BICKEL, P. J.; SAKOV, A. On the choice of m in the m out of n bootstrap and confidence bounds for extrema. *Statistica Sinica*, v. 18, n. 3, p. 967–985, 2008.
- BLINDER, A. S. Wage discrimination: Reduced form and structural estimates. *Journal of Human Resources*, v. 8, n. 4, p. 436–455, 1973.
- BREIMAN, L. Random forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001.
- CAMERON, A. C.; GELBACH, J. B.; MILLER, D. L. Bootstrap-based improvements for inference with clustered errors. *The Review of Economics and Statistics*, v. 90, n. 3, p. 414–427, 2008.
- CHEN, T.; GUESTRIN, C. XGBoost: A scalable tree boosting system. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. [S.l.: s.n.], 2016. p. 785–794.
- CRENSHAW, K. Demarginalizing the intersection of race and sex: A black feminist critique of antidiscrimination doctrine. *University of Chicago Legal Forum*, v. 1989, n. 1, p. 139–167, 1989.
- DUAN, N. Smearing estimate: A nonparametric retransformation method. *Journal of the American Statistical Association*, v. 78, n. 383, p. 605–610, 1983.
- FIRPO, S. P.; FORTIN, N. M.; LEMIEUX, T. Decomposing wage distributions using recentered influence function regressions. *Econometrics*, v. 6, n. 2, p. 28, 2018.
- FRANK, K. A.; MAROULIS, S. J.; DUONG, M. Q.; KELCEY, B. M. What would it take to change an inference? using rubin's causal model to interpret the robustness of causal inferences. *Educational Evaluation and Policy Analysis*, v. 35, n. 4, p. 437–460, 2013.
- GRANOVETTER, M. S. The strength of weak ties. *American Journal of Sociology*, v. 78, n. 6, p. 1360–1380, 1973.
- HASENBALG, C. *Discriminação e Desigualdades Raciais no Brasil*. Rio de Janeiro: Graal, 1979.
- HENRIQUES, R. Desigualdade racial no brasil: Evolução das condições de vida na década de 90. *Texto para Discussão IPEA*, n. 807, 2001.

- IBGE. *Pesquisa de Orçamentos Familiares 2017–2018: análise da qualidade de vida (Índice de Perda de Qualidade de Vida)*. Rio de Janeiro, 2019.
- IBGE. *Pesquisa Nacional por Amostra de Domicílios Contínua: Notas Metodológicas*. Rio de Janeiro, 2023.
- IBGE. *Pesquisa Nacional por Amostra de Domicílios Contínua: Rendimento de Todas as Fontes 2025*. Rio de Janeiro, 2025.
- KOENKER, R.; BASSETT, G. Regression quantiles. *Econometrica*, v. 46, n. 1, p. 33–50, 1978.
- LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, v. 30, 2017.
- MANSKI, C. F. Identification of endogenous social effects: The reflection problem. *Review of Economic Studies*, v. 60, n. 3, p. 531–542, 1993.
- MARQUES, E. Redes sociais, segregação e pobreza em são paulo. *Dados: Revista de Ciências Sociais*, v. 53, n. 1, p. 5–50, 2010.
- OAXACA, R. Male-female wage differentials in urban labor markets. *International Economic Review*, v. 14, n. 3, p. 693–709, 1973.
- OAXACA, R. L.; RANSOM, M. R. Identification in detailed wage decompositions. *Review of Economics and Statistics*, v. 81, n. 1, p. 154–157, 1999.
- PAGER, D. *Marked: Race, Crime, and Finding Work in an Era of Mass Incarceration*. Chicago: University of Chicago Press, 2007.
- RAUDENBUSH, S. W.; BRYK, A. S. *Hierarchical Linear Models: Applications and Data Analysis Methods*. 2. ed. Thousand Oaks, CA: Sage, 2002.
- SAMPSON, R. J.; RAUDENBUSH, S. W.; EARLS, F. Neighborhoods and violent crime: A multilevel study of collective efficacy. *Science*, v. 277, p. 918–924, 1997.
- SOARES, S. Desigualdade racial de renda no brasil: 1976–2006. *Estudos Econômicos*, v. 39, n. 4, p. 803–825, 2009.
- VANDERWEELE, T. J.; DING, P. Sensitivity analysis in observational research: Introducing the e-value. *Annals of Internal Medicine*, v. 167, n. 4, p. 268–274, 2017.
- WILSON, W. J. *The Truly Disadvantaged: The Inner City, the Underclass, and Public Policy*. Chicago: University of Chicago Press, 1987.